



N I N ng Th Th y H i quy tuy n t nh D b o gi nh t

Hóa học đại cương (Trường Đại học Bách khoa Hà Nội)



Scan to open on Studeersnel

TRƯỜNG ĐẠI HỌC BÁCH KHOA HÀ NỘI
VIỆN TOÁN ỨNG DỤNG VÀ TIN HỌC



HỒI QUY TUYỂN TÍNH
VÀ ỨNG DỤNG DỰ BÁO GIÁ NHÀ ĐẤT

ĐỒ ÁN I

Chuyên ngành: TOÁN TIN
Chuyên sâu: TOÁN ỨNG DỤNG

Giảng viên hướng dẫn : TS. LÊ ĐÌNH NAM
Sinh viên thực hiện : NÔNG THỊ THỦY
Mã số sinh viên : 20195926
Lớp : Toán Tin 02 - K64

Chữ kí của GVHD

HÀ NỘI - 2022

NHẬN XÉT CỦA GIẢNG VIÊN HƯỚNG DẪN

1. Mục đích và nội dung của đề án

2. Kết quả đạt được

3. Ý thức làm việc của sinh viên

Hà Nội, ngày tháng 08 năm 2022

Giảng viên hướng dẫn

(Ký và ghi rõ họ tên)

Mục lục

Lời mở đầu	3
1 HỌC MÁY NÓI CHUNG	4
1.1. Học máy là gì?	4
1.2. Học máy trong thực tế	4
1.2.1. Phân tích văn bản	4
1.2.2. Xử lý ảnh	5
1.2.3. Khai phá dữ liệu	5
1.2.4. Trò chơi điện tử và robot	5
1.3. Phân loại các thuật toán của học máy	5
1.3.1. Học máy có giám sát	5
1.3.2. Học máy không giám sát	6
2 HỒI QUY TUYẾN TÍNH	7
2.1. Giới thiệu	7
2.1.1. Giới thiệu về phương pháp	7
2.1.2. Sự cần thiết của phương pháp	7
2.1.3. Tính tuyến tính trong mô hình	8
2.2. Mô hình hồi quy tuyến tính cổ điển	8
2.3. Phương pháp bình phương tối thiểu	9
2.3.1. Tiếp cận $\hat{\beta}$ bằng các biến đổi đại số	10
2.3.2. Tiếp cận $\hat{\beta}$ bằng hình học	10
2.3.3. Ước lượng bình phương cực tiểu của hệ số hồi quy	11
2.3.4. Tính chất của ước lượng bình phương cực tiểu	13
2.3.5. Định lý Gauss về bình phương cực tiểu	13
2.3.6. Hệ số xác định R	14
2.4. Ước lượng khoảng của mô hình hồi quy	15
2.4.1. Ước lượng khoảng tin cậy của các hệ số β	15
2.4.2. Kiểm định giả thuyết về các hệ số hồi quy	18

2.5. Ước lượng hàm hồi quy tuyến tính	20
2.5.1. Ước lượng hàm hồi quy tại z_0	20
2.5.2. Dự đoán quan sát mới tại z_0	21
2.6. Kiểm tra mô hình và các khía cạnh khác của hồi quy	24
2.6.1. Chuẩn hoá tập mẫu	24
2.6.2. Outlier và cách xử lý	24
2.6.3. Độ đo Leverage	24
2.6.4. Quy tắc 1.5IQR	25
2.6.5. Kiểm tra tính phụ thuộc vào biến của mô hình	26
2.6.6. Kiểm tra tính đa cộng tuyến của các biến dự đoán và cách khắc phục	27
2.6.7. Giá trị thống kê kiểm định và trị số p	28
2.6.8. Khảo sát phần dư	29
2.6.9. Xác định các biến quan trọng	32
2.7. Hồi quy tuyến tính đa bội	33
2.7.1. Xây dựng mô hình	33
2.7.2. Ước lượng các tham số	34
2.7.3. Các tính chất quan trọng	38
2.7.4. Đưa ra dự đoán từ mô hình hồi quy tuyến tính đa bội	40
3 ỨNG DỤNG HỒI QUY TUYẾN TÍNH DỰ BÁO GIÁ NHÀ ĐẤT	43
3.1. Mô tả bài toán	43
3.1.1. Đặt vấn đề	43
3.1.2. Bài toán	43
3.2. Xây dựng bộ dữ liệu	44
3.2.1. Tiến hành phân tích hồi quy	44
3.2.2. Mô tả bộ dữ liệu	45
3.3. Kiểm nghiệm thuật toán và áp dụng	47
3.4. Đánh giá thuật toán	53
Tổng kết	53
Tài liệu tham khảo	54

Lời mở đầu

Cùng với sự phát triển của công nghệ, trí tuệ nhân tạo trong những năm gần đây có ảnh hưởng rất lớn tới nhiều lĩnh vực, gắn liền với nó là thuật ngữ học máy. Học máy là một dạng chương trình mà ta có thể đưa dữ liệu bất kỳ vào (âm thanh, hình ảnh, chữ,...), rồi chương trình sẽ chạy và đưa ra kết quả đầu ra. Tức, học máy có thể đưa ra kết quả dự báo với độ chính xác nào đó. Và độ chính xác của dự báo sẽ phụ thuộc vào số lượng, thời lượng của dữ liệu đầu vào. Số lượng dữ liệu càng lớn thì dự báo của học máy càng chính xác. Sau dữ liệu, thuật toán chính là công cụ để học máy có thể đưa ra những dự báo chính xác.

Nhận thấy tầm quan trọng của học máy, em đã quyết định lựa chọn tìm hiểu, nghiên cứu một thuật toán quan của nó đối với dữ liệu. Có rất nhiều mô hình cũng như thuật toán trong phân tích dữ liệu của học máy, và trong đồ án này, em sẽ trình bày một trong những thuật toán cơ bản nhất của học máy. Đó là thuật toán hồi quy tuyến tính thuộc nhóm học có giám sát. Hồi quy tuyến tính là một phương pháp đơn giản nhưng đã được chứng minh được tính hữu ích cho một số lượng lớn các tình huống. Và một ứng dụng tiêu biểu nhất của hồi quy tuyến tính đó là dự báo giá nhà đất.

Để có thể hoàn thành đồ án này, em xin được gửi lời cảm ơn chân thành và sâu sắc đến thầy TS. Lê Đình Nam, thầy đã tận tình giảng dạy và hướng dẫn em trong suốt quá trình học tập và hoàn thành đồ án.

1

HỌC MÁY NÓI CHUNG

1.1. Học máy là gì?

- Những năm gần đây, trí tuệ nhân tạo, và cụ thể hơn là học máy ngày càng trở nên phổ biến trong công nghiệp. Thực tế, chúng ta đã bắt gặp nhất nhiều ứng dụng của trí tuệ mà có thể chúng ta không nhận ra như: hệ thống tự gắn thẻ khuôn mặt trong ảnh của mạng xã hội hàng đầu hiện nay như Facebook, hệ thống gợi ý phim dịch vụ phát trực tuyến theo đăng ký của Netflix, máy chơi cờ vây AlphaGo,...
- Vậy học máy là gì? Học máy là một nhánh của trí tuệ nhân tạo và khoa học máy tính, tập trung vào việc sử dụng dữ liệu và thuật toán để bắt chước cách con người học, cải thiện độ chính xác của chúng theo thời gian mà không cần lập trình trước.
- Học máy tập trung vào mục tiêu ngắn hạn như: làm cho máy tính có những khả năng nhận thức cơ bản như con người (nhìn, nghe hiểu được ngôn ngữ, giải toán, lập trình,...) và hỗ trợ con người xử lý lượng thông tin khổng lồ.

1.2. Học máy trong thực tế

1.2.1. Phân tích văn bản

Phân tích văn bản là công việc trích xuất hoặc phân loại thông tin từ văn bản. Các văn bản ở đây có thể là các các trạng thái trên mạng xã hội, các đoạn tin nhắn, tài liệu,... có thể kể đến một số ví dụ như: lọc thư rác, phân tích ngữ nghĩa, khai thác và xử lý thông tin,...

1.2.2. Xử lý ảnh

Bài toán xử lý ảnh giải quyết các vấn đề phân tích thông tin từ hình ảnh hay thực hiện một số phép biến đổi. Một số ví dụ là: gắn thẻ hình ảnh thông qua nhận diện khuôn mặt, nhận dạng ký tự,...

1.2.3. Khai phá dữ liệu

Khai phá dữ liệu là quá trình khám phá ra các thông tin có giá trị hoặc đưa ra các dự đoán từ tập dữ liệu khổng lồ. Một số ứng dụng như:

- Phát hiện bất thường, ví dụ như phát hiện gian lận thẻ tín dụng.
- Phát hiện các quy luật, ví dụ, trong một trang thương mại điện tử. Bạn có thể khám phá ra khách hàng thường mua các món hàng nào. Thông tin này cực hữu ích trong việc tiếp thị sản phẩm.
- Dự đoán, các cột giá trị (của một bản ghi mới trong tập dữ liệu). Ví dụ, bạn có thể dự đoán giá của căn hộ dựa trên các dữ liệu về giá các căn hộ bạn đã có. Và vấn đề này sẽ được trình bày trong đồ án này.

1.2.4. Trò chơi điện tử và robot

- Trò chơi điện tử và robot (một loại máy có thể thực hiện những công việc một cách tự động bằng sự điều khiển của máy tính) là lĩnh vực lớn có sự góp mặt của học máy. Nếu ta có một nhân vật cần di chuyển và tránh các chướng ngại vật trong game (trò chơi), học máy có thể học và giải quyết công việc này thay bạn.

1.3. Phân loại các thuật toán của học máy

1.3.1. Học máy có giám sát

Thuật toán học máy cần học cách để chuyển đổi mỗi input (đầu vào dữ liệu) thành kết quả đầu ra tương ứng. Do vậy, mọi mẫu dữ liệu trong tập dữ liệu gốc cần phải biết trước kết quả của nó. Học máy có giám sát gồm hai thuật toán chính:

1. Phân loại
2. Hồi quy

Và trong đồ án này, em sẽ tập trung vào việc phân tích thuật toán hồi quy.

1.3.2. Học máy không giám sát

Học không giám sát cũng là một nhánh trong học máy. Các mẫu dữ liệu trong học không giám sát chỉ cần input mà không cần kết quả đầu ra ở dữ liệu. Nó được sử dụng nhiều trong việc khám phá cấu trúc và mối quan hệ của dữ liệu. Một thuật toán điển hình là bài toán phân cụm. Nó học cách để tìm các mẫu dữ liệu tương tự nhau và nhóm vào thành các cụm.

2

HỒI QUY TUYẾN TÍNH

Ở chương này, tất cả các công thức, định lý và hệ quả, em tham khảo ở sách "Applied Multivariate Statistical Analysis" từ trang 149-209, của tác giả Richard Johnson và Dean Wichern. Chỉ có một số định nghĩa em sử dụng trong sách "Introduction to statistical learning" từ trang 59-121 của tác giả Gareth James, Daniela Witten, Trevor Hastie Robert và Tibshiran.

2.1. Giới thiệu

2.1.1. Giới thiệu về phương pháp

Phân tích hồi quy là một kỹ thuật thống kê để điều tra và mô hình hóa mối quan hệ giữa các biến. Các ứng dụng của hồi quy rất nhiều và xảy ra trong hầu hết các lĩnh vực như: kỹ thuật, khoa học, vật lý, hóa học, kinh tế, quản lý, khoa học đời sống, sinh học, khoa học xã hội. Trên thực tế, phân tích hồi quy có thể là kỹ thuật thống kê được sử dụng rộng rãi nhất. Ví dụ: dự đoán giá nhà, tiền lương, nhận dạng ảnh,... Và ở trong đồ án này, em xin phép trình bày ứng dụng của hồi quy tuyến tính để dự đoán giá nhà đất.

2.1.2. Sự cần thiết của phương pháp

- Mô hình hồi quy tuyến tính cho phép đánh giá tác động riêng phần của một biến độc lập lên biến phụ thuộc khi biến độc lập khác trong mô hình không đổi.
- Ngoài ra, việc đưa thêm các biến độc lập thích hợp vào mô hình đồng nghĩa với việc sử dụng thêm thông tin trong việc giải thích sự thay đổi của biến phụ thuộc, do đó cải thiện chất lượng dự báo của mô hình.

2.1.3. Tính tuyến tính trong mô hình

Tính tuyến tính của hàm hồi quy được hiểu là tuyến tính theo tham số, có nghĩa là tuyến tính ở các hệ số hồi quy và nó có thể tuyến tính hoặc phi tuyến ở các biến Z và Y .

Ví dụ: Mô hình hồi quy sau đây:

$$1. Y = \beta_1 + \beta_2 Z + \varepsilon$$

$$2. \log(Y) = \beta_1 + \beta_2 \log(Z) + \varepsilon$$

2.2. Mô hình hồi quy tuyến tính cổ điển

Mở đầu về chương hồi quy tuyến tính bội (hay còn được gọi là mô hình hồi quy tuyến tính nhiều biến), ta xét mô hình hồi quy tuyến tính cổ điển. Giả sử $Z_1, Z_2, \dots, Z_r$ là r biến độc lập dùng để dự báo và Y là biến phụ thuộc cần dự báo. Mô hình hồi quy tuyến tính cổ điển khẳng định rằng Y phụ thuộc tuyến tính vào các yếu tố chính Z_i theo như phương trình:

$$Y = \beta_0 + \beta_1 Z_1 + \dots + \beta_r Z_r + \varepsilon \quad (2.1)$$

Trong đó β_i với $i = \overline{0, r}$ là các hệ số hồi quy chưa biết, ε là sai số ngẫu nhiên.

Tiến hành n quan sát độc lập đồng thời về $r + 1$ biến $Z_1, Z_2, \dots, Z_r, Y$. Mô hình hoàn chỉnh trở thành:

$$\begin{aligned} y_1 &= \beta_0 + \beta_1 z_{11} + \dots + \beta_r z_{1r} + \varepsilon_1 \\ y_2 &= \beta_0 + \beta_1 z_{21} + \dots + \beta_r z_{2r} + \varepsilon_2 \\ &\vdots \\ y_n &= \beta_0 + \beta_1 z_{n1} + \dots + \beta_r z_{nr} + \varepsilon_n \end{aligned} \quad (2.2)$$

Trong đó:

- β_i là các hệ số hồi quy
- y_i là các biến phụ thuộc
- Z_i là các biến giải thích (các yếu tố chính)
- ε là phần nhiễu - sai số

Các sai số $\varepsilon_1, \varepsilon_2, \dots, \varepsilon_n$ thỏa mãn 3 điều kiện:

1. $E(\varepsilon_j) = 0$
2. $\text{Var}(\varepsilon_j) = \sigma^2$ (hằng số không đổi)
3. $\text{Cov}(\varepsilon_i, \varepsilon_j) = 0, \forall i \neq j$ (các sai số ε là không tương quan với nhau)

Mô hình trên có thể được viết dưới dạng ma trận như sau:

$$\begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix} = \begin{bmatrix} 1 & z_{11} & z_{12} & \cdots & z_{1r} \\ 1 & z_{21} & z_{22} & \cdots & z_{2r} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & z_{n1} & z_{n2} & \cdots & z_{nr} \end{bmatrix} \begin{bmatrix} \beta_0 \\ \beta_1 \\ \vdots \\ \beta_r \end{bmatrix} + \begin{bmatrix} \varepsilon_1 \\ \varepsilon_2 \\ \vdots \\ \varepsilon_n \end{bmatrix}$$

Hoặc viết dưới dạng tổng quát:

$$\underbrace{\mathbf{Y}}_{n \times 1} = \underbrace{\mathbf{Z}}_{n \times (r+1)} \cdot \underbrace{\boldsymbol{\beta}}_{(r+1) \times 1} + \underbrace{\boldsymbol{\varepsilon}}_{n \times 1} \quad (2.3)$$

Với ma trận $\mathbf{Z}$ được gọi là ma trận thiết kế:

$$\mathbf{Z} = \begin{bmatrix} 1 & z_{11} & z_{12} & \cdots & z_{1r} \\ 1 & z_{21} & z_{22} & \cdots & z_{2r} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & z_{n1} & z_{n2} & \cdots & z_{nr} \end{bmatrix}$$

Và

$$\mathbf{Y} = [y_1, y_2, \dots, y_n]^T, \boldsymbol{\beta} = [\beta_0, \beta_1, \dots, \beta_r]^T, \boldsymbol{\varepsilon} = [\varepsilon_1, \varepsilon_2, \dots, \varepsilon_n]^T$$

$$E(\boldsymbol{\varepsilon}) = \underbrace{\mathbf{0}}_{n \times 1} \text{ và } \text{Cov}(\boldsymbol{\varepsilon}) = \underbrace{\sigma^2 \mathbf{I}}_{n \times n}$$

Ở đây: Ma trận $\boldsymbol{\beta}$ và σ^2 là chưa biết và nhiệm vụ là cần đi tìm $\boldsymbol{\beta}$ và σ^2 .

Bài toán đặt ra là, cho trước bộ dữ liệu $\mathbf{Y}$ và $\mathbf{Z}$, làm sao để ta tìm được vector hệ số $\boldsymbol{\beta}$ khớp với bộ dữ liệu nhất? Và sau khi tìm được vector hệ số $\boldsymbol{\beta}$ thì ta sẽ phải đưa ra dự đoán cho những quan sát mới như thế nào? Đó sẽ là nội dung các phần sau em trình bày.

2.3. Phương pháp bình phương tối thiểu

Mục tiêu của việc phân tích hồi quy tuyến tính đó là đưa ra một công thức để biểu diễn quan hệ tuyến tính giữa biến phản hồi với các biến dự đoán cho trước. Để làm được điều này thì ta sẽ phải ước lượng được các hệ số β_i ở công thức (2.1) và tìm được phương sai σ^2 của sai số từ bộ dữ liệu đã có. Giả sử $\mathbf{b} = [b_1 \ b_2 \ \cdots \ b_r]^T$ là một giá

trị thử nghiệm của β và ta đang phải kiểm tra xem giá trị này có thực sự là giá trị β hay không.

Bài toán đặt ra là hãy dựa trên ma trận $\mathbf{Z}$ và vecto $\mathbf{Y}$ của các giá trị quan sát được hãy ước lượng tham số β và σ^2 .

Xét sai số:

$$e_i = y_i - b_0 - b_1 z_{i1} - \dots - b_r z_{ir}$$

Trong thực tế thì sai số này không bao giờ nhận giá trị 0 do các yếu tố ngẫu nhiên từ các phép đo đạc và lấy dữ liệu. Nhưng ta có thể cực tiểu hóa sai số này bằng cách chọn ra giá trị thử nghiệm b hợp lý. Xét giá trị tổng bình phương sai số:

$$\text{RSS}(b) = \sum_{i=1}^n (y_i - b_0 - b_1 z_{i1} - \dots - b_r z_{ir})^2 = (\mathbf{Y} - \mathbf{Z}b)^T (\mathbf{Y} - \mathbf{Z}b) \rightarrow \min$$

Giá trị thử nghiệm b để cực tiểu hóa $\text{RSS}(b)$ được gọi là ước lượng bình phương cực tiểu của hệ số hồi quy β , để thống nhất với các mô hình thống kê thì ta ký hiệu ước lượng này là $\hat{\beta}$. Khi đó

$$\hat{\beta} = \text{argmin}(\mathbf{Y} - \mathbf{Z}\beta)^T (\mathbf{Y} - \mathbf{Z}\beta) \quad (2.4)$$

Vector $\hat{\varepsilon} = \mathbf{Y} - \mathbf{Z}\hat{\beta}$ được gọi là sai số ước lượng (hay một số tài liệu gọi là thặng dư) của mô hình hồi quy tuyến tính. Nó sẽ chứa thông tin về giá trị σ^2 chưa biết mà em sẽ đề cập ở các mục sau.

2.3.1. Tiếp cận $\hat{\beta}$ bằng các biến đổi đại số

Ta sẽ tìm $\hat{\beta}$ là nghiệm tối ưu của (2.4). Xét hàm vector:

$$\beta = (\mathbf{Y} - \mathbf{Z}\beta)^T (\mathbf{Y} - \mathbf{Z}\beta)$$

Giá trị β cực tiểu hóa hàm $\text{RSS}(\beta)$ là nghiệm của phương trình đạo hàm bằng 0. Ta có:

$$\frac{\partial}{\partial \beta} \text{RSS}(\beta) = \frac{\partial}{\partial \beta} (\mathbf{Z}\beta - \mathbf{Y})^T (\mathbf{Z}\beta - \mathbf{Y}) = 2\mathbf{Z}^T (\mathbf{Z}\beta - \mathbf{Y})$$

Do $\mathbf{Z}^T$ không là ma trận không nên $(\partial/\partial \beta) \text{RSS}(b) = 0$ khi và chỉ khi $\mathbf{Z}^T \mathbf{Z}\beta - \mathbf{Z}^T \mathbf{Y} = 0$ hay

$$\hat{\beta} = (\mathbf{Z}^T \mathbf{Z})^{-1} \mathbf{Z}^T \mathbf{Y} \quad (2.5)$$

2.3.2. Tiếp cận $\hat{\beta}$ bằng hình học

Cũng như phần trước, ta vẫn sẽ tìm $\hat{\beta}$ là nghiệm tối ưu của (2.4). Nhưng ở lần này ta sẽ có một cái nhìn trực quan hơn bằng cách sử dụng công cụ hình học. Do ta

đang tìm ước lượng bình phương cực tiểu nên việc chọn chuẩn Euclide $\|\cdot\|_2$ để biểu diễn sẽ rất phù hợp. Đặt $\varepsilon = \mathbf{Y} - \mathbf{Z}\beta$, khi đó:

$$\hat{\beta} = \operatorname{argmin}(\mathbf{Y} - \mathbf{Z}\beta)^T(\mathbf{Y} - \mathbf{Z}\beta) = \operatorname{argmin}\|\mathbf{Y} - \mathbf{Z}\beta\|_2^2 = \operatorname{argmin}\|\varepsilon\|_2^2$$

Hay nói cách khác, $\hat{\beta}$ chính là vector để cực tiểu hóa độ dài của vector sai số ε . Ta sẽ đặt:

$$\hat{\mathbf{Y}} = \mathbf{Z}\hat{\beta}, \quad \hat{\varepsilon} = \mathbf{Y} - \mathbf{Z}\hat{\beta}, \quad (\mathbf{P}) = \operatorname{span}\{\operatorname{col}_r(\mathbf{Z})\}_{r=1}^{r+1}$$

ở đây $\hat{\mathbf{Y}}$ sẽ chính là ước lượng bình phương cực tiểu của $\mathbf{Y}$. Hơn nữa, tổng bình phương sai số khi $\beta = \hat{\beta}$ sẽ đạt giá trị nhỏ nhất, hay $\|\varepsilon\|_2^2_{\min} = \|\hat{\varepsilon}\|_2^2$. Khi đó ta phải có $\hat{\varepsilon}$ vuông góc với $(\mathbf{P})$ (dựa vào tính chất đường vuông góc sẽ có độ dài nhỏ hơn đường xiên). Nhận thấy rằng vector $\mathbf{Y}$ cố định, còn vector $\hat{\mathbf{Y}}$ thì do nó chính là tổ hợp tuyến tính của các cột của ma trận $\mathbf{Z}$ nên nó sẽ là một vector nằm trên siêu phẳng $(\mathbf{P})$. Ta có thể suy ra được $\hat{\mathbf{Y}}$ là hình chiếu của $\mathbf{Y}$ lên siêu phẳng $(\mathbf{P})$. Vấn đề đặt ra là làm thế nào để tìm được hình chiếu này? Không khó để nhận ra rằng $\hat{\varepsilon}$ vuông góc với $(\mathbf{P})$ nên sẽ vuông góc với $\operatorname{col}_k(\mathbf{Z})$ với mọi $k = \overline{1, r+1}$. Hay nói cách khác, $\mathbf{Z}^T \hat{\varepsilon} = 0$. Từ đó ta suy ra được

$$\hat{\beta} = (\mathbf{Z}^T \mathbf{Z})^{-1} \mathbf{Z}^T \mathbf{Y} \quad (2.6)$$

và từ đó ta tìm được $\hat{\mathbf{Y}} = \mathbf{Z}(\mathbf{Z}^T \mathbf{Z})^{-1} \mathbf{Z}^T \mathbf{Y}$.

Như vậy, cách tiếp cận mới này vẫn cho ra cùng một kết quả, nhưng cách nhìn nhận vấn đề có phần trực quan hơn và cho ta một số các kết quả thú vị mà ở cách biến đổi đại số ta chưa nhìn ra được ngay, chẳng hạn $\mathbf{Z}^T \hat{\varepsilon} = 0$.

2.3.3. Ước lượng bình phương cực tiểu của hệ số hồi quy

Vừa rồi ta đã đi qua hai cách tiếp cận để thiết lập được công thức ước lượng bình phương cực tiểu $\hat{\beta} = (\mathbf{Z}^T \mathbf{Z})^{-1} \mathbf{Z}^T \mathbf{Y}$ của β . Bây giờ ta sẽ đi chứng minh tính đúng đắn của công thức và cũng như đưa ra một số mở rộng để khắc phục các hạn chế mà công thức này còn tồn đọng.

Trước hết ta có định lý đầu tiên:

Định lý 2.1

Xét mô hình hồi quy tuyến tính $\mathbf{Y} = \mathbf{Z}\beta + \varepsilon$ với $E(\varepsilon) = 0$, $\operatorname{Cov}(\varepsilon \varepsilon^T) = \sigma^2 \mathbf{I}$ và ma trận $\mathbf{Z}$ có hạng đầy đủ ($\operatorname{rank} \mathbf{Z} = r + 1$). Khi đó ước lượng bình phương cực tiểu của β là

$$\hat{\beta} = (\mathbf{Z}^T \mathbf{Z})^{-1} \mathbf{Z}^T \mathbf{Y}$$

Chứng minh:

Đặt $\mathbf{H} = \mathbf{Z}(\mathbf{Z}^T \mathbf{Z})^{-1} \mathbf{Z}^T$. Khi đó $\mathbf{I} - \mathbf{H}$ là ma trận đối xứng lũy đẳng. Thật vậy

1. Tính đối xứng

$$(\mathbf{I} - \mathbf{H})^T = (\mathbf{I} - \mathbf{Z}(\mathbf{Z}^T \mathbf{Z})^{-1} \mathbf{Z}^T)^T = (\mathbf{I} - \mathbf{Z}(\mathbf{Z}^T \mathbf{Z})^{-1} \mathbf{Z}^T) = \mathbf{I} - \mathbf{H}$$

2. Tính lũy đẳng

$$\begin{aligned} (\mathbf{I} - \mathbf{H})(\mathbf{I} - \mathbf{H}) &= \mathbf{I} - 2\mathbf{H} + \mathbf{H}^2 \\ &= \mathbf{I} - 2\mathbf{H} + \mathbf{Z}(\mathbf{Z}^T \mathbf{Z})^{-1} \mathbf{Z}^T \mathbf{Z}(\mathbf{Z}^T \mathbf{Z})^{-1} \mathbf{Z}^T \\ &= \mathbf{I} - 2\mathbf{H} + \mathbf{Z}(\mathbf{Z}^T \mathbf{Z})^{-1} \mathbf{Z}^T \\ &= \mathbf{I} - \mathbf{H} \end{aligned} \quad (2.7)$$

Hơn nữa, ta cũng có

$$\mathbf{Z}^T (\mathbf{I} - \mathbf{H}) = \mathbf{Z}^T (\mathbf{I} - \mathbf{Z}(\mathbf{Z}^T \mathbf{Z})^{-1} \mathbf{Z}^T) = \mathbf{Z}^T - \mathbf{Z}^T \mathbf{Z}(\mathbf{Z}^T \mathbf{Z})^{-1} \mathbf{Z}^T = \mathbf{Z}^T - \mathbf{Z}^T = 0 \quad (2.8)$$

Ta suy ra được $\mathbf{Z}^T \hat{\boldsymbol{\varepsilon}} = 0$, hay $(\mathbf{Y} - \mathbf{Z}\hat{\boldsymbol{\beta}})^T \mathbf{Z} = 0$.

Để kiểm tra tính đúng đắn của công thức ước lượng bình phương cực tiểu đã đề ra, ta biến đổi

$$\begin{aligned} \text{RSS}(\boldsymbol{\beta}) &= (\mathbf{Y} - \mathbf{Z}\boldsymbol{\beta})^T (\mathbf{Y} - \mathbf{Z}\boldsymbol{\beta}) \\ &= (\mathbf{Y} - \mathbf{Z}\hat{\boldsymbol{\beta}})^T (\mathbf{Y} - \mathbf{Z}\hat{\boldsymbol{\beta}}) + 2(\mathbf{Y} - \mathbf{Z}\hat{\boldsymbol{\beta}})^T \mathbf{Z}(\hat{\boldsymbol{\beta}} - \boldsymbol{\beta}) + (\hat{\boldsymbol{\beta}} - \boldsymbol{\beta})^T \mathbf{Z}^T \mathbf{Z}(\hat{\boldsymbol{\beta}} - \boldsymbol{\beta}) \\ &= (\mathbf{Y} - \mathbf{Z}\hat{\boldsymbol{\beta}})^T (\mathbf{Y} - \mathbf{Z}\hat{\boldsymbol{\beta}}) + (\hat{\boldsymbol{\beta}} - \boldsymbol{\beta})^T \mathbf{Z}^T \mathbf{Z}(\hat{\boldsymbol{\beta}} - \boldsymbol{\beta}) \end{aligned}$$

Nhận thấy rằng $\text{RSS}(\boldsymbol{\beta})$ nhỏ nhất khi và chỉ khi số hạng $(\hat{\boldsymbol{\beta}} - \boldsymbol{\beta})^T \mathbf{Z}^T \mathbf{Z}(\hat{\boldsymbol{\beta}} - \boldsymbol{\beta})$ đạt giá trị nhỏ nhất. Lại có

$$(\hat{\boldsymbol{\beta}} - \boldsymbol{\beta})^T \mathbf{Z}^T \mathbf{Z}(\hat{\boldsymbol{\beta}} - \boldsymbol{\beta}) = (\mathbf{Z}(\hat{\boldsymbol{\beta}} - \boldsymbol{\beta}))^T \mathbf{Z}(\hat{\boldsymbol{\beta}} - \boldsymbol{\beta}) \geq 0$$

và ma trận $\mathbf{Z}$ đầy hạng nên $(\hat{\boldsymbol{\beta}} - \boldsymbol{\beta})^T \mathbf{Z}^T \mathbf{Z}(\hat{\boldsymbol{\beta}} - \boldsymbol{\beta})$ đạt giá trị nhỏ nhất là 0 khi và chỉ khi $\mathbf{Z}(\hat{\boldsymbol{\beta}} - \boldsymbol{\beta}) = 0$, hay $\hat{\boldsymbol{\beta}} = \boldsymbol{\beta}$.

2.3.4. Tính chất của ước lượng bình phương cực tiểu

Định lý 2.2

Ước lượng $\hat{\beta} = (\mathbf{Z}^T \mathbf{Z})^{-1} \mathbf{Z}^T \mathbf{Y}$ của mô hình hồi quy tuyến tính cổ điển thỏa mãn

$$E(\hat{\beta}) = \beta \quad \text{và} \quad \text{Cov}(\hat{\beta}) = \sigma^2 (\mathbf{Z}^T \mathbf{Z})^{-1}$$

Kèm theo đó, sai số $\hat{\varepsilon} = \mathbf{Y} - \mathbf{Z}\hat{\beta}$ thỏa mãn

$$E(\hat{\varepsilon}) = 0 \quad \text{và} \quad \text{Cov}(\hat{\varepsilon}) = \sigma^2 (\mathbf{I} - \mathbf{H})$$

Hơn nữa, $\text{Cov}(\hat{\beta}, \hat{\varepsilon}) = 0$

Chứng minh:

Trước khi biến phản hồi $\mathbf{Y} = \mathbf{Z}\beta + \varepsilon$ được quan sát thì nó được coi như một vector ngẫu nhiên. Sau khi có được các quan sát và công thức ước lượng bình phương cực tiểu của β thì ta có

$$\hat{\beta} = (\mathbf{Z}^T \mathbf{Z})^{-1} \mathbf{Z}^T \mathbf{Y} = (\mathbf{Z}^T \mathbf{Z})^{-1} \mathbf{Z}^T (\mathbf{Z}\hat{\beta} + \hat{\varepsilon}) = \hat{\beta} + (\mathbf{Z}^T \mathbf{Z})^{-1} \mathbf{Z}^T \hat{\varepsilon}$$

$$\hat{\varepsilon} = (\mathbf{I} - \mathbf{H})\mathbf{Y} = (\mathbf{I} - \mathbf{H})(\mathbf{Z}\beta + \varepsilon) = (\mathbf{I} - \mathbf{H})\varepsilon$$

Hơn nữa, ta còn có tính chất $\mathbf{Z}^T (\mathbf{I} - \mathbf{H}) = 0$ đã nói tới ở công thức

$$E(\hat{\beta}) = \beta + (\mathbf{Z}^T \mathbf{Z})^{-1} \mathbf{Z}^T E(\varepsilon) = \beta$$

$$\text{Cov}(\hat{\beta}) = (\mathbf{Z}^T \mathbf{Z})^{-1} \mathbf{Z}^T \text{Cov}(\varepsilon) \mathbf{Z} (\mathbf{Z}^T \mathbf{Z})^{-1} = \sigma^2 (\mathbf{Z}^T \mathbf{Z})^{-1} \mathbf{Z}^T \mathbf{Z} (\mathbf{Z}^T \mathbf{Z})^{-1} = \sigma^2 (\mathbf{Z}^T \mathbf{Z})^{-1}$$

$$E(\hat{\varepsilon}) = (\mathbf{I} - \mathbf{H})E(\varepsilon) = 0$$

$$\text{Cov}(\hat{\varepsilon}) = (\mathbf{I} - \mathbf{H})\text{Cov}(\varepsilon)(\mathbf{I} - \mathbf{H})^T = \sigma^2 (\mathbf{I} - \mathbf{H})$$

$$\text{Cov}(\hat{\beta}, \hat{\varepsilon}) = E((\hat{\beta} - \beta)\hat{\varepsilon}^T) = (\mathbf{Z}^T \mathbf{Z})^{-1} \mathbf{Z}^T E(\varepsilon \varepsilon^T) (\mathbf{I} - \mathbf{H}) = \sigma^2 (\mathbf{Z}^T \mathbf{Z})^{-1} \mathbf{Z}^T (\mathbf{I} - \mathbf{H}) = 0$$

2.3.5. Định lý Gauss về bình phương cực tiểu

Định lý 2.3

Xét mô hình hồi quy tuyến tính $\mathbf{Y} = \mathbf{Z}\beta + \varepsilon$ với $E(\varepsilon) = 0$, $\text{Cov}(\varepsilon \varepsilon^T) = \sigma^2 \mathbf{I}$ và ma trận $\mathbf{Z}$ có hạng đầy đủ. Với ước lượng bình phương cực tiểu $\hat{\beta} = (\mathbf{Z}^T \mathbf{Z})^{-1} \mathbf{Z}^T \mathbf{Y}$ của β thì $\mathbf{c}^T \hat{\beta}$ là ước lượng không chệch của $\mathbf{c}^T \beta$ và có phương sai nhỏ nhất so với bất kỳ ước lượng tuyến tính không chệch nào khác có dạng

$$\mathbf{a}^T \mathbf{Y} = a_1 y_1 + a_2 y_2 + \cdots + a_n y_n$$

Chứng minh:

Với vector $\mathbf{c}$ cố định, đặt $\mathbf{a}^T \mathbf{Y}$ là một ước lượng không chệch của $\mathbf{c}^T \beta$. Khi đó với mọi giá trị β thì

$$E(\mathbf{a}^T \mathbf{Y}) = \mathbf{c}^T \beta \quad (2.9)$$

Mặt khác

$$E(\mathbf{a}^T \mathbf{Y}) = E(\mathbf{a}^T \mathbf{Z} \beta + \mathbf{a}^T \varepsilon) = \mathbf{a}^T \mathbf{Z} \beta \quad (2.10)$$

Từ các công thức (2.9) và (2.10), ta được $\mathbf{a}^T \mathbf{Z} \beta = \mathbf{c}^T \beta$, hay viết lại thành $(\mathbf{c}^T - \mathbf{a}^T \mathbf{Z}) \beta = 0$ với mọi β (kể cả giá trị $\beta = (\mathbf{c}^T - \mathbf{a}^T \mathbf{Z})^T$). Điều này có nghĩa là $\mathbf{c}^T = \mathbf{a}^T \mathbf{Z}$ với mọi ước lượng không chệch $\mathbf{a}^T \mathbf{Y}$. Đặt $\mathbf{u} = \mathbf{Z}(\mathbf{Z}^T \mathbf{Z})^{-1} \mathbf{c}$. Khi đó

$$\mathbf{c}^T \hat{\beta} = \mathbf{c}^T (\mathbf{Z}^T \mathbf{Z})^{-1} \mathbf{Z}^T \mathbf{Y} = \mathbf{u}^T \mathbf{Y}$$

Theo **Định lý 2.2** thì ta có $E(\hat{\beta}) = \beta$, do đó $\mathbf{c}^T \hat{\beta} = \mathbf{u}^T \mathbf{Y}$ là một ước lượng không chệch của $\mathbf{c}^T \beta$. Như vậy với mọi vector $\mathbf{a}$ thỏa mãn điều kiện không chệch $\mathbf{c}^T = \mathbf{a}^T \mathbf{Z}$ thì

$$\begin{aligned} \text{Var}(\mathbf{a}^T \mathbf{Y}) &= \text{Var}(\mathbf{a}^T \mathbf{Z} \beta + \mathbf{a}^T \varepsilon) \\ &= \text{Var}(\mathbf{a}^T \varepsilon) \\ &= \sigma^2 \mathbf{a}^T \mathbf{a} \\ &= \sigma^2 (\mathbf{a} + \mathbf{u})(\mathbf{a} - \mathbf{u} + \mathbf{u}) \\ &= \sigma^2 ((\mathbf{a} - \mathbf{u})^T (\mathbf{a} - \mathbf{u}) + \mathbf{u}^T \mathbf{u}) \end{aligned}$$

Do $\mathbf{u}$ cố định nên $(\mathbf{a} - \mathbf{u})^T (\mathbf{a} - \mathbf{u}) \geq 0$ với mọi $\mathbf{a}$. Khi đó $\text{Var}(\mathbf{a}^T \mathbf{Y})$ cực tiểu hóa khi $\mathbf{a} = \mathbf{u}$, hay nói cách khác, ước lượng không chệch có phương sai nhỏ nhất là

$$\mathbf{u}^T \mathbf{Y} = \mathbf{c}^T (\mathbf{Z}^T \mathbf{Z})^{-1} \mathbf{Z}^T \mathbf{Y} = \mathbf{c}^T \hat{\beta}$$

2.3.6. Hệ số xác định R

Ta đã chỉ ra được rằng $\mathbf{Z}^T \hat{\varepsilon} = 0$. Khi đó $\hat{\mathbf{Y}}^T \hat{\varepsilon} = \hat{\beta}^T \mathbf{Z}^T \hat{\varepsilon} = 0$. Ta có biến đổi sau

$$\mathbf{Y}^T \mathbf{Y} = (\hat{\mathbf{Y}} + \hat{\varepsilon})^T (\hat{\mathbf{Y}} + \hat{\varepsilon}) = \hat{\mathbf{Y}}^T \hat{\mathbf{Y}} + \hat{\mathbf{Y}}^T \hat{\varepsilon} + \hat{\varepsilon}^T \hat{\mathbf{Y}} + \hat{\varepsilon}^T \hat{\varepsilon} = \hat{\mathbf{Y}}^T \hat{\mathbf{Y}} + \hat{\varepsilon}^T \hat{\varepsilon} \quad (2.11)$$

Đặt $\bar{y} = \sum_{r=1}^n y_r / n$ và $\bar{\hat{y}} = \sum_{r=1}^n \hat{y}_r / n$. Cũng từ tính chất $\mathbf{Z}^T \hat{\varepsilon} = 0$, ta được $\mathbf{1}^T \hat{\varepsilon} = 0$ do cột đầu tiên của ma trận $\mathbf{Z}$ gồm toàn số 1. Khi đó

$$0 = \mathbf{1}^T \hat{\varepsilon} = \sum_{r=1}^n \hat{\varepsilon}_r = \sum_{r=1}^n y_r - \sum_{r=1}^n \hat{y}_r$$

hay $\bar{y} = \bar{\hat{y}}$. Trừ hai vế của đẳng thức (2.11) cho $n\bar{y}^2 = n\bar{\hat{y}}^2$, ta được

$$\mathbf{Y}^T \mathbf{Y} - n\bar{y}^2 = \hat{\mathbf{Y}}^T \hat{\mathbf{Y}} - n\bar{\hat{y}}^2 + \hat{\varepsilon}^T \hat{\varepsilon}$$

hay viết lại thành

$$\sum_{r=1}^n (y_r - \bar{y})^2 = \sum_{r=1}^n (\hat{y}_r - \bar{y})^2 + \sum_{r=1}^n \hat{\varepsilon}_r^2$$

Ta định nghĩa

$$R^2 = \frac{\hat{\mathbf{Y}}^T \hat{\mathbf{Y}} - n\bar{y}^2}{\mathbf{Y}^T \mathbf{Y} - n\bar{y}^2} = \frac{\sum_{r=1}^n (\hat{y}_r - \bar{y})^2}{\sum_{r=1}^n (y_r - \bar{y})^2} = 1 - \frac{\sum_{r=1}^n \hat{\varepsilon}_r^2}{\sum_{r=1}^n (y_r - \bar{y})^2}$$

gọi là bình phương của hệ số xác định, đó là tỷ lệ biến thiên của các biến y_j được giải thích bởi các biến $z_{j1}, \dots, z_{jr}$.

Thay vì sử dụng hệ số xác định R^2 thì ta sẽ sử dụng hệ số xác định R^2 hiệu chỉnh, kí hiệu là $\bar{R}^2$ và được định nghĩa như sau

$$\bar{R}^2 = 1 - (1 - R^2) \frac{(n-1)}{n-r-1}$$

Giá trị $\bar{R}^2$ thường được sử dụng thay cho giá trị R^2 thông thường khi so sánh các mô hình hồi quy có số lượng biến số khác nhau.

2.4. Ước lượng khoảng của mô hình hồi quy

Trong mục này, chúng ta sẽ tìm hiểu về ước lượng khoảng của các hệ số hồi quy β_i . Bài toán được xét dựa trên mô hình hồi quy tuyến tính cổ điển đã được giới thiệu trong phần 3, với ma trận $\mathbf{Z}$ là ma trận đầy hạng và giả thiết thêm rằng các sai số ε_i độc lập và có cùng phân phối chuẩn $\mathcal{N}(0, \sigma^2)$. Tức là $\varepsilon = [\varepsilon_1 \ \varepsilon_2 \ \dots \ \varepsilon_n]^T$ có phân phối chuẩn $\mathcal{N}_n(0, \sigma^2 \mathbf{I})$.

2.4.1. Ước lượng khoảng tin cậy của các hệ số β

Sau khi đã có $\hat{\beta}$ là ước lượng của vector hệ số hồi quy như đã trình bày ở mục 3, bước tiếp theo là ta sẽ kiểm tra xem giá trị $\hat{\beta}$ này có gần với giá trị thực β hay không, và nếu gần thì sai số sẽ là bao nhiêu. Để làm được điều này thì ta phải xác định được hàm phân phối của các giá trị đó.

Trước hết, ta có định lý sau:

Định lý 2.4

Xét mô hình hồi quy tuyến tính cổ điển $\mathbf{Y} = \mathbf{Z}\boldsymbol{\beta} + \boldsymbol{\varepsilon}$ với ma trận $\mathbf{Z}$ đầy hạng và $\boldsymbol{\varepsilon} \sim \mathcal{N}_n(0, \sigma^2 \mathbf{I})$. Khi đó:

$$\begin{aligned}\hat{\boldsymbol{\beta}} &= (\mathbf{Z}^T \mathbf{Z})^{-1} \mathbf{Z}^T \mathbf{Y} \sim \mathcal{N}_{r+1}(\boldsymbol{\beta}, \sigma^2 (\mathbf{Z}^T \mathbf{Z})^{-1}) \\ n\sigma^2 &= \hat{\boldsymbol{\varepsilon}}^T \hat{\boldsymbol{\varepsilon}} \sim \sigma^2 \chi_{n-r-1}^2\end{aligned}$$

Hơn nữa, $\hat{\boldsymbol{\beta}}$ và $\hat{\boldsymbol{\varepsilon}}$ là hai biến độc lập

Chứng minh:

Với giả thiết $\mathbf{Y} = \mathbf{Z}\boldsymbol{\beta} + \boldsymbol{\varepsilon}$ và $\boldsymbol{\varepsilon} \sim \mathcal{N}_n(0, \sigma^2 \mathbf{I})$ ta được $\mathbf{Y} \sim \mathcal{N}_n(\mathbf{Z}\boldsymbol{\beta}, \sigma^2 \mathbf{I})$.

Mặt khác, $\hat{\boldsymbol{\beta}} = (\mathbf{Z}^T \mathbf{Z})^{-1} \mathbf{Z}^T \mathbf{Y}$ và $\hat{\boldsymbol{\varepsilon}} = (\mathbf{I} - \mathbf{H})\mathbf{Y}$ đều là các tổ hợp tuyến tính của $\mathbf{Y}$. Do đó, $\hat{\boldsymbol{\beta}} \sim \mathcal{N}_{r+1}(\boldsymbol{\beta}, \sigma^2 (\mathbf{Z}^T \mathbf{Z})^{-1})$ và $\hat{\boldsymbol{\varepsilon}} \sim \mathcal{N}_n(0, \sigma^2 (\mathbf{I} - \mathbf{H}))$. Kết hợp với tính chất $\text{Cov}(\hat{\boldsymbol{\beta}}, \hat{\boldsymbol{\varepsilon}}) = 0$ đã có ở **Định lý 2.2**, suy ra $\hat{\boldsymbol{\beta}}$ và $\hat{\boldsymbol{\varepsilon}}$ là hai biến độc lập.

Tiếp theo ta sẽ chứng minh $\hat{\boldsymbol{\varepsilon}}^T \hat{\boldsymbol{\varepsilon}} \sim \sigma^2 \chi_{n-r-1}^2$.

Gọi λ là giá trị riêng ứng với vector riêng $\mathbf{v}$ của $\mathbf{I} - \mathbf{H}$, hay $(\mathbf{I} - \mathbf{H})\mathbf{v} = \lambda \mathbf{v}$.

Khi đó

$$(\mathbf{I} - \mathbf{H})^2 \mathbf{v} = \lambda (\mathbf{I} - \mathbf{H}) \mathbf{v} = \lambda^2 \mathbf{v}$$

Trước đó ở công thức (2.7), ta đã chứng minh được rằng $\mathbf{I} - \mathbf{H}$ là ma trận lũy đẳng, hay $(\mathbf{I} - \mathbf{H})^2 \mathbf{v} = (\mathbf{I} - \mathbf{H}) \mathbf{v}$. Như vậy

$$\lambda^2 \mathbf{v} = \lambda \mathbf{v} \quad \text{hay} \quad \lambda \in \{0, 1\} \quad (2.12)$$

Mặt khác, $\text{tr}(\mathbf{I} - \mathbf{H}) = n - r - 1 = \lambda_1 + \lambda_2 + \dots + \lambda_n$ nên từ đó suy ra $\mathbf{I} - \mathbf{H}$ sẽ có $n - r - 1$ giá trị riêng bằng 1 và $r + 1$ giá trị riêng còn lại bằng 0.

Giả sử $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_{n-r-1}$ là $n - r - 1$ vector riêng tương ứng với các trị riêng $\lambda_1 = \lambda_2 = \dots = \lambda_{n-r-1} = 1$ của ma trận $\mathbf{I} - \mathbf{H}$. Khi đó ta có thể biểu diễn ma trận $\mathbf{I} - \mathbf{H}$ dưới dạng phân tách phổ

$$\mathbf{I} - \mathbf{H} = \mathbf{v}_1 \mathbf{v}_1^T + \mathbf{v}_2 \mathbf{v}_2^T + \dots + \mathbf{v}_{n-r-1} \mathbf{v}_{n-r-1}^T$$

Đặt

$$\mathbf{V} = \begin{bmatrix} \mathbf{v}_1 \\ \mathbf{v}_2 \\ \vdots \\ \mathbf{v}_{n-r-1} \end{bmatrix} = \begin{bmatrix} \mathbf{v}_1^T \\ \mathbf{v}_2^T \\ \vdots \\ \mathbf{v}_{n-r-1}^T \end{bmatrix} \boldsymbol{\varepsilon}$$

Khi đó, $\mathbf{V}$ sẽ có phân phối chuẩn với $E(\mathbf{V}) = 0$ và

$$\text{Cov}(\mathbf{V}_i, \mathbf{V}_j) = \mathbf{v}_i^T (\sigma^2 \mathbf{I}) \mathbf{v}_j^T = \begin{cases} \sigma^2 & \text{nếu } i = j \\ 0 & \text{nếu } i \neq j \end{cases}$$

Từ đây suy ra $\mathbf{V}_1, \mathbf{V}_2, \dots, \mathbf{V}_{n-r-1}$ độc lập, có cùng phân phối chuẩn $\mathcal{N}(0, \sigma^2)$ và

$$\widehat{\boldsymbol{\varepsilon}}^T \widehat{\boldsymbol{\varepsilon}} = \boldsymbol{\varepsilon}^T (\mathbf{I} - \mathbf{H}) \boldsymbol{\varepsilon} = \mathbf{V}^T \mathbf{V} = V_1^2 + V_2^2 + \dots + V_{n-r-1}^2 \sim \sigma^2 \chi_{n-r-1}^2$$

Vậy ta có điều phải chứng minh.

Để thuận tiện cho các nghiên cứu về sau của mô hình hồi quy, ta đặt

$$s^2 = \frac{\widehat{\boldsymbol{\varepsilon}}^T \widehat{\boldsymbol{\varepsilon}}}{n - r - 1}$$

giá trị này chính là ước lượng không chệch σ^2 .

Định lý 2.5

Xét mô hình hồi quy tuyến tính cổ điển $\mathbf{Y} = \mathbf{Z}\boldsymbol{\beta} + \boldsymbol{\varepsilon}$ với ma trận $\mathbf{Z}$ là đầy đủ hạng và $\boldsymbol{\varepsilon} \sim \mathcal{N}_n(0, \sigma^2 \mathbf{I})$. Khi đó miền tin cậy đồng thời mức $100(1 - \alpha)\%$ của $\boldsymbol{\beta}$ được xác định bởi ellipsoid:

$$(\boldsymbol{\beta} - \widehat{\boldsymbol{\beta}})^T \mathbf{Z}^T \mathbf{Z} (\boldsymbol{\beta} - \widehat{\boldsymbol{\beta}}) \leq (r + 1) s^2 F_{r+1, n-r-1}(\alpha)$$

Và hơn nữa, khoảng tin cậy đồng thời mức $100(1 - \alpha)\%$ của các hệ số hồi quy β_i ($i = \overline{0, r}$) được xác định bởi

$$\widehat{\beta}_i \pm \sqrt{(s^2 (\mathbf{Z}^T \mathbf{Z})^{-1})_{(i+1)(i+1)} (r + 1) F_{r+1, n-r-1}(\alpha)} \quad (2.13)$$

trong đó, $F_{r+1, n-r-1}(\alpha)$ là phân vị trên mức $100\alpha\%$ của phân phối Fisher với bậc tự do là $r + 1$ và $n - r - 1$.

Chứng minh

Xét ma trận căn bậc hai đối xứng $(\mathbf{Z}^T \mathbf{Z})^{1/2}$ và đặt $\mathbf{V} = (\mathbf{Z}^T \mathbf{Z})^{1/2} (\widehat{\boldsymbol{\beta}} - \boldsymbol{\beta})$

Khi đó, ta có $E(\mathbf{V}) = 0$ và

$$\begin{aligned} \text{Cov}(\mathbf{V}) &= (\mathbf{Z}^T \mathbf{Z})^{1/2} \text{Cov}(\widehat{\boldsymbol{\beta}}) (\mathbf{Z}^T \mathbf{Z})^{1/2} \\ &= \sigma^2 (\mathbf{Z}^T \mathbf{Z})^{1/2} (\mathbf{Z}^T \mathbf{Z})^{-1} (\mathbf{Z}^T \mathbf{Z})^{1/2} \\ &= \sigma^2 \mathbf{I}_{r+1} \end{aligned}$$

Vì $\mathbf{V}$ là tổ hợp tuyến tính của các $\widehat{\beta}_i$ nên $\mathbf{V}$ có phân phối chuẩn $\mathcal{N}_{r+1}(0, \sigma^2 \mathbf{I})$. Do đó,

$$\mathbf{V}^T \mathbf{V} = (\widehat{\boldsymbol{\beta}} - \boldsymbol{\beta})^T (\mathbf{Z}^T \mathbf{Z}) (\widehat{\boldsymbol{\beta}} - \boldsymbol{\beta}) \sim \sigma^2 \chi_{r+1}^2$$

Hơn nữa theo **Định lý 2.4**, ta có $(n - r - 1) s^2 = \widehat{\boldsymbol{\varepsilon}}^T \widehat{\boldsymbol{\varepsilon}} \sim \sigma^2 \chi_{n-r-1}^2$ và nó độc lập với $\widehat{\boldsymbol{\beta}}$ (hay nói khác là độc lập với $\mathbf{V}^T \mathbf{V}$). Khi đó,

$$F = \frac{\chi_{r+1}^2 / (r + 1)}{\chi_{n-r-1}^2 / (n - r - 1)} = \frac{\mathbf{V}^T \mathbf{V}}{s^2 (r + 1)} = \frac{(\widehat{\boldsymbol{\beta}} - \boldsymbol{\beta})^T (\mathbf{Z}^T \mathbf{Z}) (\widehat{\boldsymbol{\beta}} - \boldsymbol{\beta})}{s^2 (r + 1)} \sim F_{r+1, n-r-1}$$

Từ đó ta được

$$P(F < F_{r+1, n-r-1}(\alpha)) = 1 - \alpha$$

và miền tin cậy mức $100(1 - \alpha)\%$ của β được xác định bởi ellipsoid

$$(\beta - \hat{\beta})^T \mathbf{Z}^T \mathbf{Z} (\beta - \hat{\beta}) \leq (r+1)s^2 F_{r+1, n-r-1}(\alpha) \quad (2.14)$$

Với $i = \overline{0, r}$, từ bất đẳng thức trên ta được

$$(\beta_i - \hat{\beta}_i)^2 \leq (s^2 (\mathbf{Z}^T \mathbf{Z})^{-1})_{(i+1)(i+1)} (r+1) F_{r+1, n-r-1}(\alpha)$$

Từ đó suy ra khoảng tin cậy đồng thời mức $100(1 - \alpha)\%$ của các hệ số hồi quy β_i ($i = \overline{0, r}$) được xác định bởi

$$\hat{\beta}_i \pm \sqrt{(s^2 (\mathbf{Z}^T \mathbf{Z})^{-1})_{(i+1)(i+1)} (r+1) F_{r+1, n-r-1}(\alpha)}$$

Tuy nhiên trong thực tế, người ta sẽ không sử dụng khoảng (2.13) để làm ước lượng khoảng của các hệ số hồi quy β_i . Thay vào đó, người ta sẽ sử dụng khoảng

$$\hat{\beta}_i \pm t_{n-r-1} \left(\frac{\alpha}{2} \right) \sqrt{(s^2 (\mathbf{Z}^T \mathbf{Z})^{-1})_{(i+1)(i+1)}}$$

trong đó $t_{n-r-1} \left(\frac{\alpha}{2} \right)$ là phân vị trên mức $100\alpha\%$ của phân phối Student với bậc tự do là $n - r - 1$.

2.4.2. Kiểm định giả thuyết về các hệ số hồi quy

Xét mô hình hồi quy tuyến tính cổ điển

$$\mathbf{Y} = \beta_0 + \beta_1 \mathbf{Z}_1 + \beta_2 \mathbf{Z}_2 + \dots + \beta_r \mathbf{Z}_r + \varepsilon$$

Khi thiết lập mô hình, ta giả sử rằng mọi biến $Z_1, Z_2, \dots, Z_r$ đều tham gia vào phương trình hồi quy. Tuy nhiên, đối với bộ dữ liệu có quá nhiều biến dự đoán, ta chỉ cần trích ra một số biến có ảnh hưởng đáng kể đối với biến phản hồi, các biến còn lại có thể lược bỏ để tránh tình trạng mô hình bị quá khớp với bộ dữ liệu. Do đó, ta cần kiểm định các hệ số hồi quy để có được mô hình tốt nhất.

Ta đặt:

$$\beta = \begin{bmatrix} \beta_{(1)} \\ (q+1) \times 1 \\ \dots \\ \beta_{(2)} \\ (r-q) \times 1 \end{bmatrix}$$

Ta có bài toán kiểm định giả thuyết:

$$H_0 : \beta_{q+1} = \dots = \beta_r \quad (0 < q < r) \quad \text{hay} \quad H_0 : \beta_{(2)} = 0 \quad (2.15)$$

Xét mô hình hồi quy tuyến tính cổ điển

$$\begin{aligned} \mathbf{Y} = \mathbf{Z}\beta + \varepsilon &= \begin{bmatrix} \mathbf{Z}_1 & \vdots & \mathbf{Z}_{(2)} \\ n \times (q+1) & n \times (r-q) \end{bmatrix} \begin{bmatrix} \beta_{(1)} \\ \vdots \\ \beta_{(2)} \\ (q+1) \times 1 \\ (r-q) \times 1 \end{bmatrix} + \varepsilon \\ &= \mathbf{Z}_1\beta_{(1)} + \mathbf{Z}_{(2)}\beta_{(2)} + \varepsilon \end{aligned}$$

Xét mô hình hồi quy tuyến tính $\mathbf{Y} = \mathbf{Z}\beta + \varepsilon$ với ma trận β đầy hạng và $\varepsilon \sim \mathcal{N}_n(0, \sigma^2 \mathbf{I})$. Khi đó ta bác bỏ giả thuyết $H_0 : \beta_{(2)} = 0$ với mức ý nghĩa $100\alpha\%$ nếu:

$$\text{RSS}(\beta_1) - \text{RSS}(\beta) > s^2(r-q)F_{r-q, n-r-1}(\alpha) \quad (2.16)$$

Chứng minh

Hàm hợp lý tham số β và σ^2 là:

$$L(\beta, \sigma^2) = \frac{1}{(2\pi)^{n/2} \sigma^n} e^{\left(\frac{-(y - \mathbf{Z}\beta)^T (y - \mathbf{Z}\beta)}{2\sigma^2} \right)} \leq \frac{1}{(2\pi)^{n/2} \hat{\sigma}^n} e^{\left(\frac{-n}{2} \right)}$$

Max của $L(\beta, \sigma^2)$ xảy ra khi $\beta = \hat{\beta} = (\mathbf{Z}^T \mathbf{Z})^{-1} \mathbf{Z}^T \mathbf{Y}$

$$\text{và } \sigma^2 = \hat{\sigma}^{*2} = \frac{(y - \mathbf{Z}\hat{\beta})^T (y - \mathbf{Z}\hat{\beta})}{n}$$

Trong đó, $\hat{\sigma}^{*2}$ là ước lượng hợp lý cực đại của σ^2 .

Tương tự với $Y = \mathbf{Z}_1\beta_{(1)} + \varepsilon$ thì:

$$\max_{\beta_{(1)}, \sigma_1^2} L(\beta_{(1)}, \sigma_1^2) = \frac{1}{(2\pi)^{n/2} \hat{\sigma}_1^n} e^{\left(\frac{-n}{2} \right)}$$

$$\text{tại } \beta_{(1)} = \hat{\beta}_{(1)} = (\mathbf{Z}_{(1)}^T \mathbf{Z}_{(1)})^{-1} \mathbf{Z}_{(1)}^T \mathbf{Y} \text{ và } \sigma_1^2 = \hat{\sigma}_1^{*2} = \frac{(y - \mathbf{Z}_{(1)}\hat{\beta}_{(1)})^T (y - \mathbf{Z}_{(1)}\hat{\beta}_{(1)})}{n}$$

Ta bác bỏ giả thuyết $H_0 : \beta_{(2)} = 0$ nếu

$$\frac{\max L(\beta_{(1)}, \sigma_1^2)}{\max L(\beta, \sigma^2)} = \left(\frac{\hat{\sigma}_1^{*2}}{\hat{\sigma}^{*2}} \right)^{-n/2} = \left(1 + \frac{\hat{\sigma}_1^{*2} - \hat{\sigma}^{*2}}{\hat{\sigma}^{*2}} \right)^{-n/2}$$

là nhỏ, hay giá trị $\frac{\hat{\sigma}_1^{*2} - \hat{\sigma}^{*2}}{\hat{\sigma}^{*2}}$ đủ lớn

$$F = \frac{n(\hat{\sigma}_1^{*2} - \hat{\sigma}^{*2})/(r-q)}{n\hat{\sigma}^{*2}/(n-r-1)} = \frac{\text{RSS}(\beta_1) - \text{RSS}(\beta)}{(r-q)s^2}$$

$$F \sim F_{r-q, n-r-1} \Rightarrow P(F > F_{r-q, n-r-1}(\alpha)) = \alpha$$

Suy ra ta bác bỏ giả thuyết $H_0 : \beta_{(2)} = 0$ với mức ý nghĩa $100\alpha\%$ nếu:

$$RSS(\beta_1) - RSS(\beta) > s^2(r-q)F_{r-q, n-r-1}(\alpha)$$

Tổng quát hơn ta xét bài toán kiểm định giả thuyết (rank = r + 1) dạng:

$$H_0 : \begin{cases} c_{10}\beta_0 + c_{11}\beta_1 + \dots + c_{1r}\beta_r = a_1 \\ c_{20}\beta_0 + c_{21}\beta_1 + \dots + c_{2r}\beta_r = a_2 \\ \dots \\ c_{r-q,0}\beta_0 + c_{r-q,1}\beta_1 + \dots + c_{r-q,r}\beta_r = a_{r-q} \end{cases} \Leftrightarrow \mathbf{C}\beta = \mathbf{a} \quad (2.17)$$

trong đó $\mathbf{C} = [c_{ij}]_{r-q, r+1}; \mathbf{a} = [a_1, \dots, a_{r-q}]^T$

Với:

$$\mathbf{C} = \begin{bmatrix} 0 & 0 & \dots & 0 & \vdots & 1 & 0 & \dots & 0 \\ 0 & 0 & \dots & 0 & \vdots & 0 & 1 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots & \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & 0 & \vdots & 0 & 0 & \dots & 1 \end{bmatrix} = [0 : I_{r-q}]$$

Quy tắc kiểm định:

Bác bỏ giả thuyết $H_0 : \mathbf{C}\beta = 0$ nếu:

$$((\mathbf{C}\hat{\beta})^T (\mathbf{C}(\mathbf{Z}^T \mathbf{Z})^{-1} \mathbf{C}^T)^{-1} \mathbf{C}\hat{\beta}) / s^2 > (r-q)F_{r-q, n-r-1}(\alpha) \quad (2.18)$$

2.5. Ước lượng hàm hồi quy tuyến tính

Sau khi đã có được 1 mô hình hồi quy tuyến tính khá tốt, thì ta có thể sử dụng nó để ước lượng các dự đoán mới thông qua các quan sát mới.

2.5.1. Ước lượng hàm hồi quy tại $\mathbf{z}_0$

Giả sử Y_0 là giá trị phản hồi của mô hình hồi quy khi biến dự đoán là $\mathbf{z}_0 = [1 \ z_{01} \ z_{02} \ \dots \ z_{0r}]^T$. Khi đó

$$E(Y_0 | \mathbf{Z} = \mathbf{z}_0) = \beta_0 + \beta_1 z_{01} + \dots + \beta_r z_{0r} = \mathbf{z}_0^T \beta$$

Theo **Định lý 2.3**, ước lượng bình phương cực tiểu của $E(Y_0 | \mathbf{Z} = \mathbf{z}_0) = \mathbf{z}_0^T \beta$ là $\mathbf{z}_0^T \hat{\beta}$. Hơn nữa, nó còn là ước lượng hiệu quả của $E(Y_0 | \mathbf{z}_0)$, với phương sai nhỏ nhất là

$$\text{Var}(\mathbf{z}_0^T \hat{\beta}) = \mathbf{z}_0^T (\mathbf{Z}^T \mathbf{Z})^{-1} \mathbf{z}_0 \sigma^2$$

Định lý 2.6

Xét mô hình hồi quy tuyến tính cổ điển $\mathbf{Y} = \mathbf{Z}\beta + \varepsilon$ với ma trận $\mathbf{Z}$ đầy hạng và $\varepsilon \sim \mathcal{N}_n(0, \sigma^2 I)$. Khi đó khoảng tin cậy đồng thời mức $100(1 - \alpha)\%$ của $\mathbf{z}_0^T \beta$ là

$$\mathbf{z}_0^T \hat{\beta} \pm t_{n-r-1} \left(\frac{\alpha}{2} \right) \sqrt{\mathbf{z}_0^T (\mathbf{Z}^T \mathbf{Z})^{-1} \mathbf{z}_0 s^2}$$

Chứng minh

Cố định $\mathbf{z}_0$, lúc này $\mathbf{z}_0^T \beta$ là tổ hợp tuyến tính của các hệ số hồi quy β_i . Ta đã chỉ ra ở công thức trên rằng

$$\text{Var}(\mathbf{z}_0^T \hat{\beta}) = \mathbf{z}_0^T \text{Cov}(\hat{\beta}) \mathbf{z}_0 = \mathbf{z}_0^T (\mathbf{Z}^T \mathbf{Z})^{-1} \mathbf{z}_0 \sigma^2$$

Mặt khác, theo **Định lý 2.4**, ta có

$$\hat{\beta} \sim \mathcal{N}_{r+1}(\beta, \sigma^2 (\mathbf{Z}^T \mathbf{Z})^{-1}) \text{ và } \hat{\beta} \text{ độc lập với } s^2 / \sigma^2 \sim \chi_{n-r-1}^2 / (n-r-1)$$

Do đó, tổ hợp tuyến tính $\mathbf{z}_0^T \hat{\beta}$ có phân phối chuẩn $\mathcal{N}(\mathbf{z}_0^T \beta, \mathbf{z}_0^T (\mathbf{Z}^T \mathbf{Z})^{-1} \mathbf{z}_0 \sigma^2)$

Từ đó suy ra

$$\frac{(\mathbf{z}_0^T \hat{\beta} - \mathbf{z}_0^T \beta) / \sqrt{\mathbf{z}_0^T (\mathbf{Z}^T \mathbf{Z})^{-1} \mathbf{z}_0 \sigma^2}}{\sqrt{s^2 / \sigma^2}} = \frac{\mathbf{z}_0^T \hat{\beta} - \mathbf{z}_0^T \beta}{\sqrt{\mathbf{z}_0^T (\mathbf{Z}^T \mathbf{Z})^{-1} \mathbf{z}_0 s^2}} \sim t_{n-r-1}$$

Hay

$$P \left(\frac{|\mathbf{z}_0^T \hat{\beta} - \mathbf{z}_0^T \beta|}{\sqrt{s^2 \mathbf{z}_0^T (\mathbf{Z}^T \mathbf{Z})^{-1} \mathbf{z}_0}} < t_{n-r-1} \left(\frac{\alpha}{2} \right) \right) = 1 - \alpha$$

Do đó, khoảng tin cậy đồng thời mức $100(1 - \alpha)\%$ của $\mathbf{z}_0^T \beta$ là:

$$\mathbf{z}_0^T \hat{\beta} \pm t_{n-r-1} \left(\frac{\alpha}{2} \right) \sqrt{\mathbf{z}_0^T (\mathbf{Z}^T \mathbf{Z})^{-1} \mathbf{z}_0 s^2}$$

2.5.2. Dự đoán quan sát mới tại $\mathbf{z}_0$

Với $\mathbf{z}_0$ là vector cho trước, thay vào mô hình hồi quy tuyến tính ta được

$$Y_0 = \mathbf{z}_0^T \beta + \varepsilon_0$$

trong đó $\varepsilon_0 \sim \mathcal{N}(0, \sigma^2)$ và độc lập với các ε_i , do đó cũng độc lập với $\hat{\beta}$ và s^2 . Các sai số ε_i sẽ bị ảnh hưởng từ các ước lượng $\hat{\beta}$ và s^2 thông qua biến phản hồi Y , nhưng ε_0 thì không.

Ta có định lý sau:

Định lý 2.7

Xét mô hình hồi quy tuyến tính cổ điển $\mathbf{Y} = \mathbf{Z}\beta + \varepsilon$ với ma trận $\mathbf{Z}$ là đầy hạng và $\varepsilon \sim \mathcal{N}_n(0, \sigma^2 I)$. Một quan sát mới Y_0 sẽ có ước lượng không chệch

$$\mathbf{z}_0^T \hat{\beta} = \hat{\beta}_0 + \hat{\beta}_1 z_{01} + \cdots + \hat{\beta}_r z_{0r}$$

trong đó $\text{Var}(\hat{\varepsilon}_0) = \text{Var}(Y_0 - \mathbf{z}_0^T \hat{\beta}) = \sigma^2(1 + \mathbf{z}_0^T (\mathbf{Z}^T \mathbf{Z})^{-1} \mathbf{z}_0)$. Khi đó, khoảng dự đoán mức $100(1 - \alpha)\%$ của Y_0 được cho bởi:

$$\mathbf{z}_0^T \hat{\beta} \pm t_{n-r-1} \left(\frac{\alpha}{2} \right) \sqrt{s^2(1 + \mathbf{z}_0^T (\mathbf{Z}^T \mathbf{Z})^{-1} \mathbf{z}_0)}$$

Chứng minh

Theo Định lý 2.6, kỳ vọng và phương sai của $\mathbf{z}_0^T \hat{\beta}$ là

$$E(\mathbf{z}_0^T \hat{\beta}) = \mathbf{z}_0^T \beta \quad \text{và} \quad \text{Var}(\mathbf{z}_0^T \hat{\beta}) = \mathbf{z}_0^T (\mathbf{Z}^T \mathbf{Z})^{-1} \mathbf{z}_0 \sigma^2$$

Mặt khác

$$\hat{\varepsilon}_0 = Y_0 - \mathbf{z}_0^T \hat{\beta} = \mathbf{z}_0^T \beta + \varepsilon_0 - \mathbf{z}_0^T \hat{\beta} = \varepsilon_0 + \mathbf{z}_0^T (\beta - \hat{\beta})$$

Ta lại có $\hat{\beta}$ là ước lượng không chệch của β nên $E(\hat{\beta}) = \beta$

$$E(\hat{\varepsilon}_0) = E(\varepsilon_0) + E(\mathbf{z}_0^T (\beta - \hat{\beta})) = 0$$

Như vậy $\mathbf{z}_0^T \hat{\beta}$ là ước lượng không chệch của Y_0 . Hơn nữa, để ý rằng ε_0 và $\hat{\beta}$ là hai biến độc lập và $\hat{\beta}$ có phương sai là $\sigma^2 (\mathbf{Z}^T \mathbf{Z})^{-1}$ nên

$$\text{Var}(\hat{\varepsilon}_0) = \text{Var}(Y_0) + \text{Var}(\mathbf{z}_0^T \hat{\beta}) = \text{Var}(\varepsilon_0) + \text{Var}(\mathbf{z}_0^T \hat{\beta}) = \sigma^2(1 + \mathbf{z}_0^T (\mathbf{Z}^T \mathbf{Z})^{-1} \mathbf{z}_0)$$

Với giả thiết là ε có phân phối chuẩn và $\hat{\beta}$ cũng có phân phối chuẩn nên ta có

$$\frac{(Y_0 - \mathbf{z}_0^T \hat{\beta}) / \sqrt{\sigma^2(1 + \mathbf{z}_0^T (\mathbf{Z}^T \mathbf{Z})^{-1} \mathbf{z}_0)}}{\sqrt{s^2 / \sigma^2}} = \frac{Y_0 - \mathbf{z}_0^T \hat{\beta}}{\sqrt{s^2(1 + \mathbf{z}_0^T (\mathbf{Z}^T \mathbf{Z})^{-1} \mathbf{z}_0)}} \sim t_{n-r-1}.$$

Hay

$$P \left(\frac{|Y_0 - \mathbf{z}_0^T \hat{\beta}|}{\sqrt{s^2(1 + \mathbf{z}_0^T (\mathbf{Z}^T \mathbf{Z})^{-1} \mathbf{z}_0)}} < t_{n-r-1} \left(\frac{\alpha}{2} \right) \right) = 1 - \alpha$$

Do đó, khoảng dự đoán mức $100(1 - \alpha)\%$ của Y_0 là:

$$\mathbf{z}_0^T \hat{\beta} \pm t_{n-r-1} \left(\frac{\alpha}{2} \right) \sqrt{s^2(1 + \mathbf{z}_0^T (\mathbf{Z}^T \mathbf{Z})^{-1} \mathbf{z}_0)}$$

Ví dụ 5.1:

Một hãng sản xuất linh kiện máy tính cần xác định được tuổi thọ của một loại CPU (bộ xử lý trung tâm) dựa vào số lượng mua của khách hàng. Mục đích là để trong tương lai, hãng có thể sản xuất ra loại CPU thích hợp xu hướng người dùng. Bảng dưới đây là tuổi thọ của 7 loại CPU khác nhau (tính theo giờ) dựa trên số lượng đơn đặt của khách (tính theo nghìn) và lượng đơn vị vào - ra (là thông số của CPU, tính theo nghìn)

Y Tuổi thọ CPU (giờ)	z_1 Số đơn đặt (nghìn)	z_2 Lượng đơn vị vào - ra (nghìn)
141.5	123.5	2.108
168.9	146.1	9.213
154.8	133.9	1.905
146.5	128.5	0.815
172.8	151.5	1.061
160.1	136.2	8.603
108.5	92.0	1.125

Bảng 5.1. Tuổi thọ của 7 loại CPU

Ta xét mô hình hồi quy tuyến tính cổ điển cho tuổi thọ CPU

$$Y_j = \beta_0 + \beta_1 z_{j1} + \beta_2 z_{j2} + \varepsilon_j$$

Ta tính được phương trình hồi quy tuyến tính mẫu là

$$\hat{Y} = 7.862 + 1.080z_1 + 0.451z_2$$

Ta sẽ sử dụng nó để dự đoán hàm hồi quy và dự đoán quan sát mới tại $\mathbf{z}_0 = \begin{bmatrix} 1 & 130 & 7.5 \end{bmatrix}^T$. Ta có

$$\mathbf{z}_0^T \hat{\beta} = 141.687, \quad s^2 = 3.26549, \quad \mathbf{z}_0^T (\mathbf{Z}^T \mathbf{Z})^{-1} \mathbf{z}_0 = 0.37133$$

Do đó, khoảng tin cậy đồng thời mức 95% của hàm hồi quy tuyến tính tại $\mathbf{z}_0$ là

$$\mathbf{z}_0^T \hat{\beta} \pm t_{n-r-1} \left(\frac{\alpha}{2} \right) \sqrt{s^2 \mathbf{z}_0^T (\mathbf{Z}^T \mathbf{Z})^{-1} \mathbf{z}_0} = 151.687 \pm 3.057$$

và khoảng dự đoán mức 95% của quan sát mới $\mathbf{Y}_0$ tại $\mathbf{z}_0$ là:

$$Y_0 = \mathbf{z}_0^T \hat{\beta} \pm t_{n-r-1} \left(\frac{\alpha}{2} \right) \sqrt{s^2 (1 + \mathbf{z}_0^T (\mathbf{Z}^T \mathbf{Z})^{-1} \mathbf{z}_0)} = 151.687 \pm 5.875$$

2.6. Kiểm tra mô hình và các khía cạnh khác của hồi quy

2.6.1. Chuẩn hoá tập mẫu

Chuẩn hóa dữ liệu là một phương pháp tiền xử lý phổ biến thường xuyên được sử dụng trong các bài toán phân tích dữ liệu, đặc biệt là khi dữ liệu của chúng ta có yếu tố đơn vị (mét, kilogram,...). Yếu tố này khiến cho dữ liệu của chúng ta có các khoảng giá trị khác hẳn nhau, chẳng hạn z_1 là biến dự đoán chỉ chiều cao của một người, vậy thì $z_1 \in [0, 2]$ với đơn vị mét. Mặt khác, z_2 là biến dự đoán chỉ thu nhập của một người (tính theo giá trị tiền tệ) cho nên $z_2 \in [5000000, +\infty)$. Sự khác biệt lớn giữa khoảng giá trị của các biến độc lập có thể cản trở việc đưa ra mô hình chính xác. Để chuẩn hóa dữ liệu, ta đặt:

$$x = \frac{z - \mu}{\sigma}$$

trong đó z là giá trị quan sát, μ là giá trị trung bình mẫu và σ là độ lệch chuẩn mẫu.

Phép chuẩn hóa trên có tác dụng đo lường xem từng giá trị z có cách xa giá trị trung bình μ của nó hay không. Hơn nữa, việc chuẩn hóa giúp ta thu được một bộ dữ liệu mới có trung bình là 0 và độ lệch chuẩn là 1.

2.6.2. Outlier và cách xử lý

Outlier là điểm dữ liệu bất thường, bất thường ở đây có nghĩa là quan sát tại điểm đó nằm cách xa đám mây dữ liệu mà ta thu thập được. Outlier thường là kết quả của sự thiếu chính xác khi quan sát số liệu.

Trong thực nghiệm việc nhận biết được outlier không hề đơn giản, đặc biệt là khi ta có hàng nghìn đến hàng triệu điểm dữ liệu khiến cho việc dùng mắt thường để xác định outlier trở nên vô nghĩa. Trong đồ án này, ta sẽ tìm hiểu về hai phương pháp để hỗ trợ công việc trên đó là **độ đo Leverage** và **quy tắc 1.5IQR**.

2.6.3. Độ đo Leverage

Leverage là độ đo khoảng cách giữa một điểm dữ liệu và phần còn lại của bộ dữ liệu dựa trên miền giá trị của bộ dữ liệu đó. Độ đo Leverage được xác định bởi công thức:

$$h_{jj} = \frac{1}{n} + \frac{(z_j - \bar{z})^2}{\sum_{j=1}^n (z_j - \bar{z})^2}$$

Một cách định nghĩa khác cho độ đo Leverage đó là ta xét ma trận $\mathbf{H} = \mathbf{Z}(\mathbf{Z}^T \mathbf{Z})^{-1} \mathbf{Z}$. Khi đó leverage tại điểm dữ liệu thứ j chính là phần tử h_{jj} trên đường chéo chính

của ma trận $\mathbf{H}$. Phân tích sâu hơn, ta có vector

$$\hat{\mathbf{Y}} = \mathbf{Z}\hat{\boldsymbol{\beta}} = \mathbf{Z}(\mathbf{Z}^T\mathbf{Z})^{-1}\mathbf{Z}\mathbf{Y} = \mathbf{H}\mathbf{Y}$$

trong đó, phần tử thứ j của vector $\hat{\mathbf{Y}}$ là

$$\hat{Y}_j = h_{jj}y_j + \sum_{k \neq j} h_{jk}y_k$$

Với điều kiện các phần tử y_{jk} , $j \neq k$ cố định thì

$$\Delta \hat{Y}_j = \Delta y_j h_{jj}$$

Như vậy, nếu độ đo Leverage (h_{jj}) tại quan sát thứ j càng lớn, thì y_j sẽ càng có tác động lớn đến giá trị của $\hat{Y}_j$, hay nói cách khác là ảnh hưởng lớn đến độ dốc của mô hình hồi quy. Những điểm như vậy được gọi là high Leverage và chắc chắn đây là outlier.

Quay trở lại phương trình của h_{jj} , ta thấy rằng h_{jj} luôn nằm giữa $1/n$ và 1 . Hơn nữa, Leverage trung bình cho các quan sát luôn bằng $(p+1)/n$, trong đó p là số biến dự đoán. Vì vậy, nếu một quan sát mà có độ đo Leverage quá lớn so với $(p+1)/n$, ta có thể nghi ngờ rằng đó là một điểm high Leverage.

2.6.4. Quy tắc 1.5IQR

Bất kỳ tập dữ liệu nào cũng có thể mô tả bằng năm giá trị đặc trưng, năm giá trị này cung cấp cho chúng ta thông tin cần thiết để định vị outlier bao gồm (lần lượt theo thứ tự tăng dần):

- Giá trị nhỏ nhất hoặc thấp nhất của tập dữ liệu.
- Tứ phân vị thứ nhất Q_1 : Phân vị mức 25%.
- Tứ phân vị thứ hai Q_2 : Phân vị mức 50% (chính là trung vị).
- Tứ phân vị thứ ba Q_3 : Phân vị mức 75%.
- Giá trị lớn nhất hoặc cao nhất của tập dữ liệu.

Tiếp theo, ta định nghĩa **khoảng cách tứ phân vị** là giá trị

$$\text{IQR} = Q_3 - Q_1$$

Khi đó nếu $x \notin [Q_1 - 1.5\text{IQR}, Q_3 + 1.5\text{IQR}]$ thì x sẽ được coi là một điểm outlier.

2.6.5. Kiểm tra tính phụ thuộc vào biến của mô hình

Sau khi đã đưa ra được mô hình hoàn chỉnh, một bước nữa không thể thiếu đó là kiểm định sự quan trọng của các biến. Điều này bắt nguồn từ việc trong thực tế không phải biến dự đoán nào cũng có đóng góp lớn đến đầu ra của mô hình. Vì thế, việc loại bỏ bớt biến là vô cùng cần thiết, một mặt điều này làm đơn giản hóa mô hình, giúp cho các tính toán được thực thi nhanh hơn, mặt khác, nó giúp ta hiểu thêm về các nhân tố quyết định đến đầu ra mà ta mong muốn.

Để kiểm định xem, liệu trong số các biến $Z_1, Z_2, \dots, Z_r$ có biến nào là có thể loại khỏi mô hình hồi quy tuyến tính bội, ta tiến hành F -test. Việc này được tiến hành bằng cách giả sử rằng một vài hệ số β_r của chúng ta bằng 0 (đồng nghĩa với việc loại bỏ Z_r) hay ta có cặp giả thuyết đối thuyết sau

$$H_0 : \beta_1 = \beta_2 = \dots = \beta_r = 0 \quad \text{và} \quad H_1 : \exists \beta_j \neq 0 \text{ với } j = \overline{1, r}$$

Ta sau đó tính toán F -score

$$F = \frac{(n-r-1)R^2}{k(1-R^2)}$$

trong đó,

$$R^2 = \frac{\hat{\mathbf{Y}}^T \hat{\mathbf{Y}} - n\bar{y}^2}{\mathbf{Y}^T \mathbf{Y} - n\bar{y}^2} = \frac{\sum_{r=1}^n (\hat{Y}_r - \bar{y})^2}{\sum_{r=1}^n (y_r - \bar{y})^2} = 1 - \frac{\sum_{r=1}^n \hat{\varepsilon}_r^2}{\sum_{r=1}^n (y_r - \bar{y})^2}$$

Ta bác bỏ H_0 và chấp nhận H_1 với mức ý nghĩa $100\alpha\%$ nếu $F > F_{k, n-r-1}(\alpha)$.

Ví dụ 6.1:

Để nghiên cứu sự phụ thuộc giữa doanh thu với chi phí sản xuất và chi phí tiếp thị, người ta điều tra ngẫu nhiên doanh thu của 12 công ty trong 12 thời kỳ, kết quả ta có bảng sau:

Y Doanh thu (dollar)	z_1 Chi phí sản xuất (dollar)	z_2 Chi phí tiếp thị (dollar)
127	18	10
149	25	11
106	19	6
163	24	16
102	15	7
180	26	17
161	25	14
128	16	12
139	17	12
144	23	12
159	22	14
138	15	15

Sử dụng công thức tính R^2 , ta được $R^2 = 0.9756$. Từ đó,

$$F = \frac{2(0.9756)}{(12 - 2 - 1)(1 - 0.9756)} = 179.6292$$

Tra bảng F với mức ý nghĩa 2%, ta được $F_{2,9}(0.02) = 6.234 < F$. Do đó, ta bác bỏ giả thuyết H_0 , tức là bài toán có sự phụ thuộc vào các biến độc lập.

2.6.6. Kiểm tra tính đa cộng tuyến của các biến dự đoán và cách khắc phục

Sự đa cộng tuyến giữa các biến dự đoán ám chỉ trường hợp mà ở đó, hai hay nhiều biến dự đoán có sự ràng buộc với nhau. Một cách mô tả khác của hiện tượng này là khi ma trận $\mathbf{Z}$ không đầy hạng, tức là tồn tại một vector thực $\mathbf{u}$ sao cho $\mathbf{Z}\mathbf{u} = \mathbf{0}$, lúc này ta nói giữa các cột của $\mathbf{Z}$ có sự đa cộng tuyến và dẫn đến $(\mathbf{Z}^T\mathbf{Z})^{-1}$ không có nghịch đảo. Trong các phân tích hồi quy, việc $\mathbf{Z}\mathbf{u} = \mathbf{0}$ rất hiếm khi xảy ra. Mặc dù vậy, nếu như một số tổ hợp tuyến tính giữa các cột của $\mathbf{Z}$ gần với vector 0, việc tính toán ra $(\mathbf{Z}^T\mathbf{Z})^{-1}$ sẽ bị thiếu ổn định. Hệ quả điển hình của hiện tượng này đó là các phần tử trên đường chéo chính của ma trận $(\mathbf{Z}^T\mathbf{Z})^{-1}$ sẽ rất lớn, dẫn đến các ước lượng $\hat{\beta}_i$ lớn theo và gây cản trở trong việc xác định độ quan trọng của các biến dự đoán.

Một số dấu hiệu nhận biết hiện tượng này chẳng hạn như có một hay nhiều phần tử trên đường chéo chính của ma trận $(\mathbf{Z}^T \mathbf{Z})^{-1}$ tỏ ra rất lớn, hay các hệ số tương quan tuyến tính mẫu $\rho_{ij} = s_{ij} / \sqrt{s_{jj}s_{ii}}$ lớn hơn 0.7. Trong đó,

$$s_{ij} = \frac{1}{n} \sum_{r=1}^n z_{ri} z_{rj} - \bar{z}_i \bar{z}_j$$

Để khắc phục hiện tượng đa cộng tuyến, ta thực hiện các bước sau:

1. Tính các hệ số tương quan tuyến tính mẫu ρ_{ij}
2. Đặt ρ_{0i} là các hệ số tương quan giữa Y và Z_i , với

$$\rho_{0i} = \frac{s_{0i}}{\sqrt{s_{ii}s_{00}}}$$

trong đó $s_{00} = s_Y^2$ và $s_{0j} = (1/n) \sum_{k=1}^n y_k z_{kj} - \bar{y} \bar{z}_j$. Nếu $|\rho_{ij}| > 0.7$ thì

- Loại Z_i ra khỏi mô hình nếu $|\rho_{0i}| < |\rho_{0j}|$
- Loại Z_j ra khỏi mô hình nếu $|\rho_{0i}| > |\rho_{0j}|$

3. Thực hiện hồi quy sau khi ma trận $\mathbf{Z}$ đã loại bỏ biến Z_i hay Z_j

Cơ sở để thực hiện loại biến dự đoán ở bước 2 đó là dựa trên sự tương quan của biến này đối với Y , biến nào thể hiện mức độ tương quan với Y lớn hơn, tức là có hệ số tương quan sát với 1 hơn, thì biến đó sẽ được giữ lại.

2.6.7. Giá trị thống kê kiểm định và trị số p

Trước khi đến với phần chọn lọc các biến quan trọng đối với mô hình, ta trước hết cần tính toán ra trị số p viết tắt là p -value cho mỗi biến. Để tính được p -value này, ta cần xét cặp giả thuyết và đối thuyết sau với mỗi $i = \overline{1, r}$.

$$H_0 : \beta_i = 0 \quad \text{và} \quad H_1 : \beta_i \neq 0$$

Việc bác bỏ hay chấp nhận giả thuyết H_0 được thực hiện thông qua giá trị thống kê kiểm định viết tắt là t -statistic và được xác định bởi

$$t\text{-statistic} = \frac{\hat{\beta}_i}{\sqrt{\hat{D}(\hat{\beta}_i)}}$$

trong đó $\hat{\beta}_i$ là ước lượng của hệ số hồi quy thứ i và

$$\hat{D} = s^2 = \frac{1}{n-r-1} \sum_{j=1}^n \hat{\varepsilon}_j^2$$

Giá trị p -value là xác suất quan sát được một số có giá trị tuyệt đối bằng t -statistic hoặc lớn hơn

$$p\text{-value} = 2(1 - \text{CDF}(n, |t\text{-statistic}|))$$

trong đó CDF là hàm phân phối tích lũy của phân phối Student.

Áp dụng vào bài toán đang xét, ta rút ra được các kết quả sau

- Nếu có mối liên hệ giữa Z_i và Y , ta kì vọng t -statistic có phân phối Student với $n - 2$ bậc tự do.
- Giả thuyết bị bác bỏ khi $p\text{-value} < 5\%$ hoặc $p\text{-value} < 1\%$ tùy mức ý nghĩa mà ta chọn (thường là 5%).
- Khi $n \geq 30$, chúng lần lượt tương ứng với $t\text{-statistic} \geq 2$ hoặc $t\text{-statistic} \geq 2.75$.

2.6.8. Khảo sát phần dư

Một giả thiết quan trọng của mô hình hồi quy tuyến tính đó là nhiễu ε có phân phối chuẩn. Thực tế ta không thể biết được sai số của các phép đo có phân phối chuẩn hay không, do đó ta phải đưa vào bài toán kiểm định.

Ta sẽ đưa ra một tiêu chuẩn để chấp nhận hay bác bỏ giả thuyết

$$H_0 : \varepsilon \sim \mathcal{N}(0, \sigma^2 \mathbf{I})$$

hay viết theo cách khác

$$H_0 : \hat{\varepsilon} \sim \mathcal{N}(0, \sigma^2 \mathbf{I})$$

Ta có định lý sau

Định lý 2.8

Xét mô hình hồi quy tuyến tính $\mathbf{Y} = \mathbf{Z}\beta + \varepsilon$ với ma trận $\mathbf{Z}$ đầy hạng. Khi đó giả thuyết $H_0 : \varepsilon \sim \mathcal{N}(0, \sigma^2 \mathbf{I})$ bị bác bỏ với mức ý nghĩa $100(1 - \alpha)\%$ nếu

$$\sqrt{n - r - 2} \left(\sum_{i=1}^n \mathbf{v}_i \right)^T \hat{\varepsilon} > t_{n-r-2} \left(\frac{\alpha}{2} \right) \sqrt{\left| n \left(\sum_{i=1}^n \mathbf{v}_i \right)^T \hat{\varepsilon} - (n - r - 1) \hat{\varepsilon}^T \hat{\varepsilon} \right|}$$

trong đó $\mathbf{v}_1, \mathbf{v}_2, \dots, \mathbf{v}_n$ là các vector riêng trực chuẩn của ma trận

$$\mathbf{I} - \mathbf{H} = \mathbf{I} - \mathbf{Z}(\mathbf{Z}^T \mathbf{Z})^{-1} \mathbf{Z}^T$$

Chứng minh

Do ma trận $\mathbf{I} - \mathbf{H}$ là ma trận lũy đẳng nó chỉ có các trị riêng là 0 hoặc 1. Viết ma trận $\mathbf{I} - \mathbf{H}$ dưới dạng chéo hóa, ta được

$$\mathbf{I} - \mathbf{H} = \mathbf{P}\mathbf{\Lambda}\mathbf{P}^T$$

trong đó $\mathbf{P} = [\mathbf{v}_1 : \mathbf{v}_2 : \dots : \mathbf{v}_n]$ là ma trận trực giao gồm các vector riêng trực chuẩn và

$$\mathbf{\Lambda} = \text{diag}\{\underbrace{1, \dots, 1}_{n-r-1}, \underbrace{0, \dots, 0}_{r+1}\}$$

Đặt

$$\mathbf{e} = \begin{bmatrix} e_1 & e_2 & \dots & e_n \end{bmatrix}^T = \mathbf{P}^T \hat{\mathbf{e}}$$

Nếu giả thuyết H_0 đúng thì

$$E(\mathbf{e}) = \mathbf{P}^T E(\hat{\mathbf{e}}) = \mathbf{0}$$

$$\text{Cov}(\mathbf{e}) = \mathbf{P}^T \text{Cov}(\sigma^2(\mathbf{I} - \mathbf{H}))\mathbf{P} = \sigma^2 \mathbf{P}^T \mathbf{P} \mathbf{\Lambda} \mathbf{P}^T \mathbf{P} = \sigma^2 \mathbf{\Lambda}$$

Không những vậy, $e_1, e_2, \dots, e_{n-r-1}$ sẽ là các biến ngẫu nhiên có phân phối chuẩn và $e_{n-r} = e_{n-r+1} = \dots = e_n = 0$. Khi đó,

$$\sum_{i=1}^n e_i = \sum_{i=1}^{n-r-1} e_i \quad \text{và} \quad \sum_{i=1}^n e_i^2 = \sum_{i=1}^{n-r-1} e_i^2 \quad (2.19)$$

Xét vector ngẫu nhiên

$$\bar{e} = \frac{1}{n} \sum_{i=1}^n e_i \quad \text{và} \quad \tilde{e} = \frac{1}{n-r-1} \sum_{i=1}^{n-r-1} e_i$$

Nếu giả thuyết H_0 đúng thì ta sẽ có

$$n\bar{e} = (n-r-1)\tilde{e} \quad (2.20)$$

Hơn nữa, ta còn có biến đổi

$$\begin{aligned} \sum_{i=1}^{n-r-1} (e_i - \tilde{e})^2 &= \sum_{i=1}^{n-r-1} e_i^2 + (n-r-1)\tilde{e}^2 - 2 \sum_{i=1}^{n-r-1} e_i \tilde{e} \\ &= \sum_{i=1}^{n-r-1} e_i^2 + (n-r-1)\tilde{e}^2 - 2 \sum_{i=1}^n e_i \tilde{e} \\ &= \sum_{i=1}^{n-r-1} e_i^2 + (n-r-1)\tilde{e}^2 - 2\tilde{e}(n\bar{e}) \\ &= \sum_{i=1}^{n-r-1} e_i^2 - (n-r-1)\tilde{e}^2 \end{aligned} \quad (2.21)$$

Xét thống kê

$$T = n\bar{e} \sqrt{\frac{n-r-2}{\left| n^2\bar{e}^2 - (n-r-1) \sum_{i=1}^n e_i^2 \right|}} \quad (2.22)$$

Nếu giả thiết H_0 đúng thì theo các công thức (2.19), (2.20) và (2.21), ta có

$$\begin{aligned} T &= \left(\sum_{i=1}^n e_i \right) \sqrt{\frac{n-r-2}{\left| (n-r-1)^2 \bar{e}^2 - (n-r-1) \sum_{i=1}^n e_i^2 \right|}} \\ &= \left(\sum_{i=1}^{n-r-1} e_i \right) \frac{1}{\sqrt{n-r-1}} \sqrt{\frac{n-r-2}{\sum_{i=1}^n e_i^2 - (n-r-1) \bar{e}^2}} \\ &= \left(\sum_{i=1}^{n-r-1} e_i \right) \frac{1}{\sqrt{n-r-1}} \sqrt{\frac{n-r-2}{\sum_{i=1}^{n-r-1} (e_i - \bar{e})^2}} \\ &= \frac{\frac{1}{n-r-1} \sum_{i=1}^{n-r-1} e_i}{\sqrt{\frac{1}{n-r-2} \sum_{i=1}^{n-r-1} (e_i - \bar{e})^2}} \sqrt{n-r-1} \sim t_{n-r-2} \end{aligned}$$

Như vậy tiêu chuẩn để bác bỏ giả thuyết H_0 với mức ý nghĩa $100(1-\alpha)\%$ là

$$|T| > t_{n-r-2} \left(\frac{\alpha}{2} \right)$$

hay viết lại thành

$$n\bar{e}\sqrt{n-r-2} > t_{n-r-2} \left(\frac{\alpha}{2} \right) \sqrt{\left| n^2\bar{e}^2 - (n-r-1) \sum_{i=1}^n e_i^2 \right|} \quad (2.23)$$

Chú ý rằng

$$\begin{aligned} n\bar{e} &= \sum_{i=1}^n e_i = \mathbf{1}^T \mathbf{e} = \mathbf{1}^T \mathbf{P}^T \hat{\mathbf{e}} = (\mathbf{P}\mathbf{1})^T \hat{\mathbf{e}} = \left(\sum_{i=1}^n \mathbf{v}_i \right)^T \hat{\mathbf{e}} \\ \sum_{i=1}^n e_i^2 &= \mathbf{e}^T \mathbf{e} = \hat{\mathbf{e}}^T \mathbf{P} \mathbf{P}^T \hat{\mathbf{e}} = \hat{\mathbf{e}}^T \hat{\mathbf{e}} \end{aligned}$$

Thay vào tiêu chuẩn ở công thức (2.23), ta được điều phải chứng minh.

2.6.9. Xác định các biến quan trọng

Như đã nói ở trên, một bước không thể thiếu sau khi đưa ra được mô hình hồi quy đó là xác định tính quan trọng của các biến dự đoán thông qua F -test để đưa ra được p -value cho từng hệ số tương ứng với biến. Sau đó ta dựa vào mức ý nghĩa (thường là 5%) để loại bỏ các biến (p -value > 5%). Tất nhiên, có thể sẽ xảy ra tình huống mà ở đó tất cả biến dự đoán đều quan trọng đối với biến phản hồi nhưng trong thực tế điều này hiếm khi xảy ra nếu không muốn nói là không thể. Thay vào đó, biến phản hồi thường chỉ có tương quan chặt chẽ với một tập con các biến dự đoán. Do vậy, nhiệm vụ của nhà phân tích là tìm ra được một tập con phù hợp nhất trong các biến dự đoán sao cho vẫn đảm bảo được sức mạnh của mô hình.

Lý tưởng mà nói, ta luôn muốn chọn được tập con phù hợp bằng cách thử tất cả các mô hình với các tập con có thể có trong số p biến dự đoán. Vậy làm cách nào để quyết định xem mô hình con nào tốt hơn?

Tổng quát, với mô hình cho trước p biến dự đoán, không lẽ ta sẽ phải kiểm tra toàn bộ 2^p mô hình tất cả và chọn ra mô hình tốt nhất? Tất nhiên ta sẽ không mò kim đáy bể như vậy, mà ta tiến hành các phương pháp thực tiễn và hiệu quả hơn về mặt thời gian.

Ta đưa ra 3 phương pháp như sau:

Chọn tiến dần.

1. Gọi $\mathcal{M}_0$ là mô hình *null* (mô hình không chứa biến dự đoán).
2. Với $k = 0, 1, \dots, p-1$
 - Xét tất cả $p-k$ mô hình được tạo bằng cách lấy các biến phản hồi của $\mathcal{M}_k$ và thêm vào một biến không có trong $\mathcal{M}_k$.
 - Chọn mô hình tốt nhất trong $p-k$ mô hình vừa tạo và gọi mô hình đó là $\mathcal{M}_{k+1}$. Tốt nhất ở đây là có giá trị RSS cao nhất hoặc R^2 cao nhất.
3. Chọn mô hình tốt nhất trong các mô hình $\mathcal{M}_0, \mathcal{M}_1, \dots, \mathcal{M}_p$.

Chọn lùi dần.

1. Gọi $\mathcal{M}_p$ là mô hình *full* (mô hình chứa tất cả các biến dự đoán).
2. Với $k = p, p-1, \dots, 1$
 - Xét tất cả k mô hình được tạo bằng cách loại đi một biến trong mô hình $\mathcal{M}_k$.

- Chọn mô hình "tốt nhất" trong k mô hình vừa tạo và gọi mô hình đó là $\mathcal{M}_{k-1}$. Tốt nhất ở đây là có giá trị RSS cao nhất hoặc R^2 cao nhất.

3. Chọn mô hình tốt nhất trong các mô hình $\mathcal{M}_0, \mathcal{M}_1, \dots, \mathcal{M}_p$.

Chọn hỗn hợp. (Kết hợp giữa chọn tiến dần và chọn lùi dần)

1. Gọi $\mathcal{M}_0$ là mô hình *null* (mô hình không chứa biến dự đoán).
2. Với $k = 0, 1, \dots, p$
 - Xét tất cả $p - k$ mô hình được tạo bằng cách lấy các biến phản hồi của $\mathcal{M}_k$ và thêm vào một biến không có trong $\mathcal{M}_k$.
 - Chọn mô hình tốt nhất trong $p - k$ mô hình vừa tạo và gọi mô hình đó là $\mathcal{M}_{k+1}$. Tốt nhất ở đây là có giá trị RSS cao nhất hoặc R^2 cao nhất.
 - Sau khi chọn được mô hình tốt nhất, ta tiến hành kiểm tra xem có thể loại được biến nào trong mô hình đó hay không. Biến loại đi sẽ không được thêm lại vào mô hình ở các vòng lặp tiếp theo.

2.7. Hồi quy tuyến tính đa bội

Ở phần hồi quy tuyến tính đa bội, em có tham khảo thêm một số định nghĩa, công thức, định lý và hệ trong sách "Analysing Your Multivariate Data as a Pictorial: A Case for Applying Biplot Methodology" từ trang 365-387 của tác giả N. J. le Roux và Sugnet Gardner.

2.7.1. Xây dựng mô hình

Ở các mục trước, chúng ta đã tìm hiểu về mô hình hồi quy tuyến tính đơn giản và mô hình hồi quy tuyến tính bội. Ở mục này, ta sẽ mở rộng mô hình bằng cách sử dụng nhiều hơn một biến phản hồi. Xét một mối quan hệ tuyến tính giữa m biến phản hồi $Y_1, Y_2, \dots, Y_m$ và r biến dự đoán $z_1, z_2, \dots, z_r$. Mỗi biến phản hồi Y_i được giả sử là tuân theo một mô hình hồi quy tuyến tính, vì vậy ta viết

$$\begin{aligned} Y_1 &= \beta_{01} + \beta_{11}Z_1 + \dots + \beta_{r1}Z_r + \varepsilon_1 \\ Y_2 &= \beta_{02} + \beta_{12}Z_1 + \dots + \beta_{r2}Z_r + \varepsilon_2 \\ &\vdots \\ Y_m &= \beta_{0m} + \beta_{1m}Z_1 + \dots + \beta_{rm}Z_r + \varepsilon_m \end{aligned}$$

Vector nhiễu $[\varepsilon] = [\varepsilon_1 \ \varepsilon_2 \ \dots \ \varepsilon_m]^T$ được giả sử là tuân theo phân phối chuẩn m chiều với $E([\varepsilon]) = 0$ và $\text{Var}([\varepsilon]) = \Sigma$. Trong đó, Σ là ma trận đối xứng xác định dương. Bây giờ, để tiếp cận với công thức của mô hình hồi quy tuyến tính đa bội, ta ký hiệu

$$\begin{aligned}\mathbf{Z}_j &= [z_{j0} \ z_{j1} \ \dots \ z_{jr}] \\ \mathbf{Y}_j &= [y_{j1} \ y_{j2} \ \dots \ y_{jm}]^T \\ [\varepsilon]_j &= [\varepsilon_{j1} \ \varepsilon_{j2} \ \dots \ \varepsilon_{jm}]^T\end{aligned}$$

lần lượt là giá trị thu thập được của các biến dự đoán, biến phản hồi và nhiễu tại quan sát thứ j .

Ta xây dựng được mô hình hồi quy tuyến tính đa bội như sau

$$[\mathbf{Y}]_{n \times m} = [\mathbf{Z}]_{n \times (r+1)} [\boldsymbol{\beta}]_{(r+1) \times m} + [\boldsymbol{\varepsilon}]_{n \times m}$$

với các giả thiết

$$E(\varepsilon_{(i)}) = 0 \quad \text{và} \quad \text{Cov}(\varepsilon_{(i)}, \varepsilon_{(j)}) = \sigma_{ij} \mathbf{I} \quad \forall i, j = \overline{1, m}$$

và ma trận hiệp phương sai của m giá trị nhiễu tại quan sát thứ j

$$\text{Var}(\varepsilon_j) = \Sigma = \begin{bmatrix} \sigma_{11} & \sigma_{12} & \dots & \sigma_{1m} \\ \sigma_{21} & \sigma_{22} & \dots & \sigma_{2m} \\ \vdots & \vdots & \ddots & \vdots \\ \sigma_{m1} & \sigma_{m2} & \dots & \sigma_{mm} \end{bmatrix} \quad \forall j = \overline{1, n}$$

Tương tự như mô hình hồi quy tuyến tính cổ điển, các nhiễu tại các quan sát khác nhau sẽ không có sự tương quan, hay nói cách khác $\text{Cov}(\varepsilon_{ij}, \varepsilon_{kq}) = 0$ với $j \neq q$. Tuy nhiên, các nhiễu tại cùng một quan sát có thể có tương quan với nhau.

Các tham số mà ta chưa biết là $[\boldsymbol{\beta}]$ và Σ , việc ước lượng các tham số này dựa trên các quan sát mà ta thu thập sẽ được trình bày chi tiết ở phần sau.

2.7.2. Ước lượng các tham số

1. Ước lượng bình phương cực tiểu của $[\boldsymbol{\beta}]$

Như đã đề cập ở phần trước, ta có biến phản hồi thứ j tuân theo mô hình hồi quy tuyến tính cổ điển

$$\mathbf{Y}_{(j)} = \mathbf{Z}\boldsymbol{\beta}_{(j)} + \varepsilon_{(j)}$$

Với mỗi mô hình như vậy, tổng bình phương nhiễu RSS_j được cực tiểu hóa bởi $[\hat{\boldsymbol{\beta}}]_{(j)} = (\mathbf{Z}^T \mathbf{Z})^{-1} \mathbf{Z}^T \mathbf{Y}_{(j)}$. Mặt khác, tổng bình phương nhiễu của cả mô hình hồi

quy tuyến tính bội được cho bởi công thức

$$\text{RSS}([\beta]) = \sum_{j=1}^n \text{RSS}(\beta_{(j)}) = \sum_{j=1}^n (\mathbf{Y}_{(j)} - \mathbf{Z}\beta_{(j)})^T (\mathbf{Y}_{(j)} - \mathbf{Z}\beta_{(j)})$$

Vì mỗi số hạng trong chuỗi tổng trên là một số không âm nên $\text{RSS}([\beta])$ của toàn bộ mô hình đạt cực tiểu khi từng $\text{RSS}(\beta_{(j)})$ đạt cực tiểu. Để đạt được điều này thì ta phải có $\beta_{(j)} = [\hat{\beta}]_{(j)} = (\mathbf{Z}^T \mathbf{Z})^{-1} \mathbf{Z}^T \mathbf{Y}_{(j)}$, hay

$$[\hat{\beta}] = (\mathbf{Z}^T \mathbf{Z})^{-1} \mathbf{Z}^T [\mathbf{Y}] \quad (2.24)$$

Từ đó suy ra $[\hat{\beta}]$ là một ước lượng bình phương cực tiểu cho ma trận hệ số hồi quy $[\beta]$.

2. Ước lượng cho $[\mathbf{Y}]$, $[\varepsilon]$ và Σ

Sử dụng ước lượng bình phương cực tiểu $[\hat{\beta}]$ vừa tìm được ở công thức (2.24), ta dễ dàng xây dựng các ma trận ước lượng của $[\mathbf{Y}]$ và $[\varepsilon]$ như sau:

$$\begin{aligned} [\hat{\mathbf{Y}}] &= \mathbf{Z} [\hat{\beta}] = \mathbf{Z} (\mathbf{Z}^T \mathbf{Z})^{-1} \mathbf{Z}^T [\mathbf{Y}] \\ [\hat{\varepsilon}] &= [\mathbf{Y}] - [\hat{\mathbf{Y}}] = (\mathbf{I} - \mathbf{Z} (\mathbf{Z}^T \mathbf{Z})^{-1} \mathbf{Z}^T) [\mathbf{Y}] \end{aligned}$$

Hơn nữa, ta có

$$\begin{aligned} \mathbf{Z}^T [\hat{\varepsilon}] &= \mathbf{Z}^T (\mathbf{I} - \mathbf{Z} (\mathbf{Z}^T \mathbf{Z})^{-1} \mathbf{Z}^T) [\mathbf{Y}] = (\mathbf{Z}^T - \mathbf{Z}^T \mathbf{Z} (\mathbf{Z}^T \mathbf{Z})^{-1} \mathbf{Z}^T) [\mathbf{Y}] = 0 \\ [\hat{\mathbf{Y}}]^T [\hat{\varepsilon}] &= (\mathbf{Z} [\hat{\beta}])^T [\hat{\varepsilon}] = [\hat{\beta}]^T \mathbf{Z}^T [\hat{\varepsilon}] = 0 \end{aligned}$$

Điều này kéo theo mọi cột của $\mathbf{Z}$ và $[\hat{\mathbf{Y}}]$ trực giao với mọi cột của $[\hat{\varepsilon}]$. Mặt khác, do $[\mathbf{Y}] = [\hat{\mathbf{Y}}] + [\hat{\varepsilon}]$ nên

$$[\mathbf{Y}]^T [\mathbf{Y}] = ([\hat{\mathbf{Y}}] + [\hat{\varepsilon}])^T ([\hat{\mathbf{Y}}] + [\hat{\varepsilon}]) = [\hat{\mathbf{Y}}]^T [\hat{\mathbf{Y}}] + [\hat{\varepsilon}]^T [\hat{\varepsilon}]$$

Tiếp theo, ta sẽ tìm công thức ước lượng cho ma trận hiệp phương sai Σ . Cụ thể hơn, ta có định lý sau:

Định lý 2.8

Xét mô hình hồi quy tuyến tính bội $[\mathbf{Y}] = \mathbf{Z}[\boldsymbol{\beta}] + [\boldsymbol{\varepsilon}]$, với $\text{rank}\mathbf{Z} = r + 1 \leq n - m$, và nhiễu $[\boldsymbol{\varepsilon}]$ có phân phối chuẩn. Khi đó

$$\hat{\Sigma} = \frac{1}{n} [\hat{\boldsymbol{\varepsilon}}]^T [\hat{\boldsymbol{\varepsilon}}] = \frac{1}{n} ([\mathbf{Y}] - \mathbf{Z} [\hat{\boldsymbol{\beta}}])^T ([\mathbf{Y}] - \mathbf{Z} [\hat{\boldsymbol{\beta}}])$$

là ước lượng hợp lý cực đại của Σ

Chứng minh

Theo giả thiết, ta có n quan sát và tại quan sát thứ i thì vector $\boldsymbol{\varepsilon}_i = [\varepsilon_{i1} \ \varepsilon_{i2} \ \dots \ \varepsilon_{im}]$ tuân theo phân phối chuẩn m chiều $\mathcal{N}_m(0, \Sigma)$ với hàm mật độ xác suất đồng thời

$$f(\boldsymbol{\varepsilon}_i) = \frac{1}{\sqrt{(2\pi)^m \det \Sigma}} \exp \left(-\frac{1}{2} \boldsymbol{\varepsilon}_i \Sigma^{-1} \boldsymbol{\varepsilon}_i^T \right) = \frac{1}{\sqrt{(2\pi)^m \det \Sigma}} \exp \left(-\frac{1}{2} (\mathbf{Y}_i - \mathbf{Z} \boldsymbol{\beta}_i) \Sigma^{-1} (\mathbf{Y}_i - \mathbf{Z} \boldsymbol{\beta}_i)^T \right)$$

Từ đây ta có được hàm hợp lý cho n quan sát

$$L([\boldsymbol{\beta}], \Sigma, [\mathbf{Y}]) = \prod_{i=1}^n f(\boldsymbol{\varepsilon}_i) = \frac{1}{\sqrt{(2\pi)^{mn} (\det \Sigma)^n}} \exp \left(-\frac{1}{2} \sum_{i=1}^n (\mathbf{Y}_i - \mathbf{Z} \boldsymbol{\beta}_i) \Sigma^{-1} (\mathbf{Y}_i - \mathbf{Z} \boldsymbol{\beta}_i)^T \right) \quad (2.25)$$

Đặt

$$\mathbf{Q} = [q_{ij}]_{n \times n} = [\hat{\boldsymbol{\varepsilon}}]^T [\hat{\boldsymbol{\varepsilon}}] = ([\mathbf{Y}] - \mathbf{Z} [\hat{\boldsymbol{\beta}}])^T ([\mathbf{Y}] - \mathbf{Z} [\hat{\boldsymbol{\beta}}])$$

Khi đó

$$q_{ij} = \sum_{r=1}^n (y_{ri} - \hat{y}_{ri})(y_{rj} - \hat{y}_{rj})$$

trong đó y_{ij} và $\hat{y}_{ij}$ lần lượt là phần tử ở hàng i , cột j của ma trận $[\mathbf{Y}]$ và $[\hat{\mathbf{Y}}] = \mathbf{Z} [\hat{\boldsymbol{\beta}}]$. Với $(\Sigma^{-1})_{ij}$ là phần tử ở hàng i , cột j của ma trận Σ^{-1} , ta có biến đổi

$$\begin{aligned} \sum_{i=1}^n (\mathbf{Y}_i - \mathbf{Z} \boldsymbol{\beta}_i) \Sigma^{-1} (\mathbf{Y}_i - \mathbf{Z} \boldsymbol{\beta}_i)^T &= \sum_{i=1}^n \left(\sum_{j=1}^m \sum_{r=1}^m (y_{ij} - \hat{y}_{ij}) (\Sigma^{-1})_{jr} (y_{ir} - \hat{y}_{ir}) \right) \\ &= \sum_{j=1}^m \sum_{r=1}^m \left((\Sigma^{-1})_{jr} \sum_{i=1}^n (y_{ij} - \hat{y}_{ij})(y_{ir} - \hat{y}_{ir}) \right) \\ &= \sum_{j=1}^m \sum_{r=1}^m (\Sigma^{-1})_{jr} q_{jr} \\ &= \text{tr}(\Sigma^{-1} \mathbf{Q}) \end{aligned}$$

Như vậy hàm hợp lý ở công thức (2.25) có thể được viết lại thành

$$L([\boldsymbol{\beta}], \Sigma, [\mathbf{Y}]) = \frac{1}{\sqrt{(2\pi)^{mn} (\det \Sigma)^n}} \exp \left(-\frac{1}{2} \text{tr}(\Sigma^{-1} \mathbf{Q}) \right)$$

Tới đây ta sẽ tìm ma trận Σ để cực đại hóa log-hàm hợp lý

$$\log L([\beta], \Sigma, [\mathbf{Y}]) = -mn \log 2\pi + n \log \det(\Sigma^{-1}) - \frac{1}{2} \text{tr}(\Sigma^{-1} \mathbf{Q})$$

Do $\mathbf{Q}$ là ma trận đối xứng xác định dương nên tồn tại ma trận nghịch đảo của nó và ma trận căn bậc hai $\mathbf{Q}^{1/2}$.

Đặt $\mathbf{A} = \mathbf{Q}^{1/2} \Sigma^{-1} \mathbf{Q}^{1/2}$, khi đó $\Sigma^{-1} = \mathbf{Q}^{-1/2} \mathbf{A} \mathbf{Q}^{-1/2}$. Ta viết lại log-hàm hợp lý thành

$$\begin{aligned} \log L([\beta], \Sigma, [\mathbf{Y}]) &= -mn \log 2\pi + n \log \det(\mathbf{Q}^{-1/2} \mathbf{A} \mathbf{Q}^{-1/2}) - \text{tr}(\mathbf{Q}^{-1/2} \mathbf{A} \mathbf{Q}^{-1/2} \mathbf{Q}) \\ &= -mn \log 2\pi + n \log \det(\mathbf{Q}^{-1}) + n \log \det \mathbf{A} - \text{tr}(\mathbf{Q}^{-1/2} \mathbf{A} \mathbf{Q}^{1/2}) \\ &= -mn \log 2\pi - n \log \det \mathbf{Q} + n \log \det \mathbf{A} - \text{tr} \mathbf{A} \end{aligned} \quad (2.26)$$

Gọi λ_i ($i = \overline{1, m}$) là các trị riêng của ma trận $\mathbf{A}$. Ta có các kết quả đã có trong đại số tuyến tính như sau

$$\det \mathbf{A} = \prod_i \lambda_i \quad \text{và} \quad \text{tr} \mathbf{A} = \sum_i \lambda_i$$

Thay các kết quả này vào (2.26), ta được

$$\log L([\beta], \Sigma, [\mathbf{Y}]) = -mn \log 2\pi - n \log \det \mathbf{Q} + \sum_{i=1}^m (-\lambda_i + n \log \lambda_i)$$

Như vậy log-hàm hợp lý đạt cực đại khi và chỉ khi các giá trị $-\lambda_i + n \log \lambda_i$ đạt cực đại, tương đương với $\lambda_i = n$ với mỗi $i = \overline{1, m}$. Mặt khác, do $\mathbf{A}$ là ma trận đối xứng nên ta có thể viết $\mathbf{A}$ dưới dạng chéo hóa

$$\mathbf{A} = \mathbf{P} \mathbf{\Lambda} \mathbf{P}^T$$

trong đó $\mathbf{\Lambda} = \text{diag}\{\lambda_1, \lambda_2, \dots, \lambda_m\}$ và $\mathbf{P}$ là ma trận trực giao. Do các trị riêng của $\mathbf{A}$ đều bằng n nên

$$\mathbf{A} = \mathbf{P}(n\mathbf{I})\mathbf{P}^T = n\mathbf{P}\mathbf{P}^T = n\mathbf{I}$$

Từ đây suy ra ước lượng hợp lý cực đại của Σ là

$$\hat{\Sigma} = \mathbf{Q}^{1/2} \mathbf{A}^{-1} \mathbf{Q}^{1/2} = \mathbf{Q}^{1/2} \left(\frac{1}{n} \mathbf{I} \right) \mathbf{Q}^{1/2} = \frac{1}{n} \mathbf{Q} = \frac{1}{n} ([\mathbf{Y}] - \mathbf{Z} [\hat{\beta}])^T ([\mathbf{Y}] - \mathbf{Z} [\hat{\beta}])$$

Từ định lý trên, ta có hệ quả

Hệ quả 2.1

Giá trị lớn nhất của hàm hợp lý cực đại đạt tại $[\hat{\beta}]$ và $\hat{\Sigma}$ là

$$\begin{aligned} L([\hat{\beta}], \hat{\Sigma}, [\mathbf{Y}]) &= \frac{1}{\sqrt{(2\pi)^{mn} (\det \Sigma)^n}} \exp \left(-\frac{1}{2} \text{tr}(\Sigma^{-1} \mathbf{Q}) \right) \\ &= \frac{1}{\sqrt{(2\pi)^{mn} (\det \Sigma)^n}} \exp \left(-\frac{1}{2} \text{tr} \left(n \left([\varepsilon]^T [\varepsilon] \right)^{-1} ([\varepsilon]^T [\varepsilon]) \right) \right) \\ &= \frac{1}{\sqrt{(2\pi)^{mn} (\det \Sigma)^n}} \exp \left(-\frac{1}{2} \text{tr}(n \mathbf{I}) \right) \\ &= (\det \Sigma)^{-\frac{n}{2}} (2\pi e)^{-\frac{mn}{2}} \end{aligned}$$

Ngoài ra, với ước lượng như trên thì $n\hat{\Sigma}$ sẽ tuân theo phân phối $W_{p, n-r-1}(\Sigma)$.

2.7.3. Các tính chất quan trọng

Ở phần này, ta sẽ bàn về các tính chất của các tham số ước lượng, ví dụ như xét xem liệu các ước lượng đó có là ước lượng hợp lý cực đại với các mẫu quan sát được không, liệu chúng là ước lượng chệch hay không chệch.

Tính chất 1: $[\hat{\beta}]$ là ước lượng không chệch của β

Chứng minh

Để chứng minh tính chất này ta cần chỉ ra $E([\hat{\beta}]) = \beta$. Thật vậy, ta có

$$\begin{aligned} E([\hat{\beta}]) &= E((\mathbf{Z}^T \mathbf{Z})^{-1} \mathbf{Z}^T [\mathbf{Y}]) \\ &= E((\mathbf{Z}^T \mathbf{Z})^{-1} \mathbf{Z}^T (\mathbf{Z}[\beta] + [\varepsilon])) \\ &= E((\mathbf{Z}^T \mathbf{Z})^{-1} \mathbf{Z}^T \mathbf{Z}[\beta]) + E((\mathbf{Z}^T \mathbf{Z})^{-1} \mathbf{Z}^T [\varepsilon]) \\ &= [\beta] + (\mathbf{Z}^T \mathbf{Z})^{-1} \mathbf{Z}^T \underbrace{E([\varepsilon])}_0 = [\beta] \end{aligned}$$

Như vậy, $[\hat{\beta}]$ là một ước lượng không chệch của β

Tính chất 2: $[\hat{\beta}]$ là ước lượng hợp lý cực đại của $[\beta]$ (Khi nhiều $[\varepsilon]$ có phân phối chuẩn)

Chứng minh

Khi $[\varepsilon]$ có phân phối chuẩn thì hàm hợp lý cho n quan sát sẽ có dạng như công thức (2.25)

$$L([\beta], \Sigma, [\mathbf{Y}]) = \prod_{i=1}^n f(\varepsilon_i) = \frac{1}{\sqrt{(2\pi)^{mn}(\det \Sigma)^n}} \exp \left(-\frac{1}{2} \sum_{i=1}^n (\mathbf{Y}_i - \mathbf{Z}\beta_i) \Sigma^{-1} (\mathbf{Y}_i - \mathbf{Z}\beta_i)^T \right)$$

Đặt

$$S_i = (\mathbf{Y}_i - \mathbf{Z}\beta_i) \Sigma^{-1} (\mathbf{Y}_i - \mathbf{Z}\beta_i)^T$$

$$S = \sum_{i=1}^n (\mathbf{Y}_i - \mathbf{Z}\beta_i) \Sigma^{-1} (\mathbf{Y}_i - \mathbf{Z}\beta_i)^T = \sum_{i=1}^n S_i$$

Ta sẽ tìm giá trị $[\hat{\beta}]$ để cực đại hóa hàm hợp lý trên. Do đại lượng $1/\sqrt{(2\pi)^{mn}(\det \Sigma)^n}$ không phụ thuộc vào $[\beta]$ nên L đạt cực đại khi và chỉ khi giá trị S đạt cực tiểu. Mặt khác, bởi vì S là tổng của dạng toàn phương xác định không âm S_i nên S đạt cực tiểu khi và chỉ khi các giá trị S_i đạt cực tiểu. Ta có

$$\frac{\partial S_i}{\partial [\beta]^T} = (\Sigma^{-1} + (\Sigma^{-1})^T)(\mathbf{Y}_i^T - [\beta]^T \mathbf{Z}_i^T)(-\mathbf{Z}_i) = -2\Sigma^{-1}(\mathbf{Y}_i^T \mathbf{Z}_i - [\beta]^T \mathbf{Z}_i^T \mathbf{Z}_i)$$

Do ma trận Σ^{-1} là ma trận đối xứng xác định dương nên $\partial S_i / \partial [\beta]^T = 0$ khi và chỉ khi $\mathbf{Y}_i^T \mathbf{Z}_i = [\beta]^T (\mathbf{Z}_i^T \mathbf{Z}_i)$. Lấy tổng với i từ 1 đến n , ta được

$$\sum_{i=1}^n \mathbf{Y}_i^T \mathbf{Z}_i = \sum_{i=1}^n [\beta]^T (\mathbf{Z}_i^T \mathbf{Z}_i) \quad \text{hay} \quad [\mathbf{Y}]^T \mathbf{Z} = [\beta]^T (\mathbf{Z}^T \mathbf{Z})$$

Như vậy ước lượng hợp lý cực đại của $[\beta]$ chính là nghiệm của phương trình $\partial S_i / \partial [\beta]^T = 0$, và nghiệm đó chính là $[\hat{\beta}] = (\mathbf{Z}^T \mathbf{Z})^{-1} \mathbf{Z}^T [\mathbf{Y}]$

Tính chất 3: $E([\hat{\varepsilon}]) = 0$ và $\text{Cov}(\beta_{(i)}, \beta_{(j)}) = \sigma_{ij}(\mathbf{Z}^T \mathbf{Z})^{-1}$

Chứng minh

Để thấy $E([\hat{\varepsilon}]) = 0$ vì với mọi $j = \overline{1, m}$, ta có

$$E([\hat{\varepsilon}]_{(j)}) = E(\mathbf{Y}_{(j)} - \mathbf{Z} [\hat{\beta}]_{(j)}) = E(\mathbf{Z}(\beta_{(j)} - [\hat{\beta}]_{(j)}) + \varepsilon_{(j)}) = 0$$

Mặt khác, với phép đặt $\mathbf{C} = (\mathbf{Z}^T \mathbf{Z})^{-1} \mathbf{Z}^T$, ta có

$$\begin{aligned} \text{Cov}([\hat{\beta}]_{(i)}, [\hat{\beta}]_{(j)}) &= \text{Cov}(\mathbf{C}\mathbf{Y}_{(i)}, \mathbf{C}\mathbf{Y}_{(j)}) \\ &= E(\mathbf{C}\mathbf{Y}_{(i)} - E(\mathbf{C}\mathbf{Y}_{(i)}))(\mathbf{C}\mathbf{Y}_{(j)} - E(\mathbf{C}\mathbf{Y}_{(j)}))^T \\ &= \mathbf{C}(E(\mathbf{Y}_{(i)} - \mathbf{Z}\beta_{(i)})(\mathbf{Y}_{(j)} - \mathbf{Z}\beta_{(j)})^T)\mathbf{C}^T \\ &= \mathbf{C}E(\varepsilon_{(i)}\varepsilon_{(j)}^T)\mathbf{C}^T \\ &= \mathbf{C}\text{Cov}(\varepsilon_{(i)}, \varepsilon_{(j)})\mathbf{C}^T \\ &= (\mathbf{Z}^T \mathbf{Z})^{-1} \mathbf{Z}^T (\sigma_{ij}I) \mathbf{Z}(\mathbf{Z}^T \mathbf{Z})^{-1} \\ &= \sigma_{ij}(\mathbf{Z}^T \mathbf{Z})^{-1} \end{aligned}$$

Tính chất 4: $[\hat{\beta}]$ có phân phối chuẩn

Chứng minh

Với giả thiết $\varepsilon_{(i)} \sim \mathcal{N}_n(0, \sigma_{ii}\mathbf{I})$ ta được $\mathbf{Y}_{(i)} \sim \mathcal{N}_n(\mathbf{Z}\beta, \sigma_{ii}\mathbf{I})$.

Do đó $[\hat{\beta}]_{(\mathbf{I})} = (\mathbf{Z}^T \mathbf{Z})^{-1} \mathbf{Z} \mathbf{Y}_{(i)} \sim \mathcal{N}_{r+1}(\beta_{(i)}, \sigma_{ii}(\mathbf{Z}^T \mathbf{Z})^{-1})$.

$\Rightarrow [\hat{\beta}]$ có phân phối chuẩn.

Tính chất 5: $\hat{\Sigma}$ là ước lượng chệch của Σ

Chứng minh

Trước hết ta chứng minh $E([\hat{\varepsilon}]_{(i)}^T [\hat{\varepsilon}]_{(j)}) = \sigma_{ij}(n-r-1)$, với mọi $i, j = \overline{1, m}$.

Thật vậy, với các ma trận đối xứng lũy đẳng $\mathbf{H} = \mathbf{Z}(\mathbf{Z}^T \mathbf{Z})^{-1} \mathbf{Z}^T$ và $\mathbf{I} - \mathbf{H}$ đã đề cập ở mục 3, ta có biến đổi

$$\begin{aligned} E([\hat{\varepsilon}]_{(j)}^T [\hat{\varepsilon}]_{(k)}) &= E(\mathbf{Y}_{(j)} - \hat{\mathbf{Y}}_{(j)})^T (\mathbf{Y}_{(k)} - \hat{\mathbf{Y}}_{(k)}) \\ &= E(\mathbf{Y}_{(j)} - \mathbf{H}\mathbf{Y}_{(j)})^T (\mathbf{Y}_{(k)} - \mathbf{H}\mathbf{Y}_{(k)}) \\ &= E(\mathbf{Y}_{(j)}^T (\mathbf{I} - \mathbf{H}) \mathbf{Y}_{(k)}) \\ &= E(\mathbf{Y}_{(j)} - \mathbf{Z}\beta_{(j)})^T (\mathbf{I} - \mathbf{H}) (\mathbf{Y}_{(k)} - \mathbf{Z}\beta_{(k)}) \\ &= E(\varepsilon_{(j)}^T (\mathbf{I} - \mathbf{H}) \varepsilon_{(k)}) \\ &= E(\text{tr}((\mathbf{I} - \mathbf{H}) \varepsilon_{(k)} \varepsilon_{(j)}^T)) \\ &= \text{tr}((\mathbf{I} - \mathbf{H}) E(\varepsilon_{(k)} \varepsilon_{(j)}^T)) \\ &= \sigma_{jr} \text{tr}(\mathbf{I} - \mathbf{H}) \\ &= \sigma_{jr}(n-r-1) \end{aligned}$$

Như vậy, $E(\hat{\Sigma}) = (n-r-1)\Sigma/n$ và do đó $\hat{\Sigma}$ là ước lượng chệch của Σ .

Hệ quả 2.2

Ước lượng không chệch của Σ là

$$\hat{\Sigma}^* = \frac{n}{n-r-1} \hat{\Sigma} = \frac{n}{n-r-1} [\hat{\varepsilon}]^T [\hat{\varepsilon}]$$

2.7.4. Đưa ra dự đoán từ mô hình hồi quy tuyến tính đa bội

Xét mô hình hồi quy tuyến tính đa bội $\mathbf{Y} = \mathbf{Z}\beta + [\varepsilon]$ với $\text{rank}\mathbf{Z} = r+1 \leq n-m$ và nhiều $[\varepsilon]$ có phân phối chuẩn, với các tham số đã được ước lượng và tinh chỉnh. Khi đó, ta có thể tiến hành sử dụng mô hình trong việc dự đoán với các dữ liệu sẵn có. Vấn đề được đặt ra là ta phải dự đoán trung bình của các biến phải hồi dựa trên một

quan sát $\mathbf{Z}_0$ mà ta vừa thu thập được. Suy luận về trung bình của các biến phản hồi có thể được đưa ra dựa vào các phân phối mà ta đã kết luận được từ việc ước lượng các tham số hồi quy.

Trước hết ta có

$$[\hat{\beta}]^T \mathbf{z}_0 \sim \mathcal{N}_m(\beta^T \mathbf{z}_0, \mathbf{z}_0^T (\mathbf{Z}^T \mathbf{Z})^{-1} \mathbf{z}_0 \Sigma) \quad \text{và} \quad n\hat{\Sigma} \sim W_{n-r-1}(\Sigma)$$

Giá trị cần tìm của hàm hồi quy là $\beta^T \mathbf{z}_0$, dựa vào kiến thức về thống kê T^2 ở mục 5 ta có thể viết

$$T^2 = \left(\frac{[\hat{\beta}]^T \mathbf{z}_0 - \beta^T \mathbf{z}_0}{\sqrt{\mathbf{z}_0^T (\mathbf{Z}^T \mathbf{Z})^{-1} \mathbf{z}_0}} \right)^T \left(\frac{n}{n-r-1} \hat{\Sigma} \right)^{-1} \left(\frac{[\hat{\beta}]^T \mathbf{z}_0 - \beta^T \mathbf{z}_0}{\sqrt{\mathbf{z}_0^T (\mathbf{Z}^T \mathbf{Z})^{-1} \mathbf{z}_0}} \right)$$

và miền ellipsoid với độ tin cậy $100(1-\alpha)\%$ của $[\hat{\beta}]^T \mathbf{z}_0$ được cho bởi bất đẳng thức

$$\left(\frac{[\hat{\beta}]^T \mathbf{z}_0 - [\beta]^T \mathbf{z}_0}{\sqrt{\mathbf{z}_0^T (\mathbf{Z}^T \mathbf{Z})^{-1} \mathbf{z}_0}} \right)^T \left(\frac{n}{n-r-1} \hat{\Sigma} \right)^{-1} \left(\frac{[\hat{\beta}]^T \mathbf{z}_0 - [\beta]^T \mathbf{z}_0}{\sqrt{\mathbf{z}_0^T (\mathbf{Z}^T \mathbf{Z})^{-1} \mathbf{z}_0}} \right) \leq \mathbf{z}_0^T (\mathbf{Z}^T \mathbf{Z})^{-1} \mathbf{z}_0 \left[\frac{m(n-r-1)}{n-r-m} F_{m,n-r-m} \right]$$

mà ở đó, $F_{m,n-r-m}(\alpha)$ là phân vị trên mức ý nghĩa $100\alpha\%$ của phân phối Fisher với các bậc tự do là m và $n-r-m$. Từ đây ta có khoảng tin cậy đồng thời với độ tin cậy $100(1-\alpha)\%$ của $E(\mathbf{Y}_i | \mathbf{Z} = \mathbf{z}_0) = \mathbf{z}_0^T \beta_{(i)}$ là

$$\mathbf{z}_0 [\hat{\beta}]_{(i)} \pm \sqrt{\frac{m(n-r-1)}{n-r-m} F_{m,n-r-m}(\alpha)} \sqrt{\mathbf{z}_0^T (\mathbf{Z}^T \mathbf{Z})^{-1} \mathbf{z}_0 \left(\frac{n}{n-r-1} \hat{\Sigma}_{ii} \right)}$$

với $[\hat{\beta}]_{(i)}$ là cột thứ i của ma trận $[\hat{\beta}]$ và $\hat{\Sigma}_{ii}$ là phần tử ở hàng thứ i trên đường chéo chính của ma trận $\hat{\Sigma}$.

Một vấn đề khác là việc đưa ra dự đoán về các giá trị của $\mathbf{Y}_0 = [\beta]^T \mathbf{z}_0 + \varepsilon_0$, trong đó ε_0 độc lập với các vector trong ma trận $[\varepsilon]$.

Ta lại có

$$\mathbf{Y}_0 - [\hat{\beta}]^T \mathbf{z}_0 \sim \mathcal{N}_m(0, (1 + \mathbf{z}_0^T (\mathbf{Z}^T \mathbf{Z})^{-1} \mathbf{z}_0) \Sigma)$$

Khi đó miền ellipsoid dự đoán với độ tin cậy $100(1-\alpha)\%$ là:

$$\begin{aligned} & \left(\frac{[\hat{\beta}]^T \mathbf{z}_0 - [\beta]^T \mathbf{z}_0}{\sqrt{\mathbf{z}_0^T (\mathbf{Z}^T \mathbf{Z})^{-1} \mathbf{z}_0}} \right)^T \left(\frac{n}{n-r-1} \hat{\Sigma} \right)^{-1} \left(\frac{[\hat{\beta}]^T \mathbf{z}_0 - [\beta]^T \mathbf{z}_0}{\sqrt{\mathbf{z}_0^T (\mathbf{Z}^T \mathbf{Z})^{-1} \mathbf{z}_0}} \right) \\ & \leq \\ & (1 + \mathbf{z}_0^T (\mathbf{Z}^T \mathbf{Z})^{-1} \mathbf{z}_0) \left[\frac{m(n-r-1)}{n-r-m} F_{m,n-r-m}(\alpha) \right] \end{aligned}$$

Cuối cùng, ta có khoảng dự đoán đồng thời với độ tin cậy $100(1 - \alpha)\%$ là:

$$\mathbf{z}_0 [\hat{\beta}]_{(i)} \pm \sqrt{\frac{m(n-r-1)}{n-r-m} F_{m,n-r-m}(\alpha)} \sqrt{(1 + \mathbf{z}_0^T (\mathbf{Z}^T \mathbf{Z})^{-1} \mathbf{z}_0) \left(\frac{n}{n-r-1} \hat{\sigma}_{ii} \right)}$$

Nhận xét: so sánh hai công thức cho khoảng tin cậy, ta thấy rằng khoảng tin cậy cho giá trị thật của các biến phản hồi rộng hơn khoảng tin cậy của kỳ vọng.

Ví dụ 6.1:

Quay trở lại Ví dụ 5.1, ta bổ sung thêm biến phản hồi thứ hai là Y_2 , chỉ dung lượng của đĩa với các quan sát tương ứng với các biến dự đoán z_1, z_2 là

$$\mathbf{Y}_2 = [301.8 \quad 396.1 \quad 328.2 \quad 307.4 \quad 362.4 \quad 369.5 \quad 229.1]^T$$

Ta tiến hành xác định miền ellipse tin cậy với mức ý nghĩa 5% cho $Y_0 = [Y_{01} \ Y_{02}]$ tương ứng với quan sát vừa thu được là $\mathbf{Z}_0^T = [1 \ 130 \ 7.5]$. Tính toán trên phần mềm cho ta mô hình

$$\hat{\mathbf{Y}}_2 = 14.14 + 2.25z_1 + 5.67z_2$$

Như vậy, $[\hat{\beta}]_{(2)} = [14.14 \ 2.25 \ 5.67]^T$

Từ Ví dụ 5.1 ta có

$$[\hat{\beta}]_{(1)} = [8.42 \ 1.08 \ 42]^T, \quad \mathbf{z}_0^T \beta_{(1)} = 151.97, \quad \mathbf{z}_0^T (\mathbf{Z}^T \mathbf{Z})^{-1} \mathbf{z}_0 = 0.34725$$

Lại có

$$\mathbf{z}_0^T \beta_{(2)} = 14.14 + 2.2511302 + 5.6717.52 = 349.17$$

và

$$n\hat{\Sigma} = \begin{bmatrix} (Y_{(1)} - \mathbf{Z} [\hat{\beta}]_{(1)})^T (Y_{(1)} - \mathbf{Z} [\hat{\beta}]_{(1)}) & (Y_{(1)} - \mathbf{Z} [\hat{\beta}]_{(1)})^T (Y_{(2)} - \mathbf{Z} [\hat{\beta}]_{(2)}) \\ (Y_{(2)} - \mathbf{Z} [\hat{\beta}]_{(2)})^T (Y_{(1)} - \mathbf{Z} [\hat{\beta}]_{(1)}) & (Y_{(2)} - \mathbf{Z} [\hat{\beta}]_{(2)})^T (Y_{(2)} - \mathbf{Z} [\hat{\beta}]_{(2)}) \end{bmatrix} = \begin{bmatrix} 5.80 & 5.30 \\ 5.30 & 13.13 \end{bmatrix}$$

Bởi vì,

$$[\hat{\beta}]^T \mathbf{z}_0 = \begin{bmatrix} [\hat{\beta}]_{(1)}^T \mathbf{z}_0 \\ [\hat{\beta}]_{(2)}^T \mathbf{z}_0 \end{bmatrix} = \begin{bmatrix} 151.97 \\ 349.17 \end{bmatrix}$$

Với $n = 7, r = 2, m = 2$, miền ellipse tin cậy với mức ý nghĩa 5% cho $[\hat{\beta}]^T \mathbf{z}_0$ là tập các điểm trên mặt phẳng thỏa mãn

$$\frac{4}{7} \begin{bmatrix} \mathbf{z}_0^T \beta_{(1)} - 151.97 \\ \mathbf{z}_0^T \beta_{(2)} - 349.17 \end{bmatrix}^T \begin{bmatrix} 5.80 & 5.30 \\ 5.30 & 13.13 \end{bmatrix}^{-1} \begin{bmatrix} \mathbf{z}_0^T \beta_{(1)} - 151.97 \\ \mathbf{z}_0^T \beta_{(2)} - 349.17 \end{bmatrix} \leq (0.347252) \left(\frac{2(4)}{3} F_{2,3}(0.05) \right)$$

trong đó, $F_{2,3}(0.05) = 9.55$. Ta xác định được tâm của ellipse là $(151.97, 349.17)$. Còn độ dài trục lớn và trục bé có thể được xác định dựa vào giá trị riêng và vector riêng của $n\hat{\Sigma}$.

3

ỨNG DỤNG HỒI QUY TUYẾN TÍNH DỰ BÁO GIÁ NHÀ ĐẤT

3.1. Mô tả bài toán

3.1.1. Đặt vấn đề

Chúng ta nhìn vào vấn đề của một đại lý bất động sản. Người mới vào nghề sẽ không thể nhìn qua là biết ngay giá trị của một căn hộ thông qua các thuộc tính bên ngoài. Để giúp người mới có thể làm được điều này, ta cần viết một thuật toán nhỏ có thể ước tính giá trị của một căn hộ trong khu vực của bạn dựa trên diện tích, khu đô thị, số giường ngủ,... và những dữ liệu về các căn hộ tương tự đã bán. Ta tìm dữ liệu về giao dịch đã bán trong thành phố nào đó với khoảng thời gian cụ thể. Đối với mỗi căn hộ, ta viết ra một số liệu chi tiết gồm: số phòng ngủ, diện tích, khu đô thị,... và quan trọng nhất là giá bán cuối cùng. Và sử dụng thuật toán đó, ta sẽ có được giá của bất kỳ căn nhà nào mà ta muốn báo giá. Đây là **học có giám sát** mà ta đã nhắc đến ở phần giới thiệu về thuật toán của học máy.

Nhưng nếu bạn không biết giá của các căn hộ đó thì sao? Thì với học máy, ta vẫn hoàn toàn có thể dự báo giá nhà được. Đó là **học không giám sát**.

Đề án này nhằm xây dựng mô hình dự báo giá nhà dựa trên một số các thuộc tính được xác định thông qua tin bất động sản đã được đăng trên mạng. Ta sẽ sử dụng thuật toán **hồi quy tuyến tính** trong **học có giám sát** của học máy để nhận diện vào các đặc điểm của ngôi nhà, qua đó trả về một giá trị cụ thể của căn nhà đó.

3.1.2. Bài toán

Trong dữ liệu của bài toán dự báo giá nhà, ta quan tâm đến giá nhà, diện tích, số phòng ngủ,... Ví dụ Y là giá nhà hiện nay, khi đó Y phụ thuộc vào các yếu tố:

- Z_1 là diện tích ngôi nhà
- Z_2 là vị trí vùng (khoảng cách đến trung tâm thành phố)
- Z_3 là số lượng phòng ngủ

- Z_4 là số lượng phòng khách
- ...

Khi đó, ta có mô hình hồi quy tuyến tính của giá nhà như sau:

$$Y = \beta_0 + \beta_1 Z_1 + \cdots + \beta_k Z_k + \varepsilon$$

giống như mô hình hồi quy tuyến tính cổ điển.

3.2. Xây dựng bộ dữ liệu

3.2.1. Tiến hành phân tích hồi quy

Để xây dựng một mô hình hồi quy tuyến tính hoàn chỉnh, ta làm theo các bước sau:

1. Tiền xử lý dữ liệu: chuẩn hóa tập mẫu $z^* = (z - \bar{z})/s$
2. Xác định các biến quan trọng
 - Ước lượng các hệ số hồi quy: $\hat{\beta} = (\mathbf{Z}^T \mathbf{Z})^{-1} \mathbf{Z}^T \mathbf{Y}$
 - Sử dụng tiêu chuẩn F , kiểm tra mối liên hệ giữa $\mathbf{Z}$ và Y
 - Xác định hệ số R , t -statistic, p -value của từng biến Z_i
 - Lựa chọn các biến quan trọng, loại bỏ biến không cần thiết
 - Lặp lại tới khi nào thỏa mãn điều kiện mà ta đặt ra
3. Khảo sát phần dư
 - Sử dụng tiêu chuẩn Student, kiểm tra các sai số ε
 - Khảo sát phần dư, xác định các outlier
 - Xác định các giá trị Leverage
 - Loại bỏ các outlier dựa vào các giá trị Leverage vừa tìm được
4. Xây dựng mô hình
 - Ước lượng lại hệ số hồi quy và khoảng tin cậy
 - Xác định hệ số R
 - Ước lượng hàm hồi quy tuyến tính

3.2.2. Mô tả bộ dữ liệu

Trong đồ án I của em, em tập trung vào việc tìm hiểu mô hình hồi quy tuyến tính, sử dụng thuật toán học máy để dự báo giá nhà đất. Mức tìm hiểu dừng lại ở giới thiệu chứ không đi sâu vào phân tích dữ liệu và chạy chương trình. Cho nên, bộ dữ liệu mà em xây dựng sẽ có quy mô rất nhỏ. Vì quy mô dữ liệu nhỏ nên, ta không cần bước chuẩn hóa dữ liệu và loại bỏ các biến ít quan trọng. Điều này đồng nghĩa với việc ta không cần phải khảo sát phần dư.

File dữ liệu mà em dùng để phân tích hồi quy: **House-Price-HaNoi**

Trong phần xử lý dữ liệu, em có tham khảo sách "Solving Data Mining Problems Through Pattern Recognition" từ trang 102-111 của tác giả Kenney, Yuchun Lee, Benjamin Van Roy, Christopher D. Reed, Richard P. Lippmann để tìm hiểu về xử lý dữ liệu trước khi đưa vào thuật toán.

Mô tả bộ dữ liệu

- File CSV trên chứa thông tin về các bất động sản như số phòng ngủ, số phòng tắm, tuổi các căn hộ,... và giá bán tương ứng của nó.
- File dữ liệu em đã xử lý gồm 4549 bản ghi, 6 thuộc tính và kích cỡ là 228KB.

Dưới đây là hình ảnh bảng dữ liệu mô tả 20 bản ghi đầu tiên mà em đã định dạng lại:

1	Avg. Area Income	House Age	Number of Rooms	Number of Bedrooms	Area Population	Price
2	79545.45857	5.68	7.01	3.09	23086.8005	1059033.558
3	79248.64245	6	6.73	2.09	40173.07217	1505890.915
4	61287.06718	5.87	8.51	4.13	36882.1594	1058987.988
5	63345.24005	7.19	5.59	2.26	34310.24283	1260616.807
6	59982.19723	5.04	7.84	3.23	26354.10947	630943.4893
7	80175.75416	4.99	6.1	3.04	26748.42842	1068138.074
8	64698.46343	6.03	8.15	2.41	60828.24909	1502055.817
9	78394.33928	6.99	6.62	1.42	36516.35897	1573936.564
10	59927.66081	5.36	6.39	1.3	29387.396	798869.5328
11	81885.92718	4.42	8.17	5.1	40149.96575	1545154.813
12	80527.47208	8.09	5.04	3.1	47224.35984	1707045.722
13	50593.6955	4.5	7.47	3.49	34343.99189	663732.3969
14	39033.80924	7.67	7.25	2.1	39220.36147	1042814.098
15	73163.66344	6.92	5.99	1.27	32326.12314	1291331.518
16	69391.38018	5.34	8.41	3.37	35521.29403	1402818.21
17	73091.86675	5.44	8.52	3.01	23929.52405	1306674.66
18	79706.96306	5.07	8.22	2.12	39717.81358	1556786.6
19	61929.07702	4.79	5.1	3.3	24595.9015	528485.2467
20	63508.1943	5.95	7.19	4.12	35719.65305	1019425.937
21	62085.2764	5.74	7.09	4.49	44922.1067	1030591.429

Hình 3.1: Giá nhà các căn hộ tại Hà Nội

Xét bài toán (P_1):

Giá bán của 20 căn hộ đầu tiên ở Hà Nội, được thẩm định dựa vào thu nhập trung bình của khu vực đó, tuổi của ngôi nhà, số lượng phòng, số lượng phòng tắm, dân số khu vực và cuối cùng là giá bán của từng ngôi nhà. Ta viết dưới dạng bảng như sau:

Avg. Area Income (Z_1)	Age (Z_2)	Rooms (Z_3)	Bedrooms (Z_4)	Area Population (Z_5)	Price (Y)
79545.45857	5.68	7.01	3.09	23086.8005	1059033.558
79248.64245	6	6.73	2.09	40173.07217	1505890.915
61287.06718	5.87	8.51	4.13	36882.1594	1058987.988
63345.24005	7.19	5.59	2.26	34310.24283	1260616.807
59982.19723	5.04	7.84	3.23	26354.10947	630943.4893
80175.75416	4.99	6.1	3.04	26748.42842	1068138.074
64698.46343	6.03	8.15	2.41	60828.24909	1502055.817
78394.33928	6.99	6.62	1.42	36516.35897	1573936.564
59927.66081	5.36	6.39	1.3	29387.396	798869.5328
81885.92718	4.42	8.17	5.1	40149.96575	1545154.813
80527.47208	8.09	5.04	3.1	47224.35984	1707045.722
50593.6955	4.5	7.47	3.49	34343.99189	663732.3969
39033.80924	7.67	7.25	2.1	39220.36147	1042814.098
73163.66344	6.92	5.99	1.27	32326.12314	1291331.518
69391.38018	5.34	8.41	3.37	35521.29403	1402818.21
73091.86675	5.44	8.52	3.01	23929.52405	1306674.66
79706.96306	5.07	8.22	2.12	39717.81358	1556786.6
61929.07702	4.79	5.1	3.3	24595.9015	528485.2467
63508.1943	5.95	7.19	4.12	35719.65305	1019425.937
62085.2764	5.74	7.09	4.49	44922.1067	1030591.429

Sau đây, em sẽ áp dụng lý thuyết về mô hình hồi quy tuyến tính để từ tập dữ liệu này, xây dựng một hàm sử dụng cho việc định giá một bất động sản (giá nhà) bất kì trong tương lai. Chúng ta chuyển sang phần tiếp theo, đó là **kiểm nghiệm thuật toán và áp dụng**.

3.3. Kiểm nghiệm thuật toán và áp dụng

Ta tiến hành tìm mô hình hồi quy của bài toán (P_1) bằng hồi quy tuyến tính. Giả sử các thuộc tính này tuân theo mô hình tuyến tính cổ điển, khi đó:

$$Y = \beta_0 + \beta_1 Z_1 + \beta_2 Z_2 + \beta_3 Z_3 + \beta_4 Z_4 + \beta_5 Z_5 + \varepsilon$$

Ta có:

$$\mathbf{Z} = \begin{bmatrix} 1 & 79545.45857 & 5.68 & 7.01 & 3.09 & 23086.8005 \\ 1 & 79248.64245 & 6 & 6.73 & 2.09 & 40173.07217 \\ 1 & 61287.06718 & 5.87 & 8.51 & 4.13 & 36882.1594 \\ 1 & 63345.24005 & 7.19 & 5.59 & 2.26 & 34310.24283 \\ 1 & 59982.19723 & 5.04 & 7.84 & 3.23 & 26354.10947 \\ 1 & 80175.75416 & 4.99 & 6.1 & 3.04 & 26748.42842 \\ 1 & 64698.46343 & 6.03 & 8.15 & 2.41 & 60828.24909 \\ 1 & 78394.33928 & 6.99 & 6.62 & 1.42 & 36516.35897 \\ 1 & 59927.66081 & 5.36 & 6.39 & 1.3 & 29387.396 \\ 1 & 81885.92718 & 4.42 & 8.17 & 5.1 & 40149.96575 \\ 1 & 80527.47208 & 8.09 & 5.04 & 3.1 & 47224.35984 \\ 1 & 50593.6955 & 4.5 & 7.47 & 3.49 & 34343.99189 \\ 1 & 39033.80924 & 7.67 & 7.25 & 2.1 & 39220.36147 \\ 1 & 73163.66344 & 6.92 & 5.99 & 1.27 & 32326.12314 \\ 1 & 69391.38018 & 5.34 & 8.41 & 3.37 & 35521.29403 \\ 1 & 73091.86675 & 5.44 & 8.52 & 3.01 & 23929.52405 \\ 1 & 79706.96306 & 5.07 & 8.22 & 2.12 & 39717.81358 \\ 1 & 61929.07702 & 4.79 & 5.1 & 3.3 & 24595.9015 \\ 1 & 63508.1943 & 5.95 & 7.19 & 4.12 & 35719.65305 \\ 1 & 62085.2764 & 5.74 & 7.09 & 4.49 & 44922.1067 \end{bmatrix}$$

Cặp giả thuyết:

$$H_0 : \beta_1 = \beta_2 = \dots = \beta_k = 0 \quad \text{và} \quad H_1 : \exists \beta_j \neq 0 \text{ với } j = \overline{1, k} \text{ với mức ý nghĩa } 1\%$$

Ta tính được:

$$\mathbf{Z}^T \mathbf{Z} = \begin{bmatrix} 20 & 1361522.1 & 117.08 & 141.39 & 58.44 & 711957.912 \\ 1361522.1 & 95185583244.9 & 7954149.2 & 9603352.3 & 3976658.1 & 48423130027.7 \\ 117.08 & 7954149.3 & 705.7 & 818.4 & 332.9 & 4229221.5 \\ 141.39 & 9603352.3 & 818.4 & 1023.1 & 420.6 & 5063342.2 \\ 58.44 & 3976658.1 & 332.9 & 420.7 & 192.1 & 2088662.2 \\ 711957.9 & 48423130027.7 & 4229221.5 & 5063342.2 & 2088662.2 & 26907140945.7 \end{bmatrix}$$

$$(\mathbf{Z}^T \mathbf{Z})^{-1} = \begin{bmatrix} 1122558898 & -3707.214 & -76168209 & -57264257 & -27645912 & 1862.849 \\ -3707.214 & 0.041 & 83.172 & 70.775 & 15.864 & -0.004 \\ -76168209 & 83.172 & 9194988 & 3334883 & 2990905 & -439.259 \\ -57264257 & 70.775 & 3334883 & 6139903 & -611610 & -244.261 \\ -27645912 & 15.864 & 2990905 & -61161 & 6268673 & -138.662 \\ 1862.849 & -0.004 & -439.259 & -244.261 & -138.662 & 0.087 \end{bmatrix} \times 10^{-8}$$

$$\hat{\beta} = (\mathbf{Z}^T \mathbf{Z})^{-1} \mathbf{Z}^T \mathbf{Y} = \begin{bmatrix} -2352080.633 \\ 21.387 \\ 153050.466 \\ 109609.500 \\ -30003.699 \\ 13.783 \end{bmatrix}$$

Từ đây, ta được phương trình hồi quy tuyến tính mẫu là:

$$\hat{\mathbf{Y}} = -2352080.633 + 21.387Z_1 + 153050.466Z_2 + 109609.500Z_3 - 30003.699Z_4 + 13.783Z_5$$

$$\hat{\mathbf{Y}} = \mathbf{Z}(\mathbf{Z}^T \mathbf{Z})^{-1} \mathbf{Z}^T \mathbf{Y} = \begin{bmatrix} 1212319.428 \\ 1489766.751 \\ 1174270.294 \\ 1120911.835 \\ 827784.832 \\ 1072419.534 \\ 1613920.850 \\ 1580659.734 \\ 816376.839 \\ 1371557.694 \\ 1718638.633 \\ 606120.074 \\ 928866.856 \\ 1335770.792 \\ 1259562.026 \\ 1217092.966 \\ 1513374.805 \\ 504495.120 \\ 1073609.010 \\ 1115815.304 \end{bmatrix} \quad \hat{\boldsymbol{\varepsilon}} = \mathbf{Y} - \mathbf{Z}\hat{\boldsymbol{\beta}} = \begin{bmatrix} -153285.870 \\ 16124.164 \\ -115282.306 \\ 139704.972 \\ -196841.343 \\ -4281.460 \\ -111865.033 \\ -6723.170 \\ -17507.307 \\ 173597.119 \\ -11592.911 \\ 57612.323 \\ 113947.242 \\ -44439.274 \\ 143256.184 \\ 89581.694 \\ 43411.795 \\ 23990.126 \\ -54183.073 \\ -85223.875 \end{bmatrix}$$

Ta tính các hệ số:

1. $\bar{y} = \sum_{r=1}^n y_r / n = 1177666.669$
2. $\sum_{r=1}^n (y_r - \bar{y})^2 = 2249117535527.26$
3. $s^2 = \frac{1}{n-r-1} \sum_{j=1}^n \hat{\varepsilon}_j^2 = 14139212152.802$

Từ đó, ta tính được:

1. Tổng bình phương các phần dư: $\sum_{k=1}^n \hat{\varepsilon}_k^2 = \sum_{k=1}^n y_k^2 - \mathbf{Y}^T \mathbf{Z} \hat{\beta} = 197948970326.75$

2. Bình phương hệ số xác định: $R^2 = 1 - \frac{\sum_{k=1}^n \hat{\varepsilon}_k^2}{\sum_{k=1}^n (y_k - \bar{y})^2} = 1 - 0.088 = 0.912$

3. F-score: $F = \frac{(n-k-1)R^2}{k(1-R^2)} = \frac{(20-5-1)0.912}{5(1-0.912)} = 29.018$

Có: $F_{4,15}(0.01) = 4.56 \rightarrow F > F_{4,15}(0.01)$

$\Rightarrow$ Với mức ý nghĩa 1%, ta được $F_{4,15}(0.01) < F$. Do đó, ta bác bỏ giả thuyết H_0 , tức là bài toán có sự phụ thuộc vào các biến độc lập.

4. Từ giá trị của s^2 , ta tính lần lượt các giá trị sau:

$$(s^2(\mathbf{Z}^T \mathbf{Z})^{-1})_{11} = 14139212152.802 \times 11.22558898779$$

$$(s^2(\mathbf{Z}^T \mathbf{Z})^{-1})_{22} = 14139212152.802 \times 0.00000000041$$

$$(s^2(\mathbf{Z}^T \mathbf{Z})^{-1})_{33} = 14139212152.802 \times 0.09194988002$$

$$(s^2(\mathbf{Z}^T \mathbf{Z})^{-1})_{44} = 14139212152.802 \times 0.06139903522$$

$$(s^2(\mathbf{Z}^T \mathbf{Z})^{-1})_{55} = 14139212152.802 \times 0.06268673491$$

$$(s^2(\mathbf{Z}^T \mathbf{Z})^{-1})_{66} = 14139212152.802 \times 0.00000000087$$

Và với $t_{14}(0.005) = 2.977$, ta có khoảng tin cậy đồng thời mức 99% của các hệ số hồi quy là:

$$\hat{\beta}_0 \pm t_{14}(0.005) \sqrt{(s^2(\mathbf{Z}^T \mathbf{Z})^{-1})_{(1)(1)}} = -2352080.633 \pm 398398.022$$

$$\hat{\beta}_1 \pm t_{14}(0.005) \sqrt{(s^2(\mathbf{Z}^T \mathbf{Z})^{-1})_{(2)(2)}} = 21.387 \pm 2.408$$

$$\hat{\beta}_2 \pm t_{14}(0.005) \sqrt{(s^2(\mathbf{Z}^T \mathbf{Z})^{-1})_{(3)(3)}} = 153050.466 \pm 36056.883$$

$$\hat{\beta}_3 \pm t_{14}(0.005) \sqrt{(s^2(\mathbf{Z}^T \mathbf{Z})^{-1})_{(4)(4)}} = 109609.500 \pm 29464.114$$

$$\hat{\beta}_4 \pm t_{14}(0.005) \sqrt{(s^2(\mathbf{Z}^T \mathbf{Z})^{-1})_{(5)(5)}} = -30003.699 \pm 29771.48$$

$$\hat{\beta}_5 \pm t_{14}(0.005) \sqrt{(s^2(\mathbf{Z}^T \mathbf{Z})^{-1})_{(6)(6)}} = 13.783 \pm 12.301$$

5. Tiếp theo, ta sẽ kiểm định giả thuyết $H_0 : \hat{\beta}_{(2)} = [\beta_2 \quad \beta_3 \quad \beta_4]^T = 0$

$$\text{với ma trận } \mathbf{C} = \begin{bmatrix} \mathbf{0}_{2 \times 4} & \mathbf{I}_{2 \times 2} \end{bmatrix}$$

Ta tính các giá trị sau:

$$\mathbf{C}\hat{\beta} = \begin{bmatrix} -30003.699 \\ 13.783 \end{bmatrix} \quad \mathbf{C}(\mathbf{Z}^T \mathbf{Z})^{-1} \mathbf{C}^T = \begin{bmatrix} 0.0626867349 & -0.0000013866 \\ -0.0000013866 & 0.0000000009 \end{bmatrix}$$

Từ đó, ta có:

$$\frac{(\mathbf{C}\hat{\beta})^T (\mathbf{C}(\mathbf{Z}^T \mathbf{Z})^{-1} \mathbf{C}^T)^{-1} \mathbf{C}\hat{\beta}}{s^2} = 53.254$$

$$\text{Lại có: } (5-3)F_{2,14}(\alpha) = 6.51$$

Ta thấy, $\frac{(\mathbf{C}\hat{\beta})^T (\mathbf{C}(\mathbf{Z}^T \mathbf{Z})^{-1} \mathbf{C}^T)^{-1} \mathbf{C}\hat{\beta}}{s^2} > (5-3)F_{2,14}(\alpha)$ cho nên ta bác bỏ giả thuyết H_0 với mức ý nghĩa 1%. Hay nói cách khác, với xác suất sai lầm là 1%, thì giá của ngôi nhà sẽ phụ thuộc tuyến tính vào ít nhất 1 trong 3 yếu tố là tuổi ngôi nhà, số phòng và số phòng tắm.

6. Cuối cùng, ta sẽ tiến hành ước lượng hàm hồi quy tuyến tính tại một vector $\mathbf{z}_0$

$$\text{Cho } \mathbf{z}_0 = [1 \quad 86294.99909 \quad 6.63 \quad 8.01 \quad 3.07 \quad 47560.77534]^T$$

Ta có:

$$\mathbf{z}_0^T \hat{\beta} = 1949610.145, \quad s^2 = 14139212152.802, \quad \mathbf{z}_0^T (\mathbf{Z}^T \mathbf{Z})^{-1} \mathbf{z}_0 = 0.367$$

Do đó, khoảng tin cậy đồng thời mức 99% của hàm hồi quy tuyến tính tại $\mathbf{z}_0$ là

$$\mathbf{z}_0^T \hat{\beta} \pm t_{n-r-1} \left(\frac{\alpha}{2} \right) \sqrt{s^2 \mathbf{z}_0^T (\mathbf{Z}^T \mathbf{Z})^{-1} \mathbf{z}_0} = 1949610.145 \pm 214449.221.$$

và khoảng dự đoán mức 99% của quan sát mới Y_0 tại $\mathbf{z}_0$ là:

$$Y_0 = \mathbf{z}_0^T \hat{\boldsymbol{\beta}} \pm t_{n-r-1} \left(\frac{\alpha}{2} \right) \sqrt{s^2 (1 + \mathbf{z}_0^T (\mathbf{Z}^T \mathbf{Z})^{-1} \mathbf{z}_0)} = 1949610.145 \pm 413881.198.$$

Như vậy, $Y_0 \in (1535728.947, 2363491.343)$

Đối chiếu với kết quả ta tổng hợp được trong file dữ liệu, ta thấy thực tế

$Y_0 = 2146925.34$ nằm trong khoảng giá trị trên.

Avg. Area Income	House Age	Number of Rooms	Number of Bedrooms	Area Population	Price
86294.99909	6.63	8.01	3.07	47560.77534	2146925.34

Hình 3.2: Thông số trong file dữ liệu

Qua đó, ta có thể kết luận phần nào tính đúng đắn của thuật toán trong việc xây dựng mô hình hồi quy tuyến tính để dự đoán giá nhà. Tuy nhiên, vì chưa chuẩn hóa dữ liệu nên mô hình có mức độ ổn định không cao, khoảng ước lượng còn lớn.

3.4. Đánh giá thuật toán

Hồi quy tuyến tính là một thuật toán khá đơn giản và dễ hiểu. Mô hình cổ điển là một kỹ thuật được sử dụng để mô hình hóa mối quan hệ giữa một biến độc lập đầu vào và biến phụ thuộc đầu ra bằng mô hình tuyến tính. Trường hợp tổng quát hơn là hồi quy tuyến tính đa biến, trong đó một mô hình được tạo cho mối quan hệ giữa nhiều biến đầu vào độc lập và biến phụ thuộc đầu ra. Mô hình vẫn tuyến tính trong đó đầu ra là sự kết hợp tuyến tính của các biến đầu vào.

Ta có thể đánh giá thuật toán thông qua ưu/nhược điểm của mô hình:

- Ưu điểm

1. Nhanh chóng để mô hình hóa và đặc biệt hữu ích khi mối quan hệ được mô hình hóa không quá phức tạp khi không có nhiều dữ liệu.
2. Thuật toán khá đơn giản và dễ hiểu.
3. Phân tích hồi quy chỉ ra các mối quan hệ đáng kể giữa biến phụ thuộc và biến độc lập; chỉ ra mức độ tác động của nhiều biến độc lập lên một biến phụ thuộc. Như vậy, mô hình này rất có ích trong việc dự báo doanh thu/bất động sản/... Hiển nhiên, doanh nghiệp nào cũng cần thiết có mô hình dự báo.

- Nhược điểm

1. Trong trường hợp dữ liệu quá lớn và phức tạp thì các mô hình hồi quy tuyến tính không tốt như các mô hình khác.
2. Và nhược điểm lớn nhất của thuật toán là "nhạy cảm với nhiễu" (outlier). Tức là nếu ta thêm điểm nhiễu vào bộ dữ liệu, thì điểm đó sẽ kéo lệch đường thẳng tuyến tính ta tìm theo hồi quy tuyến tính khá nhiều, nên sẽ ảnh hưởng đến kết quả.

Vì vậy, trước khi thực hiện thuật toán hồi quy, các nhiễu cần phải được loại bỏ. Ta đã đề cập đến việc này trong phần **kiểm tra mô hình và các khía cạnh khác của hồi quy**.

3. Hồi quy tuyến tính không biểu diễn được các mô hình phức tạp. Mặc dù trong phần trên, chúng ta thấy rằng phương pháp này có thể được áp dụng nếu quan hệ giữa **Y** và **Z** không nhất thiết phải là tuyến tính, nhưng mối quan hệ này vẫn đơn giản nhiều so với các mô hình thực tế. Để dễ so sánh, ta đặt ra câu hỏi: "Làm thế nào để xác định được các hàm $\sin x$, x^3 , $\log(x)$, ...?"

Tổng kết

Phân tích hồi quy tuyến tính là một kỹ thuật thống kê dùng để ước lượng phương trình phù hợp nhất với các tập hợp kết quả quan sát của biến phụ thuộc (hoặc biến phản hồi) và biến độc lập (hoặc biến dự đoán). Nó cho phép đạt được kết quả ước lượng tốt nhất về mối quan hệ chân thực giữa các biến số. Từ phương trình ước lượng được này, người ta có thể dự báo về biến phụ thuộc (chưa biết) dựa vào giá trị cho trước của biến độc lập (đã biết).

Trong đồ án này, em đã tìm hiểu được các nội dung sau:

1. Mô hình hồi quy tuyến tính cổ điển và đa biến
2. Ước lượng khoảng tin cậy cho các hệ số hồi quy
3. Xây dựng được thuật toán hồi quy tuyến tính
4. Cách xử lý dữ liệu khi gặp điểm outlier
5. Kiểm tra các khía cạnh của hồi quy
6. Xây dựng mô hình hồi quy tuyến tính đa bội
7. Ứng dụng hồi quy tuyến tính để dự đoán giá nhà đất
8. Đánh giá thuật toán

Qua quá trình học tập và làm việc dưới sự hướng dẫn của thầy Lê Đình Nam, em đã hoàn thành đồ án I. Trong đồ án này có đầy đủ các nội dung về **hồi quy tuyến tính** trong học máy và **ứng dụng để xây dựng mô hình dự báo giá nhà đất**. Tuy nhiên thiếu sót là điều không tránh khỏi, em mong sẽ nhận được sự góp ý từ thầy.

Cuối cùng, em xin chân thành cảm ơn thầy Lê Đình Nam - giảng viên trực tiếp hướng dẫn đã có thể truyền đạt cũng như liên tục cập nhật thông tin để đảm bảo em luôn được học và tìm hiểu những kiến thức liên quan đến môn học.

Em cảm ơn thầy nhiều ạ!

Tài liệu tham khảo

1. N. J. le Roux, Sugnet Gardner. "Analysing Your Multivariate Data as a Pictorial: A Case for Applying Biplot Methodology", International Statistical Review, 73 (2005).
2. Richard Johnson, Dean Wichern. "Applied Multivariate Statistical Analysis", Pearson New International Edition, 7 (2014).
3. Gareth James, Daniela Witten, Trevor Hastie Robert, Tibshirani. "Introduction to statistical learning", (2014).
4. Kenney, Yuchun Lee, Benjamin Van Roy, Christopher D. Reed, Richard P Lippmann. "Solving Data Mining Problems Through Pattern Recognition", Upper Saddle River, NJ: Prentice-Hall, (1997).