



## Bao cao - hust

Hóa học đại cương (Trường Đại học Bách khoa Hà Nội)



Scan to open on Studeersnel

TRƯỜNG ĐẠI HỌC BÁCH KHOA HÀ NỘI  
VIỆN TOÁN ỨNG DỤNG VÀ TIN HỌC

—o0o—



## ĐỒ ÁN II

# HỒI QUY TUYẾN TÍNH VÀ ỨNG DỤNG DỰ BÁO GIÁ NHÀ ĐẤT

Chuyên ngành: TOÁN TIN

Chuyên sâu: TOÁN ỨNG DỤNG

Giảng viên hướng dẫn: TS. Lê Đình Nam

Chữ kí của GVHD

Sinh viên thực hiện: Phan Tiến Đạt

Mã số sinh viên: 20195854

Lớp: Toán Tin 02 - K64

HÀ NỘI, 1/2024

# NHẬN XÉT CỦA GIẢNG VIÊN HƯỚNG DẪN

1. Mục đích và nội dung của đề án

2. Kết quả đạt được

3. Ý thức làm việc của sinh viên

*Hà Nội, ngày      tháng 01 năm 2024*

*Giảng viên hướng dẫn*

*(Ký và ghi rõ họ tên)*

## LỜI MỞ ĐẦU

Trong đề án II, em đã tập trung nghiên cứu về học máy và đặc biệt là thuật toán hồi quy tuyến tính. Học máy là một lĩnh vực đang phát triển mạnh mẽ, liên quan chặt chẽ đến trí tuệ nhân tạo và công nghệ. Thuật ngữ này đề cập đến khả năng của chương trình tự học từ dữ liệu và đưa ra dự đoán, dự báo mới. Độ chính xác của dự báo phụ thuộc vào số lượng và chất lượng dữ liệu đầu vào.

Trong quá trình nghiên cứu, em đã tập trung vào mô hình hồi quy tuyến tính. Đây là một phương pháp đơn giản và dễ hiểu trong học máy. Hồi quy tuyến tính giúp mô hình hóa mối quan hệ giữa biến độc lập và biến phụ thuộc để dự đoán giá trị mới. Điểm mạnh của hồi quy tuyến tính là tính ứng dụng rộng rãi trong nhiều lĩnh vực như tài chính, kinh tế, y học, và khoa học xã hội.

Trong đề án, em áp dụng thuật toán hồi quy tuyến tính để dự đoán giá nhà đất tại Hà Nội. Đây là một ứng dụng thực tiễn có tính chất quan trọng trong thị trường bất động sản. Tuy nhiên, việc dự báo giá nhà đất không phải lúc nào cũng đơn giản và đòi hỏi xử lý cẩn thận các yếu tố phức tạp và nhiễu trong dữ liệu.

Mô hình hồi quy tuyến tính cho phép đánh giá tác động riêng phần của một biến độc lập lên biến phụ thuộc khi biến độc lập khác trong mô hình không đổi. Ngoài ra, việc đưa thêm các biến độc lập thích hợp vào mô hình đồng nghĩa với việc sử dụng thêm thông tin trong việc giải thích sự thay đổi của biến phụ thuộc, do đó cải thiện chất lượng dự báo của mô hình.

Em xin gửi lời cảm ơn sâu sắc tới **TS. Lê Đình Nam**, người giảng viên đã tận tình chỉ bảo, luôn theo dõi sát sao và giúp đỡ em trong quá trình nghiên cứu. Không có những lời động viên và hướng dẫn của thầy, đề án sẽ không thể hoàn thiện.

Em cũng xin gửi lời cảm ơn đến viện Toán ứng dụng và Tin học, Trường Đại học Bách Khoa Hà Nội đã cung cấp những kiến thức để tạo điều kiện thuận lợi cho em hoàn thành đề án này.

Em xin chân thành cảm ơn!

## TÓM TẮT NỘI DUNG ĐỒ ÁN

Trong đề tài này, em sẽ trình bày về học máy cơ bản và các kiến thức liên quan đến mô hình hồi quy tuyến tính, bao gồm mô hình cổ điển và mô hình hồi quy tuyến tính đa biến. Ngoài ra, em cũng sẽ áp dụng thuật toán này để tính toán và dự báo giá nhà đất tại Hà Nội. Báo cáo sẽ được chia thành các phần sau:

**Chương 1:** Tổng quan về Machine Learning - Ở phần này, em sẽ cung cấp một cái nhìn tổng quan về Machine Learning để giúp người đọc hiểu rõ hơn về chủ đề này.

**Chương 2:** Tổng quan về hồi quy tuyến tính - Tại đây, em sẽ giới thiệu về mô hình hồi quy tuyến tính, bao gồm cả mô hình cổ điển và mô hình hồi quy tuyến tính đa biến.

**Chương 3:** Ứng dụng HQTĐ dự báo giá nhà đất - Phần này sẽ tập trung vào việc áp dụng mô hình hồi quy tuyến tính để dự báo giá nhà đất tại Hà Nội. em sẽ trình bày cách xử lý bộ dữ liệu thực sử dụng thuật toán hồi quy tuyến tính.

**Chương 4:** Tổng kết - Trong phần này, em sẽ tổng kết kết quả và nhận xét của báo cáo thông qua việc ứng dụng thuật toán hồi quy tuyến tính và các bước tính toán. Đồng thời, em sẽ đề xuất các hướng nghiên cứu và ứng dụng tiềm năng cho mô hình trong tương lai.

Cụ thể, em sẽ tìm hiểu sâu hơn về các nội dung sau:

1. Mô hình hồi quy tuyến tính cổ điển và đa biến.
2. Ước lượng khoảng tin cậy cho các hệ số hồi quy.
3. Xây dựng thuật toán hồi quy tuyến tính.
4. Xử lý dữ liệu khi gặp điểm ngoại lệ (outlier).
5. Kiểm tra các khía cạnh của mô hình hồi quy.
6. Xây dựng mô hình hồi quy tuyến tính đa biến.
7. Ứng dụng hồi quy tuyến tính để dự đoán giá nhà đất.
8. Đánh giá hiệu quả của thuật toán.

Hà Nội, ngày 12 tháng 6 năm 2023

Sinh viên thực hiện

**Phan Tiến Đạt**

# MỤC LỤC

|          |                                                                        |          |
|----------|------------------------------------------------------------------------|----------|
| <b>1</b> | <b>HỌC MÁY NÓI CHUNG</b>                                               | <b>1</b> |
| 1.1      | Giới thiệu về học máy . . . . .                                        | 1        |
| 1.2      | Nguyên lý cơ bản của học máy . . . . .                                 | 2        |
| 1.3      | Các mô hình trong học máy . . . . .                                    | 3        |
| 1.4      | Ứng dụng của học máy . . . . .                                         | 3        |
| 1.5      | Thách thức và hướng phát triển của học máy . . . . .                   | 4        |
| 1.6      | Phân loại các thuật toán của học máy . . . . .                         | 5        |
| 1.6.1    | Học máy có giám sát . . . . .                                          | 5        |
| 1.6.2    | Học máy không giám sát . . . . .                                       | 6        |
| 1.6.3    | Học máy nửa giám sát . . . . .                                         | 6        |
| 1.6.4    | Học máy tăng cường . . . . .                                           | 6        |
| 1.6.5    | Học máy bán cấu trúc . . . . .                                         | 6        |
| 1.6.6    | Học máy tương tác . . . . .                                            | 6        |
| <b>2</b> | <b>TỔNG QUAN VỀ HỒI QUY TUYẾN TÍNH</b>                                 | <b>8</b> |
| 2.1      | Giới thiệu . . . . .                                                   | 8        |
| 2.1.1    | Giới thiệu về phương pháp . . . . .                                    | 8        |
| 2.1.2    | Sự cần thiết của mô hình . . . . .                                     | 8        |
| 2.1.3    | Tính tuyến tính trong mô hình . . . . .                                | 9        |
| 2.2      | Mô hình hồi quy tuyến tính cổ điển . . . . .                           | 9        |
| 2.3      | Phương pháp bình phương cực tiểu . . . . .                             | 11       |
| 2.3.1    | Ước lượng bình phương cực tiểu . . . . .                               | 11       |
| 2.3.2    | Tính chất ước lượng bằng phương pháp bình phương cực<br>tiểu . . . . . | 14       |
| 2.3.3    | Định lý Gauss về ước lượng bình phương cực tiểu . . . . .              | 15       |
| 2.3.4    | Hệ số xác định R . . . . .                                             | 16       |
| 2.4      | Ước lượng khoảng của mô hình hồi quy . . . . .                         | 17       |
| 2.4.1    | Khoảng tin cậy của các hệ số hồi quy $\beta_j$ . . . . .               | 17       |
| 2.4.2    | Kiểm định giả thuyết về các hệ số hồi quy . . . . .                    | 21       |

|          |                                                                                 |           |
|----------|---------------------------------------------------------------------------------|-----------|
| 2.5      | Ước lượng hàm hồi quy tuyến tính . . . . .                                      | 24        |
| 2.5.1    | Ước lượng hàm hồi quy tại $z_0$ . . . . .                                       | 24        |
| 2.5.2    | Dự đoán quan sát mới tại $z_0$ . . . . .                                        | 25        |
| 2.6      | Kiểm tra mô hình và các khía cạnh khác của hồi quy . . . . .                    | 29        |
| 2.6.1    | Một số khái niệm . . . . .                                                      | 29        |
| 2.6.2    | Kiểm định tính phụ thuộc vào biến của mô hình . . . . .                         | 30        |
| 2.6.3    | Kiểm tra tính đa cộng tuyến của các biến dự đoán và cách<br>khắc phục . . . . . | 32        |
| 2.6.4    | Khảo sát phần dư . . . . .                                                      | 34        |
| 2.7      | Mô hình hồi quy tuyến tính đa bội . . . . .                                     | 36        |
| 2.7.1    | Mô hình bài toán . . . . .                                                      | 36        |
| 2.7.2    | Ước lượng các tham số . . . . .                                                 | 38        |
| 2.7.3    | Các tính chất quan trọng . . . . .                                              | 42        |
| 2.7.4    | Đưa ra dự đoán từ mô hình hồi quy tuyến tính đa bội . . . . .                   | 45        |
| <b>3</b> | <b>ỨNG DỤNG HỒI QUY TUYẾN TÍNH TRONG DỰ BÁO GIÁ<br/>NHÀ ĐẤT</b>                 | <b>49</b> |
| 3.1      | Mô tả bài toán . . . . .                                                        | 49        |
| 3.1.1    | Đặt vấn đề . . . . .                                                            | 49        |
| 3.1.2    | Bài toán . . . . .                                                              | 50        |
| 3.2      | Xây dựng bộ dữ liệu . . . . .                                                   | 50        |
| 3.2.1    | Các bước tiến hành phân tích hồi quy . . . . .                                  | 50        |
| 3.3      | Mô tả bộ dữ liệu . . . . .                                                      | 51        |
| 3.4      | Cài đặt thuật toán . . . . .                                                    | 54        |
| 3.4.1    | Chương trình . . . . .                                                          | 54        |
| 3.4.2    | Kết quả . . . . .                                                               | 57        |
| 3.5      | Kiểm nghiệm thuật toán và áp dụng . . . . .                                     | 60        |
| 3.6      | Đánh giá thuật toán . . . . .                                                   | 66        |
| <b>4</b> | <b>TỔNG KẾT</b>                                                                 | <b>68</b> |
|          | <b>TÀI LIỆU THAM KHẢO</b>                                                       | <b>68</b> |

# DANH MỤC HÌNH VẼ

|          |                                                     |    |
|----------|-----------------------------------------------------|----|
| Hình 1.1 | Học máy là ứng dụng của trí tuệ nhân tạo. . . . .   | 1  |
| Hình 3.1 | Dữ liệu đầu vào. . . . .                            | 57 |
| Hình 3.2 | Hệ số hồi quy. . . . .                              | 57 |
| Hình 3.3 | Hệ số $R$ . . . . .                                 | 58 |
| Hình 3.4 | Các điểm dữ liệu bất thường. . . . .                | 58 |
| Hình 3.5 | Giá trị $\mathbf{Y}$ dự đoán. . . . .               | 58 |
| Hình 3.6 | Giá trị $\mathbf{Y}$ thực tế. . . . .               | 59 |
| Hình 3.7 | Giá trị sai số của mô hình. . . . .                 | 59 |
| Hình 3.8 | So sánh giá trị dự đoán và giá trị thực tế. . . . . | 60 |
| Hình 3.9 | Thống số bản ghi trong file dữ liệu. . . . .        | 66 |



## DANH MỤC BẢNG BIỂU

|          |                                                 |    |
|----------|-------------------------------------------------|----|
| Bảng 2.1 | Computer Data . . . . .                         | 27 |
| Bảng 2.2 | Tuổi thọ của 7 loại CPU . . . . .               | 28 |
| Bảng 2.3 | Doanh thu . . . . .                             | 32 |
| Bảng 3.1 | Bảng dữ liệu của 25 ngôi nhà đầu tiên . . . . . | 53 |

# DANH MỤC KÍ HIỆU VÀ CHỮ VIẾT TẮT


## Từ viết tắt Ý nghĩa

|      |                           |
|------|---------------------------|
| HQTT | Hồi quy tuyến tính        |
| AI   | Artificial intelligence   |
| ML   | Machine Learning          |
| SVM  | Support Vector Machine    |
| ANN  | Artificial Neural Network |
| RNN  | Recurrent Neural Networks |
| DL   | Deep Learning             |

# CHƯƠNG 1. HỌC MÁY NÓI CHUNG

## 1.1 Giới thiệu về học máy

- Trí Tuệ Nhân Tạo (AI) và học máy đã vượt qua những bước đột phá quan trọng trong những năm gần đây và trở thành những xu hướng công nghệ quan trọng, ảnh hưởng sâu sắc đến mọi khía cạnh của cuộc sống và xã hội. Trong bối cảnh mà công nghệ thông tin phát triển mạnh mẽ và việc thu thập dữ liệu ngày càng tăng, AI và học máy đã đóng vai trò không thể thiếu trong việc khai thác và tận dụng dữ liệu một cách hiệu quả.
- Học máy, là một nhánh của trí tuệ nhân tạo, tập trung vào việc phát triển các chương trình máy tính có khả năng tự học hỏi và cải thiện từ kinh nghiệm mà không cần lập trình rõ ràng. Thay vì chỉ dựa vào các quy tắc lập trình cố định, học máy tạo ra các mô hình dự đoán và phân loại dựa trên dữ liệu đầu vào và thuật toán, giúp máy tính tự động học hỏi và cải thiện theo thời gian.



Hình 1.1 Học máy là ứng dụng của trí tuệ nhân tạo.

- Các ứng dụng của học máy và AI đã lan rộng vào nhiều lĩnh vực khác nhau, từ công nghiệp, y tế, tài chính, thương mại điện tử, giáo dục, đến nông nghiệp và năng lượng. Các hệ thống học máy hiện nay không chỉ có khả năng dự đoán giá nhà, tiền lương, doanh số bán hàng, mà còn giúp trong việc chẩn đoán bệnh, phân loại hình ảnh, xử lý ngôn ngữ tự nhiên, và nhiều nhiệm vụ phức tạp khác.
- Một trong những phát triển quan trọng của học máy là Deep Learning. Deep Learning sử dụng các mạng neural nhân tạo sâu để học hỏi các đặc trưng phức tạp từ dữ liệu đầu vào và tạo ra các mô hình mạnh mẽ có thể hiểu và biểu diễn dữ liệu một cách sâu sắc. Điều này đã mang lại những tiến bộ ấn tượng trong việc nhận dạng ảnh, nhận dạng giọng nói, xử lý ngôn ngữ tự nhiên, và nhiều ứng dụng khác.
- Tuy nhiên, việc triển khai học máy và AI cũng đặt ra những thách thức về đạo đức và an ninh thông tin. Cần phải đảm bảo rằng các thuật toán và mô hình được xây dựng một cách công bằng và không gây phân biệt đối xử. Đồng thời, việc bảo vệ thông tin cá nhân và đảm bảo an toàn thông tin là vô cùng quan trọng trong việc sử dụng AI và học máy.
- Tương lai của AI và học máy hứa hẹn còn rất sáng sủa và đầy triển vọng. Với sự phát triển của công nghệ và tăng cường năng lực tính toán, chúng ta có thể kỳ vọng rằng học máy và AI sẽ tiếp tục đóng vai trò quan trọng trong việc giải quyết các thách thức và mang lại lợi ích lớn cho con người và xã hội.

## 1.2 Nguyên lý cơ bản của học máy

- Trong học máy, mô hình máy tính được xây dựng để học từ dữ liệu mà không cần được lập trình một cách rõ ràng. Thay vào đó, mô hình sẽ tự động phân tích và tìm hiểu các mẫu, quy tắc và kiến thức từ dữ liệu đầu vào. Quá trình này được thực hiện thông qua việc sử dụng các thuật toán và kỹ thuật học máy phù hợp.
- Học máy có hai hướng tiếp cận chính: học có giám sát và học không giám sát. Trong học có giám sát, mô hình được huấn luyện bằng cách sử dụng các cặp dữ liệu huấn luyện gồm đầu vào và đầu ra tương ứng. Mô hình sẽ học từ các ví dụ này và cố gắng tạo ra một quy luật chung để dự đoán kết quả cho các đầu vào mới.

- Trong học không giám sát, mô hình không có thông tin về đầu ra mong muốn. Thay vào đó, mục tiêu là tìm ra cấu trúc và thông tin hữu ích từ dữ liệu đầu vào. Các phương pháp học không giám sát thường được sử dụng trong việc gom nhóm, giảm chiều dữ liệu và phân tích khám phá.

## 1.3 Các mô hình trong học máy

Có nhiều mô hình khác nhau trong học máy, mỗi cái có ưu điểm và hạn chế riêng. Dưới đây là một số mô hình quan trọng trong học máy:

- Hồi quy tuyến tính: Sử dụng để dự đoán một giá trị số dựa vào các biến đầu vào. Thuật toán này tạo ra một mô hình tuyến tính và tìm cách tối thiểu hóa sai số giữa các giá trị dự đoán và các giá trị thực tế.
- Máy vector hỗ trợ (SVM): Được sử dụng cho các bài toán phân loại và hồi quy. SVM tìm cách xác định một ranh giới tối ưu giữa các điểm dữ liệu để phân chia chúng vào các lớp khác nhau. Thuật toán này rất hiệu quả trong việc xử lý dữ liệu có số chiều cao.
- Mạng neural nhân tạo (ANN): Lấy cảm hứng từ cấu trúc não của con người, ANN là một mô hình toàn diện trong học máy. Nó bao gồm một mạng lưới các đơn vị tính toán (neuron) được kết nối với nhau. ANN được sử dụng rộng rãi trong nhiều ứng dụng như nhận dạng hình ảnh, xử lý ngôn ngữ tự nhiên và dự đoán.
- Cây quyết định: Cây quyết định là một cấu trúc cây được sử dụng để đưa ra quyết định dựa trên các điều kiện. Các quyết định được đưa ra thông qua việc đi qua các nút quyết định và nhánh của cây. Cây quyết định thường dễ hiểu và có thể mô hình hóa quyết định phức tạp.
- Mạng nơ-ron hồi quy (RNN): RNN được sử dụng trong xử lý dữ liệu tuần tự, như dữ liệu thời gian hoặc văn bản. Mô hình này có khả năng lưu trữ thông tin từ quá khứ và sử dụng nó để dự đoán tương lai. RNN có ưu điểm là có khả năng xử lý dữ liệu dạng chuỗi và mối quan hệ phụ thuộc thời gian.

## 1.4 Ứng dụng của học máy

Học máy có nhiều ứng dụng rộng rãi trong thực tế. Dưới đây là một số ví dụ tiêu biểu:

- Nhận dạng hình ảnh: Học máy được sử dụng để nhận dạng đối tượng và mẫu trong hình ảnh, như nhận dạng khuôn mặt, phân loại vật liệu, nhận dạng biển số xe, và phát hiện đối tượng.
- Xử lý ngôn ngữ tự nhiên: Học máy có thể được áp dụng để xử lý ngôn ngữ tự nhiên, bao gồm công việc như dịch thuật tự động, phân loại văn bản, phân tích cảm xúc, và tạo ra văn bản tự động.
- Dự đoán và phân tích: Học máy có thể được sử dụng để dự đoán và phân tích các xu hướng, mẫu, và kết quả từ dữ liệu có sẵn. Ví dụ, trong lĩnh vực tài chính, học máy có thể được sử dụng để dự đoán giá cổ phiếu, phân tích rủi ro tín dụng, và phát hiện gian lận tài chính.
- Tư vấn và cá nhân hóa: Học máy có thể cung cấp tư vấn và cá nhân hóa dựa trên dữ liệu và hành vi người dùng. Ví dụ, trong lĩnh vực thương mại điện tử, học máy có thể đề xuất sản phẩm phù hợp dựa trên lịch sử mua hàng và sở thích của khách hàng.
- Tự động hóa: Học máy có thể được sử dụng để tự động hóa các quy trình và công việc. Ví dụ, trong ngành sản xuất, học máy có thể giúp tối ưu hóa quy trình sản xuất và dự báo nhu cầu nguyên liệu.
- Xử lý và phân tích dữ liệu lớn: Học máy có vai trò quan trọng trong xử lý và phân tích dữ liệu lớn. Với khả năng xử lý và học từ lượng lớn dữ liệu, học máy giúp tìm ra các mẫu, quy tắc và thông tin hữu ích từ dữ liệu không có cấu trúc và đa dạng.

Tóm lại, học máy là một lĩnh vực nghiên cứu quan trọng trong trí tuệ nhân tạo, nó tập trung vào việc phát triển các thuật toán và mô hình tính toán để máy tính có thể học từ dữ liệu và cải thiện hiệu suất của chúng theo thời gian. Học máy có ứng dụng rộng rãi trong nhiều lĩnh vực và đóng vai trò quan trọng trong việc xử lý dữ liệu, dự đoán, tư vấn và tự động hóa các công việc.

## 1.5 Thách thức và hướng phát triển của học máy

Mặc dù học máy đã đạt được những thành tựu đáng kể, nhưng vẫn còn tồn tại một số thách thức và hướng phát triển tiềm năng. Dưới đây là một số điểm đáng chú ý:

- Giới hạn của dữ liệu: Học máy yêu cầu dữ liệu huấn luyện đầy đủ và đại diện cho tất cả các trường hợp có thể xảy ra. Tuy nhiên, việc thu thập và gán nhãn dữ liệu là công việc tốn kém và phức tạp. Do đó, sự thiếu hụt và không đầy đủ dữ liệu có thể gây ảnh hưởng đến hiệu suất của mô hình học máy.
- Giải thích và giám sát: Một trong những thách thức của học máy là khả năng giải thích các quyết định và dự đoán của mô hình. Trong một số trường hợp, mô hình có thể đưa ra dự đoán chính xác nhưng không thể giải thích rõ ràng về cơ sở hoặc quy tắc được sử dụng. Điều này làm cho việc áp dụng học máy trong các lĩnh vực nhạy cảm như y tế và tài chính trở nên khó khăn.
- Đạo đức và trách nhiệm: Học máy đặt ra những thách thức đạo đức và trách nhiệm. Vấn đề như độc tài thông tin, phân biệt đối xử và bảo mật dữ liệu là những yếu tố cần được quan tâm khi triển khai các ứng dụng học máy. Cần có các quy định và hướng dẫn rõ ràng để đảm bảo sự sử dụng đúng đắn và công bằng của công nghệ học máy.
- Hướng phát triển: Có nhiều hướng phát triển tiềm năng trong lĩnh vực học máy. Một trong những hướng này là sự phát triển của học máy gia đình (family of models), trong đó các mô hình khác nhau được kết hợp để tạo ra hiệu suất tốt hơn và đa dạng hơn. Nghiên cứu về học máy không giám sát, học máy tăng cường và học máy mang tính giải thích cũng đang nhận được sự quan tâm rất lớn.

## 1.6 Phân loại các thuật toán của học máy

### 1.6.1 Học máy có giám sát

Thuật toán học máy cần học cách để chuyển đổi mỗi input (đầu vào dữ liệu) thành kết quả đầu ra tương ứng. Do vậy, mọi mẫu dữ liệu trong tập dữ liệu gốc cần phải biết trước kết quả của nó. Học máy có giám sát gồm hai thuật toán chính:

1. Phân loại
2. Hồi quy

Và trong đồ án này, em sẽ tập trung vào việc phân tích thuật toán hồi quy.

### 1.6.2 Học máy không giám sát

Trái ngược với học máy có giám sát, học máy không giám sát không sử dụng nhãn trong quá trình huấn luyện. Mục tiêu của các thuật toán không giám sát là khám phá cấu trúc và mô hình dữ liệu mà không có thông tin nhãn sẵn có. Các phương pháp phổ biến trong học máy không giám sát bao gồm phân cụm (clustering), giảm chiều dữ liệu (dimensionality reduction), và mô hình hỗn hợp (mixture models).

### 1.6.3 Học máy nửa giám sát

Trong học máy nửa giám sát, mô hình được huấn luyện trên một lượng lớn dữ liệu không có nhãn và một phần nhỏ dữ liệu có nhãn. Mục tiêu là sử dụng thông tin từ cả dữ liệu có nhãn và không có nhãn để tạo ra một mô hình dự đoán tốt hơn. Các thuật toán học máy nửa giám sát bao gồm một số phương pháp phân loại nửa giám sát và học sâu nửa giám sát.

### 1.6.4 Học máy tăng cường

Trong học máy tăng cường, mô hình học từ việc tương tác với môi trường và nhận phần thưởng hoặc hình phạt. Mục tiêu là tìm ra cách thức tối ưu hoá hành động trong một môi trường cụ thể để đạt được mục tiêu nhất định. Các thuật toán học máy tăng cường bao gồm Q-Learning, SARSA, Actor-Critic và Deep Q-Network (DQN).

### 1.6.5 Học máy bán cấu trúc

Học máy bán cấu trúc kết hợp các phương pháp học máy với khả năng xử lý dữ liệu bán cấu trúc, tức là dữ liệu có một số cấu trúc như đồ thị, mạng lưới, hoặc dữ liệu dạng văn bản. Các thuật toán trong học máy bán cấu trúc nhằm tìm ra mối quan hệ, mẫu và thông tin từ dữ liệu bán cấu trúc.

### 1.6.6 Học máy tương tác

Học máy tương tác là sự kết hợp giữa con người và máy tính trong quá trình huấn luyện mô hình. Điều này cho phép con người đưa ra thông tin phản hồi và chỉnh sửa quá trình học của mô hình trong thời gian thực. Các phương



pháp học máy tương tác nhằm tận dụng kiến thức và kinh nghiệm của con người để cải thiện hiệu suất và tương tác của mô hình.

# CHƯƠNG 2. TỔNG QUAN VỀ HỒI QUY TUYẾN TÍNH

## 2.1 Giới thiệu

### 2.1.1 Giới thiệu về phương pháp

Phân tích hồi quy là một kỹ thuật thống kê để điều tra và mô hình hóa mối quan hệ giữa các biến. Các ứng dụng của hồi quy rất nhiều và xảy ra trong hầu hết các lĩnh vực, bao gồm kỹ thuật, khoa học, vật lý và hóa học, kinh tế, quản lý, khoa học đời sống, sinh học và khoa học xã hội. Trên thực tế, phân tích hồi quy có thể là kỹ thuật thống kê được sử dụng rộng rãi nhất. Ví dụ: dự đoán tiền lương, giá nhà, ...

Hồi quy tuyến tính có lẽ là công cụ tiêu chuẩn đơn giản và phổ biến nhất được sử dụng cho bài toán hồi quy. Xuất hiện từ đầu thế kỷ 19, hồi quy tuyến tính được phát triển từ một vài giả thuyết đơn giản.

Và ở trong đề án này, em sẽ trình bày ứng dụng của hồi quy tuyến tính dự đoán giá nhà đất tại Hà Nội.

### 2.1.2 Sự cần thiết của mô hình

Mô hình hồi quy tuyến tính cho phép đánh giá tác động riêng phần của một biến độc lập lên biến phụ thuộc khi biến độc lập khác trong mô hình không đổi. Ngoài ra, việc đưa thêm các biến độc lập thích hợp vào mô hình đồng nghĩa với việc sử dụng thêm thông tin trong việc giải thích sự thay đổi của biến phụ thuộc, do đó cải thiện chất lượng dự báo của mô hình.

### 2.1.3 Tính tuyến tính trong mô hình

Tính tuyến tính của hàm hồi quy được hiểu là tuyến tính theo tham số, có nghĩa là tuyến tính ở các hệ số hồi quy và nó có thể tuyến tính hoặc phi tuyến ở các biến  $\mathbf{Z}$  và  $\mathbf{Y}$ . Ví dụ: Mô hình hồi quy sau đây:

$$1. \mathbf{Y} = \beta_1 + \beta_2 \mathbf{Z} + \varepsilon$$

$$2. \log \mathbf{Y} = \beta_1 + \beta_2 \log \mathbf{Z} + \varepsilon$$

đều được hiểu là các mô hình hồi quy tuyến tính, vì chúng đều tuyến tính ở các hệ số hồi quy.

## 2.2 Mô hình hồi quy tuyến tính cổ điển

Mở đầu về chương hồi quy tuyến tính bội (hay còn được gọi là mô hình hồi quy tuyến tính nhiều biến), ta xét mô hình hồi quy tuyến tính cổ điển. Giả sử  $\mathbf{Z}_1, \mathbf{Z}_2, \dots, \mathbf{Z}_k$  là  $k$  biến độc lập dùng để dự báo và  $\mathbf{Y}$  là biến phụ thuộc cần dự báo.

Mô hình hồi quy tuyến tính cổ điển khẳng định rằng  $\mathbf{Y}$  phụ thuộc tuyến tính vào các yếu tố chính  $\mathbf{Z}_i$  theo như phương trình:

$$\mathbf{Y} = \beta_0 + \beta_1 \mathbf{Z}_1 + \dots + \beta_k \mathbf{Z}_k + \varepsilon \quad (2.2.1)$$

Trong đó  $\beta_i$  với  $i = 0, 1, 2, \dots, k$  là các hệ số hồi quy chưa biết,  $\varepsilon$  là sai số ngẫu nhiên. Tiến hành  $n$  quan sát độc lập đồng thời về  $k+1$  biến  $\mathbf{Z}_1, \mathbf{Z}_2, \dots, \mathbf{Z}_k, \mathbf{Y}$ . Mô hình hoàn chỉnh trở thành:

$$y_1 = \beta_{i0} + \beta_{i1}z_{11} + \dots + \beta_{ik}z_{1k} + \varepsilon_1$$

$$y_2 = \beta_{i0} + \beta_{i1}z_{21} + \dots + \beta_{ik}z_{2k} + \varepsilon_2$$

$$\vdots$$

$$y_n = \beta_{i0} + \beta_{i1}z_{n1} + \dots + \beta_{ik}z_{nk} + \varepsilon_n$$



beta i thay vì  
beta i0, beta i1,  
...?

Trong đó:

- $\beta_i$  là các hệ số hồi quy

- $\mathbf{Y}$  là biến phụ thuộc
- $\mathbf{Z}_i$  là các biến giải thích (các yếu tố chính)
- $\boldsymbol{\varepsilon}$  là phần nhiễu - sai số (đại diện cho tất cả các biến không được đưa vào mô hình do các lý do như không có sẵn dữ liệu, khó đo lường và các biến này ảnh hưởng lên  $\mathbf{Y}$  là không đáng kể)

Các sai số  $\varepsilon_1, \varepsilon_2, \dots, \varepsilon_n$  thỏa mãn 3 điều kiện:

1.  $E(\varepsilon_j) = 0$
2.  $\text{Var}(\varepsilon_j) = \sigma^2$  (hằng số không đổi)
3.  $\text{Cov}(\varepsilon_j, \varepsilon_j) = 0 \quad \forall i \neq j$  (các sai số  $\varepsilon$  là không tương quan với nhau)

Mô hình trên có thể được viết dưới dạng ma trận như sau:

$$\begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix} = \begin{bmatrix} 1 & z_{11} & z_{12} & \cdots & z_{1k} \\ 1 & z_{21} & z_{22} & \cdots & z_{2k} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & z_{n1} & z_{n2} & \cdots & z_{nk} \end{bmatrix} \begin{bmatrix} \beta_1 \\ \beta_2 \\ \vdots \\ \beta_k \end{bmatrix} + \begin{bmatrix} \varepsilon_1 \\ \varepsilon_2 \\ \vdots \\ \varepsilon_n \end{bmatrix}$$

ma trận cột beta thiếu beta 0?

Hoặc viết dưới dạng tổng quát:

$$\mathbf{Y}_{n \times 1} = \mathbf{Z}_{n \times (k+1)} \times \boldsymbol{\beta}_{(k+1) \times 1} + \boldsymbol{\varepsilon}_{n \times 1}$$

Với ma trận  $\mathbf{Z}$  được gọi là ma trận thiết kế:

$$\begin{bmatrix} 1 & z_{11} & z_{12} & \cdots & z_{1k} \\ 1 & z_{21} & z_{22} & \cdots & z_{2k} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & z_{n1} & z_{n2} & \cdots & z_{nk} \end{bmatrix}$$

Và:

$$\mathbf{Y} = [y_1, y_2, \dots, y_n]^T, \boldsymbol{\beta} = [\beta_1, \beta_2, \dots, \beta_k]^T, \boldsymbol{\varepsilon} = [\varepsilon_1, \varepsilon_2, \dots, \varepsilon_n]^T$$

$$E(\boldsymbol{\varepsilon}) = \mathbf{0}_{n \times 1} \quad \text{và} \quad \text{Cov}(\boldsymbol{\varepsilon}) = \sigma^2 \mathbf{I}_{n \times n}$$

Ở đây: ma trận  $\boldsymbol{\beta}$  và  $\sigma^2$  là chưa biết và nhiệm vụ là cần đi tìm  $\boldsymbol{\beta}$  và  $\sigma^2$ .

## 2.3 Phương pháp bình phương cực tiểu

### 2.3.1 Ước lượng bình phương cực tiểu

Với các mô hình hồi quy tuyến tính, phương pháp ước lượng thông dụng nhất là phương pháp bình phương cực tiểu (least square). đây là một phương pháp tối ưu hóa để lựa chọn một đường phù hợp nhất cho một dải dữ liệu ứng với cực trị của tổng các bình phương sai số thống kê giữa đường phù hợp nhất và dữ liệu. Phương pháp này được giới thiệu bởi Gauss vào những năm cuối thế kỷ XVIII.

Bài toán đặt ra là hãy dựa trên ma trận  $\mathbf{Z}$  và vector  $\mathbf{Y}$  của các giá trị quan sát được hãy ước lượng tham số  $\beta$  và  $\sigma^2$ .

Nếu ta sử dụng giá trị  $b$  là giá trị thử cho  $\beta$  thì giữa các quan sát  $y_j$  và  $b_0 + b_1 z_{j1} + \dots + b_k z_{jk}$  sẽ có độ lệch (sai số) khác 0:

$$y_j - b_0 - (b_1 z_{j1} + \dots + b_k z_{jk})$$

Phương pháp bình phương cực tiểu là cách chọn giá trị vector  $b$  sao cho cực tiểu hóa hàm  $S(b)$ :

$$\begin{aligned} S(b) &= \sum_{j=1}^n (y_j - b_0 - b_1 z_{j1} - \dots - b_k z_{jk})^2 \\ &= (\mathbf{Y} - \mathbf{Z}b)^\top (\mathbf{Y} - \mathbf{Z}b) \rightarrow \min \end{aligned} \quad (2.3.1)$$

Đại lượng  $\hat{\beta}$  làm cực tiểu hóa phiếm hàm  $S(b)$  được gọi là ước lượng bình phương cực tiểu của  $\beta$ . Ta có:

$$\hat{\varepsilon}_j = y_j - \left( \hat{\beta}_0 + \hat{\beta}_1 z_{j1} + \dots + \hat{\beta}_k z_{jk} \right), j = 1 \div n \quad (2.3.2)$$

**Z thay vì X**

gọi là phần dư của phép hồi quy. Vì biểu thức theo  $\mathbf{X}_1, \dots, \mathbf{X}_k$  là tuyến tính nên phương trình:

$$\hat{\mathbf{Y}} = \hat{\beta}_0 + \hat{\beta}_1 \mathbf{Z}_1 + \dots + \hat{\beta}_k \mathbf{Z}_k \quad (2.3.3)$$

được gọi là phương trình hồi quy tuyến tính mẫu.

Đặt:

$$\hat{y}_j = \hat{\beta}_0 + \hat{\beta}_1 x_{j1} + \dots + \hat{\beta}_k x_{jk} \quad (2.3.4)$$

$$\hat{\mathbf{Y}} = (\hat{y}_1, \hat{y}_2, \dots, \hat{y}_n)^\top$$

Nếu ma trận thiết kế  $\mathbf{Z}$  không ngẫu nhiên có hạng  $k + 1 \leq n$  thì ước lượng bình phương cực tiểu có dạng:

$$\hat{\beta} = (\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{Z}^\top \mathbf{Y} \quad (2.3.5)$$

Khi đó:

$$\hat{\mathbf{Y}} = \mathbf{Z}\hat{\beta} = \mathbf{Z}(\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{Z}^\top \mathbf{Y} = \mathbf{H}\mathbf{Y} \quad (2.3.6)$$

Trong đó:

$$\mathbf{H} = \mathbf{Z}(\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{Z}^\top \text{ cấp } (n \times n) \quad (2.3.7)$$

$$\hat{\epsilon} = \mathbf{Y} - \hat{\mathbf{Y}} = (\mathbf{I}_n - \mathbf{H}) \mathbf{Y} \quad (2.3.8)$$

Thỏa mãn:

$$\mathbf{Z}^\top \hat{\epsilon} = 0 \text{ và } \hat{\mathbf{Y}}^\top \hat{\epsilon} = 0 \quad (\hat{\beta}^\top \mathbf{Z}^\top \hat{\epsilon} = 0) \quad (2.3.9)$$

Tổng các phần dư:

$$\sum_{j=1}^n \hat{\epsilon}_j^2 = \hat{\epsilon}^\top \hat{\epsilon} = \mathbf{Y}^\top \mathbf{Y} - \mathbf{Y}^\top \mathbf{Z}\hat{\beta} \quad (2.3.10)$$

**Chứng minh.** Vì phiếm hàm  $S(b) = \sum_{j=1}^n (y_j - b_0 - b_1 z_{j1} - \dots - b_k z_{jk})^2$  là hàm bậc hai theo  $b$  nên dễ thấy  $\hat{\beta}$  có thể tìm được từ hệ phương trình sau:

$$\frac{\partial S}{\partial b_i} = 0, i = 0 \div k$$

Ta có kết quả:

$$\begin{aligned} \sum_{j=1}^n (b_0 + b_1 z_{j1} + \dots + b_k z_{jk}) &= \sum_{j=1}^n y_j \\ b_0 + \sum_{j=1}^n b_1 z_{j1} + \sum_{j=1}^n b_2 z_{j2} + \dots + \sum_{j=1}^n b_k z_{jk} z_{j1} &= \sum_{j=1}^n y_j z_{j1} \\ b_0 + \sum_{j=1}^n b_1 z_{j1} + \sum_{j=1}^n b_2 z_{j1} z_{jk} + \dots + \sum_{j=1}^n b_k z_{j2} z_{jk} &= \sum_{j=1}^n y_j z_{jk} \end{aligned}$$

Nếu đặt  $x_{j0} = 1, j = 1 \div n$  ta có phương trình sau:

$$\begin{bmatrix} \sum_{j=1}^n z_{j0}^2 & \sum_{j=1}^n z_{j0} z_{j1} & \dots & \sum_{j=1}^n z_{j0} z_{jk} \\ \sum_{j=1}^n z_{j0} z_{j1} & \sum_{j=1}^n z_{j1}^2 & \dots & \sum_{j=1}^n z_{j1} z_{jk} \\ \vdots & \vdots & \ddots & \vdots \\ \sum_{j=1}^n z_{jk} z_{j0} & \sum_{j=1}^n z_{jk} z_{j1} & \dots & \sum_{j=1}^n z_{jk}^2 \end{bmatrix} \begin{bmatrix} b_0 \\ b_1 \\ \vdots \\ b_k \end{bmatrix} = \begin{bmatrix} \sum_{j=1}^n y_j z_{j0} \\ \sum_{j=1}^n y_j z_{j1} \\ \vdots \\ \sum_{j=1}^n y_j z_{jk} \end{bmatrix}$$

Hoặc dưới dạng ma trận:

$$\mathbf{Z}^\top \mathbf{Z} b = \mathbf{Z}^\top \mathbf{Y} \quad (2.3.11)$$

Phương trình (2.3.11) gọi là phương trình chuẩn. Do  $\text{rank}(\mathbf{Z}) = k + 1$ , nên  $\mathbf{Z}^\top \mathbf{Z}$  có nghịch đảo, ta suy ra nghiệm:

$$b = \hat{\beta} = (\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{Z}^\top \mathbf{Y}$$

Ta thấy  $\hat{\beta}$  là biểu thức tuyến tính theo  $\mathbf{Y}$ .

Để chứng minh  $\hat{\beta}$  cực tiểu hóa  $S(b)$  và thỏa mãn (2.3.9) và (2.3.10) ta chú ý rằng ma trận  $\mathbf{H}$  có tính chất sau:

$$\begin{aligned} (\mathbf{I} - \mathbf{H}) &\text{ là ma trận đối xứng: } (\mathbf{I} - \mathbf{H})^\top = (\mathbf{I} - \mathbf{H}) \\ (\mathbf{I} - \mathbf{H})^2 &= (\mathbf{I} - \mathbf{H}) \text{ tức là } (\mathbf{I} - \mathbf{H}) \text{ là ma trận lũy đẳng} \\ \mathbf{Z}(\mathbf{I} - \mathbf{H}) &= \mathbf{Z}^\top \left( \mathbf{I} - \mathbf{Z}(\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{Z}^\top \right) = \mathbf{Z}^\top - \mathbf{Z}^\top = 0 \end{aligned}$$

Dễ dàng thấy rằng:

$$\begin{aligned} S(b) &= (\mathbf{Y} - \mathbf{Z}b)^\top (\mathbf{Y} - \mathbf{Z}b) \\ &= (\mathbf{Y} - \mathbf{Z}\hat{\beta} + \mathbf{Z}\hat{\beta} - \mathbf{Z}b)^\top (\mathbf{Y} - \mathbf{Z}\hat{\beta} + \mathbf{Z}\hat{\beta} - \mathbf{Z}b) \\ &= (\mathbf{Y} - \mathbf{Z}\hat{\beta})^\top (\mathbf{Y} - \mathbf{Z}\hat{\beta}) + (\hat{\beta} - b)^\top \mathbf{Z}^\top \mathbf{Z} (\hat{\beta} - b) \\ &\quad + (\hat{\beta} - b)^\top \mathbf{Z}^\top (\mathbf{I} - \mathbf{H}) \mathbf{Y} + \mathbf{Y}^\top (\mathbf{I} - \mathbf{H})^\top \mathbf{Z} (\hat{\beta} - b) \\ &= (\mathbf{Y} - \mathbf{Z}\hat{\beta})^\top \left( \mathbf{Y} - \mathbf{Z}\hat{\beta} + (\hat{\beta} - b)^\top \mathbf{Z}^\top \mathbf{Z} (\hat{\beta} - b) \right) \\ &\geq (\mathbf{Y} - \mathbf{Z}\hat{\beta})^\top (\mathbf{Y} - \mathbf{Z}\hat{\beta}) = S(\hat{\beta}) \end{aligned}$$

Dấu bằng xảy ra khi  $\hat{\beta} = b$ . Hơn nữa:

$$\begin{aligned} \sum_{j=1}^n \hat{\varepsilon}_j^2 &= S(\hat{\beta}) = (\mathbf{Y} - \mathbf{Z}\hat{\beta})^\top (\mathbf{Y} - \mathbf{Z}\hat{\beta}) = \mathbf{Y}^\top (\mathbf{I} - \mathbf{H}) (\mathbf{I} - \mathbf{H}) \mathbf{Y} \\ &= \mathbf{Y}^\top (\mathbf{I} - \mathbf{H}) \mathbf{Y} = \mathbf{Y}^\top \mathbf{Y} - \mathbf{Y}^\top \mathbf{H} \mathbf{Y} = \mathbf{Y}^\top \mathbf{Y} - (\mathbf{Y}^\top \mathbf{Z}) \hat{\beta} \end{aligned}$$

Đây chính là công thức (2.3.11).

Từ (2.3.9), (2.3.10), (2.3.11) ta nhận được:  $\mathbf{Y}^\top \mathbf{Y} = \sum_{j=1}^n y_j^2 = \hat{\mathbf{Y}}^\top \hat{\mathbf{Y}} + \hat{\boldsymbol{\varepsilon}}^\top \hat{\boldsymbol{\varepsilon}}$

hoặc:

$$\sum_{j=1}^n y_j^2 = \sum_{j=1}^n \hat{y}_j^2 + \sum_{j=1}^n \hat{\varepsilon}_j^2 \quad (2.3.12)$$

### 2.3.2 Tính chất ước lượng bằng phương pháp bình phương cực tiểu

- Ước lượng  $\hat{\beta}$  là ước lượng không chệch với:

$$E(\hat{\beta}) = \beta; \text{cov}(\hat{\beta}) = \sigma^2 (\mathbf{Z}^\top \mathbf{Z})^{-1} \quad (2.3.13)$$

- Phần dư  $\hat{\varepsilon}$  có tính chất:

$$E(\hat{\varepsilon}) = 0; \text{cov}(\hat{\varepsilon}) = \sigma^2 (\mathbf{I} - \mathbf{H}) \quad (2.3.14)$$

- $\sigma^2 = \frac{\hat{\varepsilon}^\top \hat{\varepsilon}}{n - k - 1} = \sum_{j=1}^n \frac{\hat{\varepsilon}_j^2}{n - k - 1}$  là ước lượng không chệch của  $\sigma^2$ , tức là  $E(\hat{\sigma}^2) = \sigma^2$

- $\hat{\beta}, \hat{\varepsilon}$  là không tương quan, tức là:

$$\text{cov}(\hat{\beta}, \hat{\varepsilon}) = 0; \text{cov}(\hat{\beta}, \hat{\sigma}^2) = 0 \quad (2.3.15)$$

**Chứng minh 2.3.2** Ta xét các phép biến đổi sau đây:

1.

$$\begin{aligned} E(\hat{\beta}) &= E[(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{Y}] = (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top E(\mathbf{Y}) \\ &= (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{X} \beta = \beta \\ \text{cov}(\hat{\beta}) &= (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \text{cov}(\mathbf{Y}) \mathbf{X} (\mathbf{X}^\top \mathbf{X})^{-1} \\ &= \sigma^2 (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{I} \mathbf{X} (\mathbf{X}^\top \mathbf{X})^{-1} \\ &= \sigma^2 (\mathbf{X}^\top \mathbf{X})^{-1} \end{aligned}$$

2. Do  $\hat{\varepsilon} = (\mathbf{I} - \mathbf{H}) \mathbf{Y}$  nên:

$$\begin{aligned} E(\hat{\varepsilon}) &= (\mathbf{I} - \mathbf{H}) E(\mathbf{Y}) = (\mathbf{I} - \mathbf{H}) \mathbf{X} \beta = 0 \\ \text{cov}(\hat{\varepsilon}) &= (\mathbf{I} - \mathbf{H}) \mathbf{I} (\mathbf{I} - \mathbf{H}) \sigma^2 = \sigma^2 (\mathbf{I} - \mathbf{H}) \end{aligned}$$



3. Ta có:

$$\begin{aligned} E(\hat{\boldsymbol{\varepsilon}}^\top \hat{\boldsymbol{\varepsilon}}) &= \sum_{j=1}^n \widehat{E\varepsilon_j^2} = \text{tr}[\text{cov}(\hat{\boldsymbol{\varepsilon}})] = \sigma^2 \text{tr}(\mathbf{I}_n - \mathbf{H}) \\ &= \sigma^2 [n - \text{tr}(\mathbf{H})] \end{aligned}$$

Mặt khác:

$$\text{tr}(H) = \text{tr}[\mathbf{X}(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top] = \text{tr}[(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{X}] = \text{tr}[\mathbf{I}_{k+1}] = k + 1$$

$$\Rightarrow E(\hat{\boldsymbol{\varepsilon}}^\top \hat{\boldsymbol{\varepsilon}}) = \sigma^2 (n - k - 1)$$

4. Ta có:

$$\begin{aligned} \text{cov}(\hat{\boldsymbol{\beta}}, \hat{\boldsymbol{\varepsilon}}) &= \text{cov}\left[(\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \mathbf{Y} (\mathbf{I}_n - \mathbf{H}) \mathbf{Y}\right] \\ &= (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top \text{cov}(\mathbf{Y}) (\mathbf{I}_n - \mathbf{H}) \\ &= \sigma^2 (\mathbf{X}^\top \mathbf{X})^{-1} \mathbf{X}^\top (\mathbf{I}_n - \mathbf{H}) = 0 \end{aligned}$$

### 2.3.3 Định lí Gauss về ước lượng bình phương cực tiểu

#### Định lý

Xét mô hình hồi quy tuyến tính  $\mathbf{Y} = \mathbf{Z}\boldsymbol{\beta} + \boldsymbol{\varepsilon}$  với  $E(\boldsymbol{\varepsilon}) = 0$ ,  $\text{Cov}(\boldsymbol{\varepsilon}\boldsymbol{\varepsilon}^\top) = \sigma^2 \mathbf{I}$  và ma trận  $\mathbf{Z}$  có hạng đầy đủ. Với ước lượng bình phương cực tiểu  $\hat{\boldsymbol{\beta}} = (\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{Z}^\top \mathbf{Y}$  của  $\boldsymbol{\beta}$  thì  $c^\top \hat{\boldsymbol{\beta}} = c_0 \hat{\boldsymbol{\beta}}_0 + c_1 \hat{\boldsymbol{\beta}}_1 + \dots + c_k \hat{\boldsymbol{\beta}}_k$  là ước lượng không chệch của  $c^\top \boldsymbol{\beta} = c_0 \boldsymbol{\beta}_0 + c_1 \boldsymbol{\beta}_1 + \dots + c_k \boldsymbol{\beta}_k$  và có phương sai nhỏ nhất so với bất kỳ ước lượng tuyến tính không chệch nào khác có dạng:

$$a^\top \mathbf{Y} = a_1 y_1 + a_2 y_2 + \dots + a_n y_n$$

**Chứng minh.** Với vector  $c$  cố định, đặt  $a^\top \mathbf{Y}$  là một ước lượng không chệch của  $c^\top \boldsymbol{\beta}$ . Khi đó với mọi giá trị  $\boldsymbol{\beta}$  thì:

$$E(a^\top \mathbf{Y}) = c^\top \boldsymbol{\beta} \quad (2.3.16)$$

Mặt khác:

$$E(a^T Y) = E(a^T Z\beta + a^T \varepsilon) = a^T Z\beta \quad (2.3.17)$$

Từ các công thức (2.3.16) và (2.3.17), ta được  $a^T Z\beta = c^T \beta$ , hay viết lại thành  $(c^T - a^T Z)\beta = 0$  với mọi  $\beta$  kể cả giá trị  $\beta = (c^T - a^T Z)^T$ . Điều này nghĩa là  $c^T = a^T Z$  với mọi ước lượng không chệch  $a^T Y$ . Đặt  $u = Z(Z^T Z)^{-1}c$ . Khi đó:

$$c^T \hat{\beta} = c^T (Z^T Z)^{-1} Z^T Y = u^T Y$$

Ta có  $E(\hat{\beta}) = \beta$ , do đó  $c^T \hat{\beta} = u^T Y$  là một ước lượng không chệch của  $c^T \beta$ . Như vậy với mọi vector  $a$  thỏa mãn điều kiện không chệch  $c^T = a^T Z$  thì:

$$\begin{aligned} Var(a^T Y) &= Var(a^T Z\beta + a^T \varepsilon) \\ &= Var(a^T \varepsilon) \\ &= \sigma^2 a^T a \\ &= \sigma^2 (a + u)(a - u + u) \\ &= \sigma^2 [(a - u)^T (a - u) + u^T u] \end{aligned}$$

Do  $u$  cố định nên  $(a - u)^T (a - u) \geq 0$  với mọi  $a$ . Khi đó  $Var(a^T Y)$  cực tiểu hóa khi  $a = u$ , hay nói cách khác, ước lượng không chệch có phương sai nhỏ nhất là:

$$u^T Y = c^T (Z^T Z)^{-1} Z^T Y = c^T \hat{\beta}$$

### 2.3.4 Hệ số xác định R

Đại lượng

$$\begin{aligned} R^2 &= 1 - \frac{\text{Tổng bình phương sai số}}{\text{Tổng bình phương chung}} \\ &= \frac{\text{Tổng bình phương hồi quy}}{\text{Tổng bình phương chung}} \end{aligned}$$

hay:

$$R^2 = 1 - \frac{\sum_{j=1}^n \hat{\varepsilon}_j^2}{\sum_{j=1}^n y_j^2} = \frac{\sum_{j=1}^n \hat{y}_j^2}{\sum_{j=1}^n y_j^2} \quad (2.3.18)$$

gọi là bình phương của hệ số xác định, đó là tỷ lệ biến thiên của các biến  $y_j$  được giải thích bởi các biến  $z_{j1}, \dots, z_{jk}$ .

Thay vì sử dụng hệ số xác định  $R^2$  thì ta sẽ sử dụng hệ số xác định  $\bar{R}^2$  hiệu chỉnh, kí hiệu là  $\bar{R}^2$  và được định nghĩa như sau:

$$\bar{R}^2 = 1 - (1 - R^2) \frac{n-1}{n-k}$$

Giá trị  $\bar{R}^2$  thường được sử dụng thay cho giá trị  $R^2$  thông thường khi so sánh các mô hình hồi quy có số lượng biến khác nhau.

## 2.4 Ước lượng khoảng của mô hình hồi quy

### 2.4.1 Khoảng tin cậy của các hệ số hồi quy $\beta_j$

#### Định lý 1

Xét mô hình hồi quy cổ điển, với giả thiết thêm rằng: các  $\epsilon_j$  có cùng phân phối chuẩn  $N(0, \sigma^2)$  và độc lập, tức là  $\epsilon = (\epsilon_1, \epsilon_2, \dots, \epsilon_n)^\top$  có phân phối chuẩn  $N_n(0, \sigma^2 \mathbf{I}_n)$

1.  $\hat{\beta}$  có phân phối chuẩn  $N_{k+1}(\beta, \sigma^2 (\mathbf{Z}^\top \mathbf{Z})^{-1})$
2.  $\frac{(n-k-1)\hat{\sigma}^2}{\sigma^2} = \frac{\sum_{j=1}^n \hat{\epsilon}_j^2}{\sigma^2} = \frac{\hat{\epsilon}^\top \hat{\epsilon}}{\sigma^2}$  có phân phối  $\chi^2$  với  $(n-k-1)$  bậc tự do.
3.  $\hat{\beta}, \hat{\sigma}^2$  là độc lập.

#### Chứng minh định lý 1

1. Ta có  $\hat{\beta} = (\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{Z}^\top \mathbf{Y}$ ;  $\hat{\epsilon} = (\mathbf{I} - \mathbf{H}) \mathbf{Y}$  là các tổ hợp tuyến tính của vector  $\mathbf{Y}$  có phân phối chuẩn  $N_n(\mathbf{Z}\beta, \sigma^2 \mathbf{I}_n)$ . Vì vậy,  $\hat{\beta}$  có phân phối chuẩn  $N_{k+1}(\beta, \sigma^2 (\mathbf{Z}^\top \mathbf{Z})^{-1})$ ,  $\hat{\epsilon}$  có phân phối chuẩn  $N(0, \sigma^2 (\mathbf{I} - \mathbf{H}))$ ,  $cov(\hat{\beta}, \hat{\epsilon}) = 0$  và  $cov(\hat{\beta}, \hat{\epsilon}^\top) = 0$  có phân phối chuẩn đồng thời nên  $\hat{\beta}, \hat{\sigma}^2$  là độc lập.

2. Nếu  $x = \begin{bmatrix} x_1 & x_2 & \dots & x_k \end{bmatrix}^\top \sim N(0, \sigma^2 \mathbf{I})$ ,  $x_i$  là các biến độc lập với nhau và có giá trị trung bình bằng 0 do đó:

$$\frac{x_1^2}{\sigma^2} + \frac{x_2^2}{\sigma^2} + \dots + \frac{x_k^2}{\sigma^2} \sim \chi_k^2$$

Công thức trên có thể được viết lại là:  $\frac{1}{\sigma^2} x^\top x \sim \chi_k^2$  hoặc  $x^\top (\sigma^2 \mathbf{I})^{-1} x \sim \chi_k^2$

Tương tự nếu  $x \sim N(0, \Sigma)$ , khi đó  $x^\top \Sigma^{-1} x \sim \chi_k^2$

Thật vậy,  $\Sigma$  là ma trận xác định dương nên  $\Sigma = \mathbf{P}\mathbf{P}^\top$ . Trong đó ma trận  $\mathbf{P}$  là ma trận không suy biến cỡ  $k \times k$ . Do đó:

$$\Sigma^{-1} = (\mathbf{P}^{-1})^\top \mathbf{P}^{-1} \text{ và } \mathbf{P}^{-1} \Sigma (\mathbf{P}^{-1})^\top = \mathbf{I}$$

$$\text{Đặt } y = \begin{bmatrix} y_1 & y_2 & \dots & y_k \end{bmatrix}^\top = \mathbf{P}^{-1} x$$

$y$  là chuẩn đa biến vì các  $y_i$  là tổ hợp tuyến tính của các  $x_i$  dễ thấy  $E(y) = 0$  và:

$$\text{Var}(y) = E \left[ \mathbf{P}^{-1} x x^\top (\mathbf{P}^{-1})^\top \right] = \mathbf{P}^{-1} \Sigma (\mathbf{P}^{-1})^\top = \mathbf{I}$$

Suy ra:  $y^\top y \sim \chi_k^2$

Tuy nhiên  $y^\top y = x^\top (\mathbf{P}^{-1})^\top \mathbf{P}^{-1} x = x^\top \Sigma^{-1} x$

Vì thế nên:  $x^\top \Sigma^{-1} x \sim \chi_k^2$

Xét dạng toàn phương  $x^\top \mathbf{A} x$  với  $x \sim N(0, \mathbf{I})$  và  $\mathbf{A}$  là ma trận đối xứng lũy đẳng có rank  $r \leq k$ . Ký hiệu  $\mathbf{Q}$  là ma trận trực giao của  $\mathbf{A}$  thì:

$$\mathbf{Q}^\top \mathbf{A} \mathbf{Q} = \Lambda = \begin{bmatrix} \mathbf{I}_r & 0 \\ 0 & 0 \end{bmatrix}$$

Ở đây  $\Lambda$  có  $r$  giá trị  $\neq 0$  và  $(k - r)$  giá trị bằng 0

Đặt  $y = \begin{bmatrix} y_1 & y_2 & \dots & y_k \end{bmatrix}^\top = \mathbf{Q}^\top x$  với  $x = \mathbf{Q} y$ . Khi đó  $E(y) = 0$  và:

$$\text{Var}(y) = E(yy^\top) = E(\mathbf{Q}^\top x x^\top \mathbf{Q}) = \mathbf{Q}^\top \mathbf{I} \mathbf{Q} = \mathbf{I}$$

Ta có:  $x^\top \mathbf{A} x = y^\top \mathbf{Q}^\top \mathbf{A} \mathbf{Q} y = y_1^2 + y_2^2 + \dots + y_r^2$

Vì vậy  $x^\top \mathbf{A} x \sim \chi_r^2$

### Kết quả cuối cùng

Nếu  $x \sim N(0, \sigma^2 \mathbf{I})$  và ma trận  $\mathbf{A}$  là lũy đẳng đối xứng có hạng  $r$  thì:

$$\frac{1}{\sigma^2} x^\top \mathbf{A} x \sim \chi_r^2$$

Mặt khác  $\hat{\boldsymbol{\varepsilon}} = (\mathbf{I} - \mathbf{H}) \mathbf{Y} = (\mathbf{I} - \mathbf{H}) (\mathbf{Z}\boldsymbol{\beta} + \boldsymbol{\varepsilon}) = (\mathbf{I} - \mathbf{H}) \boldsymbol{\varepsilon}$

Hơn nữa  $\boldsymbol{\varepsilon} \sim N(0, \sigma^2 \mathbf{I})$  nên  $\frac{\hat{\boldsymbol{\varepsilon}}^\top \hat{\boldsymbol{\varepsilon}}}{\sigma^2} = \frac{\boldsymbol{\varepsilon}^\top (\mathbf{I} - \mathbf{H})^2 \boldsymbol{\varepsilon}}{\sigma^2} = \frac{\boldsymbol{\varepsilon}^\top (\mathbf{I} - \mathbf{H}) \boldsymbol{\varepsilon}}{\sigma^2} \sim \chi_r^2$

Với  $r$  là hạng của ma trận  $\mathbf{I} - \mathbf{H}$  mà ta lại có hạng của ma trận đối xứng lũy đẳng bằng trace của nó nên ta có:

$$tr(\mathbf{I} - \mathbf{H}) = tr\left[\mathbf{I} - \mathbf{Z}(\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{Z}^\top\right] = n - tr\left[(\mathbf{Z}^\top \mathbf{Z})^{-1} (\mathbf{Z}^\top \mathbf{Z})\right] = n - k - 1$$

Vậy:

$$\frac{\hat{\boldsymbol{\varepsilon}}^\top \hat{\boldsymbol{\varepsilon}}}{\sigma^2} \sim \chi_{n-k-1}^2$$

### Định lý 2

Xét mô hình hồi quy tuyến tính cổ điển  $\mathbf{Y} = \mathbf{Z}\boldsymbol{\beta} + \boldsymbol{\varepsilon}$  với  $\mathbf{Z}$  có hạng là  $k+1 \leq n$  và  $\boldsymbol{\varepsilon} \sim N(0, \sigma^2 \mathbf{I}_n)$ . Khi đó miền tin cậy đồng thời mức  $(1 - \alpha)$  của  $\boldsymbol{\beta}$  xác định bởi:  $(\boldsymbol{\beta} - \hat{\boldsymbol{\beta}})^\top \mathbf{Z}^\top \mathbf{Z} (\boldsymbol{\beta} - \hat{\boldsymbol{\beta}}) \leq (k+1) \hat{\sigma}^2 F_{k+1, n-k-1}(\alpha)$

Trong đó  $F_{k+1, n-k-1}(\alpha)$  là phân vị trên mức  $\alpha$  của phân phối Fisher với bậc tự do là  $k+1, n-k-1$ .

Nói cách khác, với độ tin cậy  $(1 - \alpha)$ , giá trị thực của  $\boldsymbol{\beta}$  phải nằm trong Ellipsoid:  $(\mathbf{z} - \hat{\boldsymbol{\beta}})^\top \mathbf{Z}^\top \mathbf{Z} (\mathbf{z} - \hat{\boldsymbol{\beta}}) = (k+1) \hat{\sigma}^2 F_{k+1, n-k-1}(\alpha)$

Hơn nữa khoảng tin cậy đồng thời mức  $(1 - \alpha)$  của các  $\beta_i, i = 0 \div k$  được xác định bởi các mút:

$$\sqrt{\hat{\beta}_i \pm \hat{D}(\hat{\beta}_i) (k+1) F_{k+1, n-k-1}(\alpha)}$$

Trong đó  $\hat{D}(\hat{\beta}_i)$  ký hiệu là phần tử thứ  $i+1$  trên đường chéo chính của ma trận  $\hat{\sigma}^2 (\mathbf{Z}^\top \mathbf{Z})^{-1}$  và là ước lượng không chệch của  $D(\hat{\beta}_i)$

## Chứng minh định lý 2

Xét ma trận căn bậc hai đối xứng  $(\mathbf{Z}^\top \mathbf{Z})^{1/2}$  và đặt:

$$\mathbf{U} = (\mathbf{Z}^\top \mathbf{Z})^{1/2} (\hat{\boldsymbol{\beta}} - \boldsymbol{\beta})$$

$$\Rightarrow E(\mathbf{U}) = 0$$

$$\text{cov}(\mathbf{U}) = (\mathbf{Z}^\top \mathbf{Z})^{1/2} \text{cov}(\hat{\boldsymbol{\beta}}) (\mathbf{Z}^\top \mathbf{Z})^{1/2} = \sigma^2 (\mathbf{Z}^\top \mathbf{Z})^{1/2} (\mathbf{Z}^\top \mathbf{Z})^{-1} (\mathbf{Z}^\top \mathbf{Z})^{1/2} = \sigma^2 \mathbf{I}_{k+1}$$

Vậy  $\mathbf{U}$  có phân phối chuẩn  $N(0, \sigma^2 \mathbf{I}_{k+1})$ .

Do đó  $\frac{1}{\sigma^2} \mathbf{U}^\top \mathbf{U} = \frac{1}{\sigma^2} (\hat{\boldsymbol{\beta}} - \boldsymbol{\beta})^\top (\mathbf{Z}^\top \mathbf{Z}) (\hat{\boldsymbol{\beta}} - \boldsymbol{\beta})$  có phân phối  $\chi^2$  với  $k+1$  bậc tự do. Hơn nữa,  $(n-k-1) \frac{\hat{\sigma}^2}{\sigma^2}$  có phân phối  $\chi^2$  với  $n-k-1$  bậc tự do và độc lập với  $\hat{\boldsymbol{\beta}}$ , tức là độc lập với  $\mathbf{U}^\top \mathbf{U}$ . Vì vậy đại lượng

$$F = \frac{(\hat{\boldsymbol{\beta}} - \boldsymbol{\beta})^\top (\mathbf{Z}^\top \mathbf{Z}) (\hat{\boldsymbol{\beta}} - \boldsymbol{\beta}) / (k+1)}{\hat{\sigma}^2} = \frac{\mathbf{U}^\top \mathbf{U} / (k+1) \sigma^2}{(n-k-1) \hat{\sigma}^2 / (n-k-1) \sigma^2}$$

có phân phối Fisher với  $k+1$  và  $n-k-1$  bậc tự do.

Từ đó:

$$P\{F \leq F_{k+1, n-k-1}(\alpha)\} = 1 - \alpha$$

Hoặc:

$$P\left[(\hat{\boldsymbol{\beta}} - \boldsymbol{\beta})^\top \mathbf{Z}^\top \mathbf{Z} (\hat{\boldsymbol{\beta}} - \boldsymbol{\beta})\right] \leq (k+1) \hat{\sigma}^2 F_{k+1, n-k-1}(\alpha) = 1 - \alpha$$

$\Rightarrow$  Miền tin cậy đồng thời mức  $1 - \alpha$  của  $\boldsymbol{\beta}$  là:

$$(\hat{\boldsymbol{\beta}} - \boldsymbol{\beta})^\top \mathbf{Z}^\top \mathbf{Z} (\hat{\boldsymbol{\beta}} - \boldsymbol{\beta}) \leq (k+1) \hat{\sigma}^2 F_{k+1, n-k-1}(\alpha)$$

## Định lý 3

Giả sử  $t_{n-k-1}(\frac{\alpha}{2})$  là phân vị trên mức  $\frac{\alpha}{2}$  của phân phối Student với  $n-k-1$  bậc tự do. Khi đó đồng thời ta có các khoảng tin cậy của  $\beta_i$ , với mức tin cậy  $(1 - \alpha)$  cho bởi các đầu mút:

$$\hat{\beta}_i \pm t_{n-k-1}(\frac{\alpha}{2}) \sqrt{\hat{D}(\hat{\beta}_i)} \quad (2.4.1)$$

### Chứng minh định lý 3

Ta có  $\hat{\beta} \sim N_{k+1}(\beta, \sigma^2 (\mathbf{Z}^\top \mathbf{Z})^{-1})$  độc lập với  $\frac{\hat{\sigma}^2}{\sigma^2} \sim \frac{\chi_{n-k-1}^2}{n-k-1}$

$$\Rightarrow \frac{(\hat{\beta} - \beta) / \sqrt{\sigma^2 (\mathbf{Z}^\top \mathbf{Z})^{-1}}}{\sqrt{\hat{\sigma}^2 / \sigma^2}} \sim t_{n-k-1}$$

$$\Rightarrow P \left( \frac{|\hat{\beta} - \beta|}{\sqrt{\hat{\sigma}^2 (\mathbf{Z}^\top \mathbf{Z})^{-1}}} < t_{n-k-1} \left( \frac{\alpha}{2} \right) \right) = 1 - \alpha$$

$\Rightarrow$  khoảng tin cậy của  $\beta_i$  với mức tin cậy  $(1 - \alpha)$  là:

$$\hat{\beta}_i \pm t_{n-k-1} \left( \frac{\alpha}{2} \right) \sqrt{\hat{D}(\hat{\beta}_i)}$$

## 2.4.2 Kiểm định giả thuyết về các hệ số hồi quy

Xét mô hình HQTTC cổ điển

$$\mathbf{Y} = \beta_0 + \beta_1 \mathbf{Z}_1 + \beta_2 \mathbf{Z}_2 + \dots + \beta_k \mathbf{Z}_k + \varepsilon$$

Khi thiết lập phương trình, ta giả sử rằng mọi biến độc lập  $\mathbf{Z}_1, \dots, \mathbf{Z}_k$  đều tham gia phương trình hồi quy. Tuy nhiên, trên thực tế, có một vài biến sẽ không tham gia vào phương trình hồi quy, hoặc có ảnh hưởng rất ít đến biến phản hồi và ta có thể lược bỏ đi.

Đặt:

$$\beta = \begin{bmatrix} \beta_{(1)} \\ (q+1) \times 1 \\ \dots \\ \beta_{(2)} \\ (k-q) \times 1 \end{bmatrix}$$

Ta có bài toán kiểm định giả thuyết:

$$\mathbf{H}_0 : \beta_{q+1} = \dots = \beta_k \quad (0 < q < k) \text{ hay } \mathbf{H}_0 : \beta_{(2)} = 0$$

với đối thuyết  $\mathbf{K} : \exists i \in \{q+1, \dots, k\}$  sao cho  $\beta_i \neq 0$

Giả thuyết  $\mathbf{H}_0$  có nghĩa là các biến độc lập không tham gia vào biểu thức tuyến tính, ngược lại đối thuyết  $\mathbf{K}$  nói rằng có ít nhất một trong các biến này có liên quan đến mô hình.

Xét mô hình hồi quy tuyến tính cổ điển:

$$\begin{aligned} \mathbf{Y} = \mathbf{Z}\boldsymbol{\beta} + \boldsymbol{\varepsilon} &= \begin{bmatrix} \mathbf{Z}_{(1)} & \vdots & \mathbf{Z}_{(2)} \\ n \times (q+1) & & n \times (k-q) \end{bmatrix} \begin{bmatrix} \boldsymbol{\beta}_{(1)} \\ \vdots \\ \boldsymbol{\beta}_{(2)} \\ (q+1) \times 1 \\ \vdots \\ (k-q) \times 1 \end{bmatrix} + \boldsymbol{\varepsilon} \\ &= \mathbf{Z}_{(1)}\boldsymbol{\beta}_{(1)} + \mathbf{Z}_{(2)}\boldsymbol{\beta}_{(2)} + \boldsymbol{\varepsilon} \end{aligned}$$

#### Định lý 4

Xét mô hình hồi quy tuyến tính  $\mathbf{Y} = \mathbf{Z}\boldsymbol{\beta} + \boldsymbol{\varepsilon}$  với ma trận  $\mathbf{Z}$  đầy hạng và  $\boldsymbol{\varepsilon} \sim N_n(0, \sigma^2 \mathbf{I})$ . Khi đó ta bác bỏ giả thuyết  $\mathbf{H}_0 : \boldsymbol{\beta}_{(2)} = 0$  với độ tin cậy  $(1 - \alpha)$  nếu :

$$SS_{res}(\mathbf{Z}_{(1)}) - SS_{res}(\mathbf{Z}) > \hat{\sigma}^2 (k - q) F_{k-q, n-k-1}(\alpha) \quad (2.4.2)$$

#### Chứng minh định lý 4

Hàm hợp lý tham số  $\boldsymbol{\beta}$  và  $\sigma^2$  là:

$$L(\boldsymbol{\beta}, \sigma^2) = \frac{1}{(2\pi)^{n/2} \sigma^n} e^{-\frac{(y - \mathbf{Z}\boldsymbol{\beta})^\top (y - \mathbf{Z}\boldsymbol{\beta})}{2\sigma^2}} \leq \frac{1}{(2\pi)^{n/2} \sigma^n} e^{-\frac{n}{2}}$$

Max của  $L(\boldsymbol{\beta}, \sigma^2)$  xảy ra khi  $\boldsymbol{\beta} = \hat{\boldsymbol{\beta}} = (\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{Z}^\top \mathbf{Y}$  và  $\sigma^2 = \hat{\sigma}^{*2} = \frac{(y - \mathbf{Z}\hat{\boldsymbol{\beta}})^\top (y - \mathbf{Z}\hat{\boldsymbol{\beta}})}{n}$  ( $\hat{\sigma}^{*2}$  là ước lượng hợp lý cực đại của  $\sigma^2$ )

Tương tự với  $\mathbf{Y} = \mathbf{Z}_{(1)}\boldsymbol{\beta}_{(1)} + \boldsymbol{\varepsilon}$  thì:

$$\max_{\boldsymbol{\beta}_{(1)}, \sigma_1^2} L(\boldsymbol{\beta}_{(1)}, \sigma_1^2) = \frac{1}{(2\pi)^{n/2} \hat{\sigma}_1^n} e^{-\frac{n}{2}}$$

Tại  $\boldsymbol{\beta}_{(1)} = \hat{\boldsymbol{\beta}}_{(1)} = (\mathbf{Z}_{(1)}^\top \mathbf{Z}_{(1)})^{-1} \mathbf{Z}_{(1)}^\top \mathbf{Y}$  và  $\sigma_1^2 = \hat{\sigma}_1^{*2} = \frac{(y - \mathbf{Z}_{(1)}\hat{\boldsymbol{\beta}}_{(1)})^\top (y - \mathbf{Z}_{(1)}\hat{\boldsymbol{\beta}}_{(1)})}{n}$  ( $\hat{\sigma}_1^{*2}$  là ước lượng hợp lý cực đại của  $\sigma_1^2$ )

Ta bác bỏ giả thuyết  $\mathbf{H}_0 : \boldsymbol{\beta}_{(2)} = 0$  nếu:

$$\frac{\max L(\boldsymbol{\beta}_{(1)}, \sigma_1^2)}{\max L(\boldsymbol{\beta}, \sigma^2)} = \left( \frac{\hat{\sigma}_1^{*2}}{\hat{\sigma}^{*2}} \right)^{-\frac{n}{2}} = \left( 1 + \frac{\hat{\sigma}_1^{*2} - \hat{\sigma}^{*2}}{\hat{\sigma}^{*2}} \right)^{-\frac{n}{2}}$$



nhỏ hay giá trị  $\frac{\hat{\sigma}_1^{*2} - \hat{\sigma}^{*2}}{\hat{\sigma}^{*2}}$  lớn.

$$F = \frac{n(\hat{\sigma}_1^{*2} - \hat{\sigma}^{*2}) / (k - q)}{n\hat{\sigma}^{*2} / (n - k - 1)} = \frac{(SS_{res}(\mathbf{Z}_{(1)}) - SS_{res}(\mathbf{Z})) / (k - q)}{\hat{\sigma}^2}$$

$$F \sim F_{k-q, n-k-1} \Rightarrow P\{F > F_{k-q, n-k-1}(\alpha)\} = \alpha$$

Suy ra ta bác bỏ giả thuyết  $\mathbf{H}_0 : \beta_{(2)} = 0$  với độ tin cậy  $(1 - \alpha)$  nếu :

$$SS_{res}(\mathbf{Z}_{(1)}) - SS_{res}(\mathbf{Z}) > \hat{\sigma}^2 (k - q) F_{k-q, n-k-1}(\alpha)$$

Tổng quát hơn ta xét bài toán kiểm định giả thuyết dạng:

$$\mathbf{H}_0 : \begin{cases} c_{10}\beta_0 + c_{11}\beta_1 + \dots + c_{1k}\beta_k = a_1 \\ c_{20}\beta_0 + c_{21}\beta_1 + \dots + c_{2k}\beta_k = a_2 \\ \dots \\ c_{k-q,0}\beta_0 + c_{k-q,1}\beta_1 + \dots + c_{k-q,k}\beta_k = a_{k-q} \end{cases}$$

$$\Leftrightarrow \mathbf{C}\beta = \mathbf{a} \quad (2.4.3)$$

Trong đó  $\mathbf{C} = [c_{ij}]_{k-q, k+1}$ ;  $\mathbf{a} = [a_1, \dots, a_{k-q}]^\top$

Với:

$$\mathbf{C} = \begin{bmatrix} 0 & 0 & \dots & 0 & \vdots & 1 & 0 & \dots & 0 \\ 0 & 0 & \dots & 0 & \vdots & 0 & 1 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots & \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & 0 & \vdots & 0 & 0 & \dots & 1 \end{bmatrix} = [0; \mathbf{I}_{k-q}]$$

Quy tắc kiểm định:

Bác bỏ giả thuyết  $\mathbf{H}_0 : \mathbf{C}\beta = 0$  nếu:

$$\left[ (\mathbf{C}\hat{\beta})^\top (\mathbf{C}(\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{C}^\top)^{-1} \mathbf{C}\hat{\beta} \right] / \hat{\sigma}^2 > (k - q) F_{k-q, n-k-1}(\alpha) \quad (2.4.4)$$

### Nhận xét

Ta có thể sử dụng định lý 3 về khoảng tin cậy của  $\beta_{q+1}, \dots, \beta_k$  với các đầu mút  $\hat{\beta}_i \pm t_{n-k-1} \left( \frac{\alpha}{2} \right) \sqrt{\hat{D}(\hat{\beta}_i)}$  để kiểm định giả thuyết. Điều đó có nghĩa là nếu tồn tại chỉ số  $i \in \{q+1, \dots, k\}$  thỏa mãn:

$$|\hat{\beta}_i| > t_{n-k-1} \left( \frac{\alpha}{2} \right) \sqrt{\hat{D}(\hat{\beta}_i)}$$

thì ta coi  $\beta_i \neq 0$ .

## 2.5 Ước lượng hàm hồi quy tuyến tính

### 2.5.1 Ước lượng hàm hồi quy tại $\mathbf{z}_0$

Đặt  $\mathbf{Z}_0^\top = \begin{bmatrix} 1 & z_{01} & z_{02} & \dots & z_{0k} \end{bmatrix}$  là biến dự đoán, ta có  $\mathbf{Y}_0$  biểu thị giá trị phản hồi của mô hình hồi quy tại  $\mathbf{Z}_0$ . Khi đó:

$$E(\mathbf{Y}_0 | \mathbf{Z}_0) = \beta_0 + \beta_1 z_{01} + \dots + \beta_k z_{0k} = \mathbf{Z}_0^\top \boldsymbol{\beta} \quad (2.5.1)$$

Theo định lý Gauss, ước lượng bình phương cực tiểu của  $E(\mathbf{Y}_0 | \mathbf{Z}_0)$  là  $\mathbf{Z}_0^\top \hat{\boldsymbol{\beta}}$

### Định lý 5

Xét mô hình hồi quy tuyến tính  $\mathbf{Y} = \mathbf{Z}\boldsymbol{\beta} + \boldsymbol{\varepsilon}$  với ma trận  $\mathbf{Z}$  đầy hạng,  $\mathbf{Z}_0^\top \hat{\boldsymbol{\beta}}$  là ước lượng không chệch của  $E(\mathbf{Y}_0 | \mathbf{Z}_0)$  với phương sai cực tiểu:

$$\text{Var}(\mathbf{Z}_0^\top \hat{\boldsymbol{\beta}}) = \mathbf{Z}_0^\top (\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{Z}_0 \sigma^2$$

Nếu  $\boldsymbol{\varepsilon} \sim N_n(0, \sigma^2 \mathbf{I})$ , khi đó khoảng tin cậy mức  $100(1 - \alpha)\%$  của  $\mathbf{Z}_0^\top \boldsymbol{\beta}$  là:

$$\mathbf{Z}_0^\top \hat{\boldsymbol{\beta}} \pm t_{n-k-1} \left( \frac{\alpha}{2} \right) \sqrt{\mathbf{Z}_0^\top (\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{Z}_0 s^2} \quad (2.5.2)$$

### Chứng minh định lý 5

Với  $\mathbf{Z}_0$  cố định,  $\mathbf{Z}_0^\top \boldsymbol{\beta}$  là một tổ hợp tuyến tính của  $\beta_i$ , nên theo định lý Gauss, ta có:

$$\text{Var} \left( \mathbf{Z}_0^\top \hat{\boldsymbol{\beta}} \right) = \mathbf{Z}_0^\top \text{cov} \left( \hat{\boldsymbol{\beta}} \right) \mathbf{Z}_0 = \mathbf{Z}_0^\top \left( \mathbf{Z}^\top \mathbf{Z} \right)^{-1} \mathbf{Z}_0 \sigma^2$$

Khi  $\text{cov} \left( \hat{\boldsymbol{\beta}} \right) = \sigma^2 \left( \mathbf{Z}^\top \mathbf{Z} \right)^{-1}$  (bởi công thức (2.3.13))

Giả định rằng  $\boldsymbol{\varepsilon}$  có phân phối chuẩn.

Định lý 1 khẳng định  $\hat{\boldsymbol{\beta}}$  có phân phối chuẩn  $N_{k+1} \left( \boldsymbol{\beta}, \sigma^2 (\mathbf{Z}^\top \mathbf{Z})^{-1} \right)$  độc lập với  $s^2/\sigma^2$  và  $s^2/\sigma^2$  có phân phối  $\chi^2_{n-k-1}/(n-k-1)$ .

Kết quả, sự kết hợp tuyến tính  $\mathbf{Z}_0^\top \hat{\boldsymbol{\beta}}$  là  $N \left( \mathbf{Z}_0^\top \boldsymbol{\beta}, \sigma^2 \mathbf{Z}_0^\top \left( \mathbf{Z}^\top \mathbf{Z} \right)^{-1} \mathbf{Z}_0 \right)$  và  $\left( \mathbf{Z}_0^\top \hat{\boldsymbol{\beta}} - \mathbf{Z}_0^\top \boldsymbol{\beta} \right) / \sqrt{\sigma^2 \mathbf{Z}_0^\top \left( \mathbf{Z}^\top \mathbf{Z} \right)^{-1} \mathbf{Z}_0}$  có phân phối  $N(0; 1)$ .

Chia tỷ lệ này cho  $\sqrt{s^2/\sigma^2}$  có phân phối  $\sqrt{\chi^2_{n-k-1}/(n-k-1)}$ , chúng ta được:

$$\frac{\left( \mathbf{Z}_0^\top \hat{\boldsymbol{\beta}} - \mathbf{Z}_0^\top \boldsymbol{\beta} \right) / \sqrt{\sigma^2 \mathbf{Z}_0^\top \left( \mathbf{Z}^\top \mathbf{Z} \right)^{-1} \mathbf{Z}_0}}{\sqrt{s^2/\sigma^2}} = \frac{\mathbf{Z}_0^\top \hat{\boldsymbol{\beta}} - \mathbf{Z}_0^\top \boldsymbol{\beta}}{\sqrt{s^2 \mathbf{Z}_0^\top \left( \mathbf{Z}^\top \mathbf{Z} \right)^{-1} \mathbf{Z}_0}} \sim t_{n-k-1}$$

Nên khoảng tin cậy của  $E(\mathbf{Y}_0 | \mathbf{Z}_0) = \mathbf{Z}_0^\top \boldsymbol{\beta}$  có mút xác định bởi:

$$\mathbf{Z}_0^\top \hat{\boldsymbol{\beta}} \pm t_{n-k-1} \left( \frac{\alpha}{2} \right) \sqrt{\mathbf{Z}_0^\top \left( \mathbf{Z}^\top \mathbf{Z} \right)^{-1} \mathbf{Z}_0 s^2}$$

### 2.5.2 Dự đoán quan sát mới tại $z_0$

Với  $\mathbf{Z}_0$  là vector cho trước, thay vào mô hình hồi quy ta được:  $\mathbf{Y}_0 = \mathbf{Z}_0^\top \boldsymbol{\beta} + \boldsymbol{\varepsilon}_0$

Trong đó  $\boldsymbol{\varepsilon}_0 \sim N(0, \sigma^2)$  và độc lập với  $\boldsymbol{\varepsilon}_i$

#### Định lý 6

Xét mô hình hồi quy tuyến tính  $\mathbf{Y} = \mathbf{Z}\boldsymbol{\beta} + \boldsymbol{\varepsilon}$  với ma trận  $\mathbf{Z}$  đầy hạng, một dự đoán mới có dự đoán không chệch:  $\mathbf{Z}_0^\top \hat{\boldsymbol{\beta}} = \hat{\beta}_0 + \hat{\beta}_1 z_{01} + \dots + \hat{\beta}_k z_{0k}$  với phương sai của sai số dự báo  $\mathbf{Y}_0 - \mathbf{Z}_0^\top \hat{\boldsymbol{\beta}}$  là:

$$\text{Var} \left( \mathbf{Y}_0 - \mathbf{Z}_0^\top \hat{\boldsymbol{\beta}} \right) = \sigma^2 \left( 1 + \mathbf{Z}_0^\top \left( \mathbf{Z}^\top \mathbf{Z} \right)^{-1} \mathbf{Z}_0 \right)$$

### Hệ quả

Với  $\varepsilon$  có phân phối chuẩn, khoảng tin cậy mức  $100(1 - \alpha)\%$  của  $\mathbf{Y}_0$  được đưa ra là:

$$\mathbf{Z}_0^\top \hat{\boldsymbol{\beta}} \pm t_{n-k-1} \left( \frac{\alpha}{2} \right) \sqrt{s^2 \left( 1 + \mathbf{Z}_0^\top (\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{Z}_0 \right)} \quad (2.5.3)$$

### Chứng minh định lý 6 và hệ quả

Chúng ta dự đoán  $\mathbf{Y}_0$  bởi  $\mathbf{Z}_0^\top \hat{\boldsymbol{\beta}}$ , ước lượng  $E(\mathbf{Y}_0 | \mathbf{Z}_0)$ .

Bằng mệnh đề (4.26),  $\mathbf{Z}_0^\top \hat{\boldsymbol{\beta}}$  có:

$$E(\mathbf{Z}_0^\top \hat{\boldsymbol{\beta}}) = \mathbf{Z}_0^\top \boldsymbol{\beta} \text{ và } Var(\mathbf{Z}_0^\top \hat{\boldsymbol{\beta}}) = \mathbf{Z}_0^\top (\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{Z}_0 \sigma^2$$

Dự báo sai số là:  $\mathbf{Y}_0 - \mathbf{Z}_0^\top \hat{\boldsymbol{\beta}} = \mathbf{Z}_0^\top \boldsymbol{\beta} + \varepsilon_0 - \mathbf{Z}_0^\top \hat{\boldsymbol{\beta}} = \varepsilon_0 + \mathbf{Z}_0^\top (\boldsymbol{\beta} - \hat{\boldsymbol{\beta}})$

Vì vậy nên  $E(\mathbf{Y}_0 - \mathbf{Z}_0^\top \hat{\boldsymbol{\beta}}) = E(\varepsilon_0) + E[\mathbf{Z}_0^\top (\boldsymbol{\beta} - \hat{\boldsymbol{\beta}})] = 0$

Từ  $\varepsilon_0$  và  $\hat{\boldsymbol{\beta}}$  độc lập

$$\begin{aligned} Var(\mathbf{Y}_0 - \mathbf{Z}_0^\top \hat{\boldsymbol{\beta}}) &= Var(\varepsilon_0) + Var(\mathbf{Z}_0^\top \hat{\boldsymbol{\beta}}) \\ &= \sigma^2 + \mathbf{Z}_0^\top (\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{Z}_0 \sigma^2 \\ &= \sigma^2 \left[ 1 + \mathbf{Z}_0^\top (\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{Z}_0 \right] \end{aligned}$$

Nếu giả định thêm rằng  $\varepsilon$  có phân phối chuẩn, sau đó  $\hat{\boldsymbol{\beta}}$  có phân phối chuẩn, và sự kết hợp tuyến tính  $\mathbf{Y}_0 - \mathbf{Z}_0^\top \hat{\boldsymbol{\beta}}$  cũng vậy.

Kết quả là:  $(\mathbf{Y}_0 - \mathbf{Z}_0^\top \hat{\boldsymbol{\beta}}) / \sqrt{\sigma^2 \left( 1 + \mathbf{Z}_0^\top (\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{Z}_0 \right)}$  có phân phối  $N(0, 1)$ .

Chia tỉ lệ này cho  $\sqrt{s^2/\sigma^2}$  có phân phối  $\sqrt{\chi_{n-k-1}^2/(n-k-1)}$ .

Chúng ta đạt được:  $\frac{\mathbf{Y}_0 - \mathbf{Z}_0^\top \hat{\boldsymbol{\beta}}}{\sqrt{s^2 \left( 1 + \mathbf{Z}_0^\top (\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{Z}_0 \right)}}$  có phân phối  $t_{n-k-1}$  nên ta

có khoảng tin cậy được xác định bởi:

$$\mathbf{Z}_0^\top \hat{\boldsymbol{\beta}} \pm t_{n-k-1} \left( \frac{\alpha}{2} \right) \sqrt{s^2 \left( 1 + \mathbf{Z}_0^\top (\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{Z}_0 \right)}$$

**Ví dụ 1.** Để nghiên cứu sự phụ thuộc giữa yêu cầu phân cứng máy tính đối với nhu cầu sử dụng của khách hàng từ những đơn đặt hàng đã có, từ đó đưa ra

dự báo về các yêu cầu phần cứng máy tính trong tương lai đồng thời có biện pháp quản lý hàng tồn kho. Một nhà khoa học máy tính đưa ra dữ liệu từ 7 trang web khác nhau được thể hiện ở bảng sau:

| $\mathbf{Z}_1$ (Orders) | $\mathbf{Z}_2$ (Add-delete items) | $\mathbf{Y}$ (CPU time) |
|-------------------------|-----------------------------------|-------------------------|
| 123.5                   | 2.108                             | 141.5                   |
| 146.1                   | 9.213                             | 168.9                   |
| 133.9                   | 1.905                             | 154.8                   |
| 128.5                   | 0.815                             | 146.5                   |
| 151.5                   | 1.061                             | 172.8                   |
| 136.2                   | 8.603                             | 160.1                   |
| 92.0                    | 1.125                             | 108.5                   |

**Bảng 2.1 Computer Data**

Xây dựng khoảng tin cậy 95% cho tuổi thọ CPU trung bình và tìm khoảng thời gian dự đoán 95% cho tuổi thọ CPU tại cơ sở mới ứng với  $\mathbf{Z}_0 = \begin{bmatrix} 1 & 130 & 7.5 \end{bmatrix}^\top$

Một chương trình máy tính cung cấp hàm hồi quy ước tính:

$$\hat{y} = 8.42 + 1.08z_1 + 0.42z_2$$

Ta tính được:

$$\bullet \mathbf{Z} = \begin{bmatrix} 1 & 123.5 & 2.108 \\ 1 & 146.1 & 9.213 \\ 1 & 133.9 & 1.905 \\ 1 & 128.5 & 0.815 \\ 1 & 151.5 & 1.061 \\ 1 & 136.2 & 8.603 \\ 1 & 92.0 & 1.125 \end{bmatrix} \text{ và } (\mathbf{Z}^\top \mathbf{Z})^{-1} = \begin{bmatrix} 8.1796 & -0.0641 & 0.0883 \\ -0.0641 & 0.0005 & -0.0010 \\ 0.0883 & -0.0010 & 0.0144 \end{bmatrix}$$

$$\bullet \sqrt{\mathbf{Z}_0^\top (\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{Z}_0} s^2 = (0.73)$$

$$\bullet s = 1.204$$

- Khoảng tin cậy mức 95% cho tuổi thọ CPU trung bình là:

$$\mathbf{z}_0^\top \hat{\boldsymbol{\beta}} \pm t_{n-k-1} \left( \frac{\alpha}{2} \right) \sqrt{s^2 \left( 1 + \mathbf{z}_0^\top (\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{z}_0 \right)} = 151.84 \pm 2.776(0.73)$$

- Khoảng thời gian dự đoán mức 95% cho tuổi thọ CPU tại cơ sở mới với điều kiện  $\mathbf{Z}_0$  là:

$$\mathbf{z}_0^\top \hat{\boldsymbol{\beta}} \pm t_{n-k-1} \left( \frac{\alpha}{2} \right) \sqrt{s^2 \left( 1 + \mathbf{z}_0^\top (\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{z}_0 \right)} = 151.84 \pm 2.776(0.73)$$

**Ví dụ 2.** Một hãng sản xuất linh kiện máy tính cần xác định được tuổi thọ của một loại CPU (bộ xử lý trung tâm) dựa vào số lượng mua của khách hàng. Mục đích là để trong tương lai, hãng có thể sản xuất ra loại CPU thích hợp xu hướng người dùng. Bảng dưới đây là tuổi thọ của 7 loại CPU khác nhau (tính theo giờ) dựa trên số lượng đơn đặt của khách (tính theo nghìn) và lượng đơn vị vào - ra (là thông số của CPU, tính theo nghìn)

| $\mathbf{Y}$<br>Tuổi thọ CPU<br>(giờ) | $\mathbf{z}_1$<br>Số đơn đặt<br>(nghìn) | $\mathbf{z}_2$<br>Lượng đơn vị vào - ra<br>(nghìn) |
|---------------------------------------|-----------------------------------------|----------------------------------------------------|
| 141.5                                 | 123.5                                   | 2.108                                              |
| 168.9                                 | 146.1                                   | 9.213                                              |
| 154.8                                 | 133.9                                   | 1.905                                              |
| 146.5                                 | 128.5                                   | 0.815                                              |
| 172.8                                 | 151.5                                   | 1.061                                              |
| 160.1                                 | 136.2                                   | 8.603                                              |
| 108.5                                 | 92.0                                    | 1.125                                              |

**Bảng 2.2 Tuổi thọ của 7 loại CPU**

Ta xét mô hình hồi quy tuyến tính cổ điển cho tuổi thọ CPU:

$$\mathbf{Y}_j = \beta_0 + \beta_1 \mathbf{z}_{j1} + \beta_2 \mathbf{z}_{j2} + \varepsilon_j$$

Ta tính được phương trình hồi quy tuyến tính mẫu là:

$$\hat{\mathbf{Y}} = 7.862 + 1.080 \mathbf{z}_1 + 0.451 \mathbf{z}_2$$

Ta sẽ sử dụng nó để dự đoán hàm hồi quy và dự đoán quan sát mới tại  $\mathbf{z}_0 = \begin{bmatrix} 1 & 130 & 7.5 \end{bmatrix}^\top$ . Ta có:

$$\mathbf{z}_0^\top \hat{\boldsymbol{\beta}} = 141.687, s^2 = 3.26549, \mathbf{z}_0^\top (\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{z}_0 = 0.37133$$

Do đó, khoảng tin cậy đồng thời mức 95% của hàm hồi quy tuyến tính tại  $\mathbf{z}_0$  là:

$$\mathbf{Y}_0 = \mathbf{z}_0^\top \hat{\boldsymbol{\beta}} \pm t_{n-k-1} \left( \frac{\alpha}{2} \right) \sqrt{s^2 \mathbf{z}_0^\top (\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{z}_0} = 151.687 \pm 3.057$$

và khoảng dự đoán mức 95% của quan sát mới  $\mathbf{Y}_0$  tại  $\mathbf{z}_0$  là:

$$\mathbf{Y}_0 = \mathbf{z}_0^\top \hat{\boldsymbol{\beta}} \pm t_{n-k-1} \left( \frac{\alpha}{2} \right) \sqrt{s^2 \left( 1 + \mathbf{z}_0^\top (\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{z}_0 \right)} = 151.687 \pm 5.875$$

## 2.6 Kiểm tra mô hình và các khía cạnh khác của hồi quy

### 2.6.1 Một số khái niệm

#### Chuẩn hóa tập mẫu

Trong các bài toán phân tích dữ liệu thì chuẩn hóa dữ liệu là một phương pháp thường xuyên được sử dụng, đặc biệt là khi dữ liệu của chúng ta có những yếu tố đơn vị như là mét, kilogram,...

Để chuẩn hóa dữ liệu, ta đặt:

$$z^* = \frac{z - \mu}{s}$$

trong đó  $z$  là giá trị quan sát,  $\mu$  là giá trị trung bình mẫu và  $s$  là độ lệch chuẩn mẫu.

Việc đặt chuẩn hóa như vậy có tác dụng như sau:

- Đo lường xem từng giá trị  $z$  cách xa giá trị trung bình  $\mu$  là bao nhiêu.
- Khi ta áp dụng công thức này với toàn bộ dữ liệu  $\mathbf{Z}$ , ta sẽ nhận được mẫu  $\mathbf{Z}^*$  mới có trung bình là 0 và độ lệch chuẩn là 1.

## Outlier

Outlier là điểm dữ liệu bất thường, bất thường ở đây có nghĩa là quan sát tại điểm đó nằm cách xa đám mây dữ liệu mà ta thu thập được. Outlier thường là kết quả của sự thiếu chính xác khi quan sát số liệu.

Trong thực nghiệm việc nhận biết được outlier không hề đơn giản, đặc biệt là khi ta có hàng nghìn đến hàng triệu điểm dữ liệu khiến cho việc dùng mắt thường để xác định outlier trở nên vô nghĩa. Trong đồ án này, ta sẽ tìm hiểu về phương pháp hỗ trợ loại bỏ điểm outlier là độ đo Leverage.

## Leverage

Leverage là độ đo khoảng cách giữa 1 điểm dữ liệu và phần còn lại của bộ dữ liệu dựa trên miền giá trị của bộ dữ liệu. Leverage được xác định bởi công thức như sau:

$$h_{kj} = \frac{1}{n} + \frac{(z_{kj} - \bar{z})^2}{\sum_{j=1}^n (z_{kj} - \bar{z})^2}$$

Những điểm nằm xa so với bộ dữ liệu gọi là những điểm high leverage, còn những điểm nằm gần thì gọi là lower leverage. Nhận xét:

- Càng có nhiều điểm dữ liệu nằm gần nhau thì sức ảnh hưởng hay độ lớn của điểm high leverage càng giảm.
- Những điểm  $h_{kj} > 3 * \bar{h}$  thì được coi là những điểm outlier. Với  $\bar{h} = \frac{1}{n} \sum_{j=1}^n h_{kj}$

Xét lại ví dụ 1, ta có bảng sau:

Như vậy trong bộ dữ liệu ở ví dụ 1, không có điểm outlier nào.

### 2.6.2 Kiểm định tính phụ thuộc vào biến của mô hình

Như ta đã biết mô hình hồi quy tuyến tính có dạng  $\mathbf{Y} = \beta_0 + \beta_1 \mathbf{Z}_1 + \beta_2 \mathbf{Z}_2 + \dots + \beta_k \mathbf{Z}_k$ . Như vậy, ta sử dụng tiêu chuẩn F-test để kiểm tra tính phụ thuộc vào biến  $\mathbf{Z}_k$  của mô hình, hay là mô hình chỉ phụ thuộc vào mỗi giá trị tự do là hằng số  $\beta_0$

Xét đại lượng:

$$F = \frac{(n - k - 1) R^2}{k (1 - R^2)}$$



trong đó:

$$R^2 := \frac{\hat{\mathbf{Y}}^\top \hat{\mathbf{Y}} - n(\bar{y})^2}{\mathbf{Y}^\top \mathbf{Y} - n(\bar{y})^2} = \frac{\sum_{j=1}^n \hat{y}_j^2 - n(\bar{y})^2}{\sum_{j=1}^n y_j^2 - n(\bar{y})^2}$$

hay còn được biểu diễn theo công thức:

$$\sum_{j=1}^n \hat{\varepsilon}_j^2 = \left[ \sum_{j=1}^n y_j^2 - n(\bar{y})^2 \right] (1 - R^2) = ns_y^2 (1 - R^2)$$

Ta có cặp giả thiết và đối thuyết như sau:

- Giả thuyết  $\mathbf{H}_0 : \beta_1 = \beta_2 = \dots = \beta_k = 0$
- Đối thuyết  $\mathbf{H}_1 : \nexists \beta_j \neq 0$  với  $j = \overline{1, k}$

Các bước kiểm tra như sau:

1. Tính đại lượng  $F$ .
2. Tra bảng phân phối Fisher với bậc tự do là  $k$  và  $n - k - 1$ , với mức ý nghĩa  $\alpha$ .
3. Nếu  $F > F_{k, n-k-1}(\alpha)$  thì ta bác bỏ  $\mathbf{H}_0$  và chấp nhận  $\mathbf{H}_1$ .

**Ví dụ.** Để nghiên cứu sự phụ thuộc giữa doanh thu với chi phí sản xuất và chi phí tiếp thị, người ta điều tra ngẫu nhiên doanh thu của 12 công ty trong 12 thời kỳ, kết quả ta có bảng sau:

| <b>Y</b><br>Doanh thu<br>(dollar) | <b>z<sub>1</sub></b><br>Chi phí sản xuất<br>(dollar) | <b>z<sub>2</sub></b><br>Chi phí tiếp thị<br>(dollar) |
|-----------------------------------|------------------------------------------------------|------------------------------------------------------|
| 127                               | 18                                                   | 10                                                   |
| 149                               | 25                                                   | 11                                                   |
| 106                               | 19                                                   | 6                                                    |
| 163                               | 24                                                   | 16                                                   |
| 102                               | 15                                                   | 7                                                    |
| 180                               | 26                                                   | 17                                                   |
| 161                               | 25                                                   | 14                                                   |
| 128                               | 16                                                   | 12                                                   |
| 139                               | 17                                                   | 12                                                   |
| 144                               | 23                                                   | 12                                                   |
| 159                               | 22                                                   | 14                                                   |
| 138                               | 15                                                   | 15                                                   |

**Bảng 2.3 Doanh thu**

Sử dụng công thức tính  $R^2$ , ta được  $R^2 = 0.9756$ . Từ đó ta có:

$$F = \frac{2(0.9756)}{(12 - 2 - 1)(1 - 0.9756)} = 179.6292$$

Tra bảng  $F$  với mức ý nghĩa 2%, ta được  $F_{2,9}(0.02) = 6.234 < F$ . Do đó, ta bác bỏ giả thuyết  $H_0$ , tức là bài toán có sự phụ thuộc vào các biến độc lập.

### 2.6.3 Kiểm tra tính đa cộng tuyến của các biến dự đoán và cách khắc phục

Các biến  $Z_i$  có thể tự tương quan, hiện tượng này dẫn tới việc  $|\mathbf{Z}^T \mathbf{Z}| \approx 0$ , hay các hệ số  $\hat{\beta} = (\mathbf{Z}^T \mathbf{Z})^{-1} \mathbf{Z}^T \mathbf{Y}$  trở nên rất lớn, khó kiểm soát sai số.

Cách nhận biết hiện tượng này:

- Một số phần tử trên đường chéo chính của ma trận  $(\mathbf{Z}^T \mathbf{Z})^{-1}$  tỏ ra rất lớn.
- Các hệ số tương quan tuyến tính mẫu của các cặp  $\mathbf{Z}_i, \mathbf{Z}_j$  là  $r_{ij} = s_{ij} / \sqrt{s_{jj}s_{ii}}$  tỏ ra rất lớn ( $|r_{ij}| \geq 0,7$ ), trong đó:

$$s_{ij} = \frac{1}{n-1} \sum_{k=1}^n (z_{ki} - \hat{z}_i) \times (z_{kj} - \hat{z}_j)$$

Để khắc phục hiện tượng đa cộng tuyến, ta làm các bước như sau:

1. Tính các hệ số tương quan mẫu  $r_{ij}$
2. Đặt  $r_{0i}$  là hệ số tương quan tuyến tính mẫu giữa  $\mathbf{Y}$  và  $\mathbf{Z}_i$ , cụ thể là:

$$r_{0i} = s_{0i} / \sqrt{s_{ii}s_{00}}$$

$$\text{Trong đó: } s_{00} = \frac{1}{n-1} \sum_{j=1}^n (y_j - \hat{y}) \times (y_j - \hat{y}) ; s_{0i} = \frac{1}{n-1} \sum_{j=1}^n (y_j - \hat{y}) \times (z_{ij} - \hat{z}_i)$$

Khi đó, nếu thấy  $|r_{ij}| \geq 0,7$  thì:

- Ta loại biến  $\mathbf{Z}_i$  ra khỏi mô hình nếu  $|r_{0i}| < |r_{0j}|$ .
  - Ta loại biến  $\mathbf{Z}_i$  ra khỏi mô hình nếu  $|r_{0i}| > |r_{0j}|$ .
3. Thực hiện hồi quy sau khi ma trận  $\mathbf{Z}$  đã loại bỏ biến  $\mathbf{Z}_i$  hay  $\mathbf{Z}_j$ .

Cơ sở để thực hiện loại biến dự đoán ở bước 2 đó là dựa trên sự tương quan của biến này đối với  $\mathbf{Y}$ , biến nào thể hiện mức độ tương quan với  $\mathbf{Y}$  lớn hơn, tức là có hệ số tương quan sát với 1 hơn, thì biến đó sẽ được giữ lại.

### Ví dụ

Ta có ma trận thiết kế và giá trị dự đoán như sau:

$$\mathbf{Z} = \begin{bmatrix} 1 & 1.9999 & 3.0001 \\ 1 & 4.0001 & 4.9999 \\ 1 & 0.0001 & 1.0001 \end{bmatrix}, \mathbf{Y} = \begin{bmatrix} 8 & 14 & 2 \end{bmatrix}^T$$

Ta tiến hành làm như sau:

- Bước 1: Tìm các  $|r_{ij}| \geq 0,7$ . Ta tính được ma trận hiệp phương sai và ma trận hệ số tương quan mẫu là:

$$\mathbf{S} = \begin{bmatrix} 4 & 3.9999 \\ 3.9999 & 5.4997 \end{bmatrix}, \quad \mathbf{R} = \begin{bmatrix} 1 & 0.8528 \\ 0.8528 & 1 \end{bmatrix}$$

- Bước 2: Tính các  $r_{0i}$

$$s_{00} = 36$$

$$s_{01} = 12, s_{02} = 11.9994$$

$$\Rightarrow r_{01} = s_{01}/\sqrt{s_{11}s_{00}} = 0.9999 \text{ và } r_{02} = s_{02}/\sqrt{s_{22}s_{00}} = 0.8528$$

Ta thấy:  $|r_{01}| > |r_{02}|$  nên ta sẽ loại biến  $\mathbf{Z}_2$  ra khỏi mô hình.

- Bước 3: Ta thực hiện hồi quy sau khi đã loại bỏ biến  $\mathbf{Z}_2$ .

## 2.6.4 Khảo sát phần dư

Một giá thiết quan trọng của mô hình hồi quy tuyến tính đó là nhiễu  $\varepsilon$  có phân phối chuẩn. Trên thực tế, ta không thể biết được sai số của phép đo có phân phối chuẩn hay không nên ta phải đưa vào bài toán kiểm định. Ta sẽ đưa ra một tiêu chuẩn để chấp nhận hay bác bỏ giả thuyết:

$$\mathbf{H}_0 : \varepsilon \sim N_n(0, \sigma^2 \mathbf{I})$$

hay:

$$\mathbf{H}_0 : \hat{\varepsilon} \sim N_n(0, \sigma^2 (\mathbf{I} - \mathbf{H}))$$

Ta có bổ đề sau:

**Bổ đề:** Nếu ma trận  $\mathbf{A}$  là ma trận lũy đẳng ( $\mathbf{A}^2 = \mathbf{A}$ ) thì nó sẽ có trị riêng là 0 hoặc 1.

Ma trận  $\mathbf{I} - \mathbf{H}$  là ma trận lũy đẳng nên theo bổ đề 1 thì  $\mathbf{I} - \mathbf{H}$  chỉ có các giá trị riêng là 0 hoặc là 1.

Xét dãy:  $e_1, \dots, e_{n-k-1}$  là  $(n - k - 1)$  vectơ riêng ứng với giá trị riêng là 1 của  $\mathbf{I} - \mathbf{H}$  còn lại là dãy  $e_{n-k}, \dots, e_n$  là  $k + 1$  vectơ riêng ứng với giá trị riêng bằng 0 của  $\mathbf{I} - \mathbf{H}$ . Khi đó, ta có:

$$\mathbf{I} - \mathbf{H} = \mathbf{P}\mathbf{\Lambda}\mathbf{P}^T$$

Trong đó  $\mathbf{P} = [e_1, \dots, e_n] = [e_{ij}]_{n \times n}$  là hệ các vector riêng trực chuẩn,  $\Lambda = \text{diag}\{1, 1, \dots, 1, 0, \dots, 0\}$  là ma trận chéo có đường chéo gồm  $n - k - 1$  số 1 và  $k + 1$  số 0

Xét vectơ ngẫu nhiên:

$$\varepsilon^* = \mathbf{P}^\top \hat{\varepsilon} = (\varepsilon_1^*, \dots, \varepsilon_n^*)$$

Khi đó với  $\varepsilon$  có phân phối chuẩn  $N_n(0, \sigma^2 \mathbf{I})$  ta có:

- $E(\varepsilon^*) = \mathbf{P}^\top E(\hat{\varepsilon}) = 0$
- $\text{cov}(\varepsilon^*) = \text{cov}(\mathbf{P}^\top \hat{\varepsilon}) = \mathbf{P}^\top \text{cov}(\hat{\varepsilon}) \mathbf{P} = \mathbf{P}^\top \sigma^2 [\mathbf{I} - \mathbf{H}] \mathbf{P} = \sigma^2 \mathbf{P}^\top \mathbf{P} \Lambda \mathbf{P}^\top \mathbf{P} = \sigma^2 \Lambda$

Do đó, nếu  $\mathbf{H}_0$  đúng thì  $\varepsilon_1^*, \dots, \varepsilon_{n-k-1}^*$  là các biến ngẫu nhiên độc lập có phân bố chuẩn còn  $\varepsilon_{n-k}^* = \dots = \varepsilon_n^*$ .

$$\text{Vì vậy nên: } \sum_{j=1}^n \varepsilon_j^* = \sum_{j=1}^{n-k-1} \varepsilon_j^*, \sum_{j=1}^n (\varepsilon_j^*)^2 = \sum_{j=1}^{n-k-1} (\varepsilon_j^*)^2$$

$$\text{Ta đặt: } \bar{\varepsilon}^* = \sum_{j=1}^n \varepsilon_j^* / n; \tilde{\varepsilon}^* = \sum_{j=1}^{n-k-1} \varepsilon_j^* / (n - k - 1).$$

Ta sẽ có  $n\bar{\varepsilon}^* = (n - k - 1)\tilde{\varepsilon}^*$  khi  $\mathbf{H}_0$  đúng.

Hơn nữa, ta còn có:

$$\sum_{j=1}^{n-k-1} (\varepsilon_j^*)^2 - (n - k - 1) (\tilde{\varepsilon}^*)^2 = \sum_{j=1}^{n-k-1} (\varepsilon_j^{*2} - \tilde{\varepsilon}^{*2})$$

Xét thống kê:

$$T = \frac{n(n - k - 2)^{1/2} \bar{\varepsilon}^*}{(n - k - 1)^{1/2} \left[ \sum_{j=1}^n (\varepsilon_j^*)^2 - n^2 (\bar{\varepsilon}^*)^2 / (n - k - 1) \right]^{1/2}}$$

Nếu giả thiết  $\mathbf{H}_0$  đúng thì:

$$\begin{aligned} T &= \frac{(n - k - 1)(n - k - 2)^{1/2} \tilde{\varepsilon}^*}{(n - k - 1)^{1/2} \left[ \sum_{j=1}^{n-k-1} (\varepsilon_j^*)^2 - (n - k - 1)^2 (\tilde{\varepsilon}^*)^2 / (n - k - 1) \right]^{1/2}} \\ &= \frac{(n - k - 1)^{1/2} \tilde{\varepsilon}^*}{\left\{ \sum_{j=1}^{n-k-1} \left[ (\varepsilon_j^*)^2 - \tilde{\varepsilon}^{*2} \right] / (n - k - 2) \right\}^{1/2}} \end{aligned}$$

có phân bố Student với  $n - k - 2$  bậc tự do. Vậy với mức ý nghĩa  $\alpha$  ta sẽ bác bỏ  $\mathbf{H}_0$  nếu:

$$|T| > t_{n-k-2} \left( \frac{\alpha}{2} \right)$$

Thống kê  $T$  ở trên chỉ xác định khi  $n \geq k + 2$ . Nhưng trong thực tế, thường giá trị quan sát  $n$  sẽ lớn hơn rất nhiều so với  $k + 2$  là biến dự đoán nên ràng buộc này hầu như luôn thỏa mãn.

## 2.7 Mô hình hồi quy tuyến tính đa bội

### 2.7.1 Mô hình bài toán

Mô hình hóa quan hệ giữa  $m$  biến phụ thuộc  $\mathbf{Y}_1, \mathbf{Y}_2, \dots, \mathbf{Y}_m$  và tập các biến độc lập  $z_1, z_2, \dots, z_k$ .

Giả sử mỗi biến phụ thuộc tuân theo một mô hình hồi quy, theo đó:

$$\mathbf{Y}_1 = \beta_{01} + \beta_{11}z_1 + \dots + \beta_{k1}z_k + \varepsilon_1$$

$$\mathbf{Y}_2 = \beta_{02} + \beta_{12}z_1 + \dots + \beta_{k2}z_k + \varepsilon_2$$

$$\vdots$$

$$\mathbf{Y}_m = \beta_{0m} + \beta_{1m}z_1 + \dots + \beta_{km}z_k + \varepsilon_m$$

Sai số  $\varepsilon^\top = [\varepsilon_1, \varepsilon_2, \dots, \varepsilon_n]$  có  $E(\varepsilon) = 0$  và  $Var(\varepsilon) = \Sigma$ . Để xây dựng khái niệm mô hình mới sao cho phù hợp với mô hình hồi quy tuyến tính cổ điển, ta đặt  $[z_{j0}, z_{j1}, \dots, z_{jk}]$  là giá trị các biến độc lập ở lần quan sát thứ  $j$ , đặt  $\mathbf{Y}_j^\top = [\mathbf{Y}_{j1}, \mathbf{Y}_{j2}, \dots, \mathbf{Y}_{jm}]$  là các biến phụ thuộc, và đặt  $\varepsilon_j^\top = [\varepsilon_{j1}, \varepsilon_{j2}, \dots, \varepsilon_{jm}]$  là sai số.

Kí hiệu ma trận:

$$\mathbf{Z}_{n \times (k+1)} = \begin{bmatrix} 1 & z_{11} & \dots & z_{1k} \\ 1 & z_{21} & \dots & z_{2k} \\ \vdots & \vdots & \ddots & \vdots \\ 1 & z_{n1} & \dots & z_{nk} \end{bmatrix}$$

cũng tương tự như ma trận  $\mathbf{Z}$  trong mô hình hồi quy tuyến tính đơn biến cổ điển.

Các ma trận còn lại:

$$\mathbf{Y}_{n \times m} = \begin{bmatrix} \mathbf{Y}_{11} & \mathbf{Y}_{12} & \cdots & \mathbf{Y}_{1m} \\ \mathbf{Y}_{21} & \mathbf{Y}_{22} & \cdots & \mathbf{Y}_{2m} \\ \vdots & \vdots & \ddots & \vdots \\ \mathbf{Y}_{n1} & \mathbf{Y}_{n2} & \cdots & \mathbf{Y}_{nm} \end{bmatrix} = \begin{bmatrix} \mathbf{Y}_{(1)} & \vdots & \mathbf{Y}_{(2)} & \vdots & \cdots & \vdots & \mathbf{Y}_{(m)} \end{bmatrix}$$

$$\boldsymbol{\beta}_{(k+1) \times m} = \begin{bmatrix} \beta_{01} & \beta_{02} & \cdots & \beta_{0m} \\ \beta_{11} & \beta_{12} & \cdots & \beta_{1m} \\ \vdots & \vdots & \ddots & \vdots \\ \beta_{k1} & \beta_{k2} & \cdots & \beta_{km} \end{bmatrix} = \begin{bmatrix} \boldsymbol{\beta}_{(1)} & \vdots & \boldsymbol{\beta}_{(2)} & \vdots & \cdots & \vdots & \boldsymbol{\beta}_{(m)} \end{bmatrix}$$

$$\boldsymbol{\varepsilon}_{n \times m} = \begin{bmatrix} \varepsilon_{11} & \varepsilon_{12} & \cdots & \varepsilon_{1m} \\ \varepsilon_{21} & \varepsilon_{22} & \cdots & \varepsilon_{2m} \\ \vdots & \vdots & \ddots & \vdots \\ \varepsilon_{n1} & \varepsilon_{n2} & \cdots & \varepsilon_{nm} \end{bmatrix} = \begin{bmatrix} \boldsymbol{\varepsilon}_{(1)} & \vdots & \boldsymbol{\varepsilon}_{(2)} & \vdots & \cdots & \vdots & \boldsymbol{\varepsilon}_{(m)} \end{bmatrix}$$

Từ đó, mô hình hồi quy tuyến tính bội được định nghĩa là:

$$\begin{bmatrix} \mathbf{Y} \\ n \times m \end{bmatrix} = \begin{bmatrix} \mathbf{Z} \\ n \times (k+1) \end{bmatrix} \begin{bmatrix} \boldsymbol{\beta} \\ (k+1) \times m \end{bmatrix} + \begin{bmatrix} \boldsymbol{\varepsilon} \\ n \times m \end{bmatrix}$$

Với:

$$E(\boldsymbol{\varepsilon}_{(j)}) = 0 \text{ và } cov(\boldsymbol{\varepsilon}_{(i)}, \boldsymbol{\varepsilon}_{(j)}) = \sigma_{ij} \mathbf{I} \quad \forall i, j = \overline{1, m}.$$

và ma trận hiệp phương sai của  $m$  giá trị nhiễu tại quan sát thứ  $j$ :

$$Var(\boldsymbol{\varepsilon}_j) = \Sigma = \begin{bmatrix} \sigma_{11} & \sigma_{12} & \cdots & \sigma_{1m} \\ \sigma_{21} & \sigma_{22} & \cdots & \sigma_{2m} \\ \vdots & \vdots & \ddots & \vdots \\ \sigma_{m1} & \sigma_{m2} & \cdots & \sigma_{mm} \end{bmatrix} \quad \forall j = \overline{1, n}$$

Tương tự như mô hình hồi quy tuyến tính cổ điển, các nhiễu tại các quan sát khác nhau sẽ không có sự tương quan, hay nói cách khác  $Cov(\boldsymbol{\varepsilon}_{ij}, \boldsymbol{\varepsilon}_{kq}) = 0$

với  $j \neq q$ . Tuy nhiên, các nhiễu tại cùng một quan sát có thể có tương quan với nhau.

Các tham số mà ta chưa biết là  $[\beta]$  và  $\Sigma$ , việc ước lượng các tham số này dựa trên các quan sát mà ta thu thập sẽ được trình bày chi tiết ở phần sau.

## 2.7.2 Ước lượng các tham số

### 1. Ước lượng bình phương cực tiểu của $[\beta]$

Như đã đề cập ở phần trước, ta có biến phản hồi thứ  $j$  tuân theo mô hình hồi quy tuyến tính cổ điển:

$$\mathbf{Y}_{(j)} = \mathbf{Z}\beta_{(j)} + \beta_{(j)}$$

Với mỗi mô hình như vậy, tổng bình phương nhiễu  $RSS_j$  được cực tiểu hóa bởi  $[\hat{\beta}]_{(j)} = (\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{Z}^\top \mathbf{Y}_{(j)}$ . Mặt khác, tổng bình phương nhiễu của cả mô hình hồi quy tuyến tính bội được cho bởi công thức:

$$RSS([\beta]) = \sum_{j=1}^n RSS(\beta_{(j)}) = \sum_{j=1}^n (\mathbf{Y}_{(j)} - \mathbf{Z}\beta_{(j)})^\top (\mathbf{Y}_{(j)} - \mathbf{Z}\beta_{(j)})$$

Vì mỗi số hạng trong chuỗi tổng trên là một số không âm nên  $RSS([\beta])$  của toàn bộ mô hình đạt cực tiểu khi từng  $RSS(\beta_{(i)})$  đạt cực tiểu. Để đạt được điều này thì ta phải có  $\beta_{(j)} = [\hat{\beta}]_{(j)} = (\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{Z}^\top \mathbf{Y}_{(j)}$ , hay:

$$[\hat{\beta}] = (\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{Z}^\top [\mathbf{Y}] \quad (2.7.1)$$

Từ đó suy ra  $[\hat{\beta}]$  là một ước lượng bình phương cực tiểu cho ma trận hệ số hồi quy  $[\beta]$ .

### 2. Ước lượng cho $[\mathbf{Y}]$ , $[\epsilon]$ và $\Sigma$

Sử dụng ước lượng bình phương cực tiểu  $[\hat{\beta}]$  vừa tìm được ở công thức (2.7.1), ta dễ dàng xây dựng các ma trận ước lượng của  $[\mathbf{Y}]$  và  $[\epsilon]$  như sau:

$$\begin{aligned} [\hat{\mathbf{Y}}] &= \mathbf{Z} [\hat{\beta}] = \mathbf{Z} (\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{Z}^\top [\mathbf{Y}] \\ [\hat{\epsilon}] &= [\mathbf{Y}] - [\hat{\mathbf{Y}}] = \left( \mathbf{I} - \mathbf{Z} (\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{Z}^\top \right) [\mathbf{Y}] \end{aligned}$$

Hơn nữa, ta có:



$$\begin{aligned}\mathbf{Z}^\top [\hat{\boldsymbol{\varepsilon}}] &= \mathbf{Z}^\top \left( \mathbf{I} - \mathbf{Z} (\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{Z}^\top \right) [\mathbf{Y}] = \left( \mathbf{Z}^\top - \mathbf{Z}^\top \mathbf{Z} (\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{Z}^\top \right) [\mathbf{Y}] = 0 \\ [\hat{\mathbf{Y}}]^\top [\hat{\boldsymbol{\varepsilon}}] &= \left( \mathbf{Z} [\hat{\boldsymbol{\beta}}] \right)^\top [\hat{\boldsymbol{\varepsilon}}] = [\hat{\boldsymbol{\beta}}]^\top \mathbf{Z}^\top [\hat{\boldsymbol{\varepsilon}}] = 0\end{aligned}$$

Điều này kéo theo mọi cột của  $\mathbf{Z}$  và  $[\hat{\mathbf{Y}}]$  trực giao với mọi cột của  $[\hat{\boldsymbol{\varepsilon}}]$ . Mặt khác, do  $[\mathbf{Y}] = [\hat{\mathbf{Y}}] + [\hat{\boldsymbol{\varepsilon}}]$  nên:

$$[\mathbf{Y}]^\top [\mathbf{Y}] = \left( [\hat{\mathbf{Y}}] + [\hat{\boldsymbol{\varepsilon}}] \right)^\top \left( [\hat{\mathbf{Y}}] + [\hat{\boldsymbol{\varepsilon}}] \right) = [\hat{\mathbf{Y}}]^\top [\hat{\mathbf{Y}}] + [\hat{\boldsymbol{\varepsilon}}]^\top [\hat{\boldsymbol{\varepsilon}}]$$

Tiếp theo, ta sẽ tìm công thức ước lượng cho ma trận hiệp phương sai  $\boldsymbol{\Sigma}$ . Cụ thể hơn, ta có định lý sau:

### Định lý

Xét mô hình hồi quy tuyến tính bội  $[\mathbf{Y}] = \mathbf{Z} [\boldsymbol{\beta}] + [\boldsymbol{\varepsilon}]$ , với  $\text{rank } \mathbf{Z} = r+1 \leq n-m$ , và nhiễu  $[\boldsymbol{\varepsilon}]$  có phân phối chuẩn. Khi đó:

$$\hat{\boldsymbol{\Sigma}} = \frac{1}{n} [\hat{\boldsymbol{\varepsilon}}]^\top [\hat{\boldsymbol{\varepsilon}}] = \frac{1}{n} \left( [\mathbf{Y}] - \mathbf{Z} [\hat{\boldsymbol{\beta}}] \right)^\top \left( [\mathbf{Y}] - \mathbf{Z} [\hat{\boldsymbol{\beta}}] \right)$$

là ước lượng hợp lý cực đại của  $\boldsymbol{\Sigma}$

### Chứng minh

Theo giả thiết, ta có  $n$  quan sát và tại quan sát thứ  $i$  thì vector  $\boldsymbol{\varepsilon}_i = [\varepsilon_{i1} \ \varepsilon_{i2} \dots \varepsilon_{im}]$  tuân theo phân phối chuẩn  $m$  chiều  $N(0, \boldsymbol{\Sigma})$  với hàm mật độ xác suất đồng thời:

$$\begin{aligned}f(\boldsymbol{\varepsilon}_i) &= \frac{1}{\sqrt{(2\pi)^m \det \boldsymbol{\Sigma}}} \exp \left( -\frac{1}{2} \boldsymbol{\varepsilon}_i \boldsymbol{\Sigma}^{-1} \boldsymbol{\varepsilon}_i^\top \right) \\ &= \frac{1}{\sqrt{(2\pi)^m \det \boldsymbol{\Sigma}}} \exp \left[ -\frac{1}{2} (\mathbf{Y}_i - \mathbf{Z} \boldsymbol{\beta}_i) \boldsymbol{\Sigma}^{-1} (\mathbf{Y}_i - \mathbf{Z} \boldsymbol{\beta}_i)^\top \right]\end{aligned}$$

Từ đây ta có được hàm hợp lý cho  $n$  quan sát:

$$\begin{aligned}L([\boldsymbol{\beta}], \boldsymbol{\Sigma}, [\mathbf{Y}]) &= \prod_{i=1}^n f(\boldsymbol{\varepsilon}_i) \\ &= \frac{1}{\sqrt{(2\pi)^{mn} (\det \boldsymbol{\Sigma})^n}} \exp \left[ -\frac{1}{2} \sum_{i=1}^n (\mathbf{Y}_i - \mathbf{Z} \boldsymbol{\beta}_i) \boldsymbol{\Sigma}^{-1} (\mathbf{Y}_i - \mathbf{Z} \boldsymbol{\beta}_i)^\top \right]\end{aligned} \tag{2.7.2}$$

Đặt:

$$\mathbf{Q} = [q_{ij}]_{n \times n} = [\hat{\boldsymbol{\varepsilon}}]^\top [\hat{\boldsymbol{\varepsilon}}] = \left( [\mathbf{Y}] - \mathbf{Z} [\hat{\boldsymbol{\beta}}] \right)^\top \left( [\mathbf{Y}] - \mathbf{Z} [\hat{\boldsymbol{\beta}}] \right)$$

khi đó:

$$q_{ij} = \sum_{k=1}^n (y_{ki} - \hat{y}_{ki}) (y_{kj} - \hat{y}_{kj})$$

trong đó  $y_{ki}$  và  $\hat{y}_{ki}$  lần lượt là phần tử ở hàng  $i$ , cột  $j$  của ma trận  $[\mathbf{Y}]$  và  $[\hat{\mathbf{Y}}] = [\mathbf{Z}] [\hat{\boldsymbol{\beta}}]$ . Với  $(\boldsymbol{\Sigma}^{-1})_{ij}$  là phần tử ở hàng  $i$ , cột  $j$  của ma trận  $\boldsymbol{\Sigma}^{-1}$ , ta có biến đổi:

$$\begin{aligned} \sum_{i=1}^n (\mathbf{Y}_i - \mathbf{Z} \boldsymbol{\beta}_i) \boldsymbol{\Sigma}^{-1} (\mathbf{Y}_i - \mathbf{Z} \boldsymbol{\beta}_i)^\top &= \sum_{i=1}^n \left[ \sum_{j=1}^m \sum_{k=1}^m (y_{ij} - \hat{y}_{ij}) (\boldsymbol{\Sigma}^{-1})_{jk} (y_{ik} - \hat{y}_{ik}) \right] \\ &= \sum_{j=1}^m \sum_{k=1}^m \left[ (\boldsymbol{\Sigma}^{-1})_{jk} \sum_{i=1}^n (y_{ij} - \hat{y}_{ij}) (y_{ik} - \hat{y}_{ik}) \right] \\ &= \sum_{j=1}^m \sum_{k=1}^m (\boldsymbol{\Sigma}^{-1})_{jk} q_{jk} \\ &= \text{tr} (\boldsymbol{\Sigma}^{-1} \mathbf{Q}) \end{aligned}$$

Như vậy hàm hợp lý ở công thức (2.7.2) có thể được viết lại thành:

$$L([\boldsymbol{\beta}], \boldsymbol{\Sigma}, [\mathbf{Y}]) = \frac{1}{\sqrt{(2\pi)^{mn} (\det \boldsymbol{\Sigma})^n}} \exp \left[ -\frac{1}{2} \text{tr} (\boldsymbol{\Sigma}^{-1} \mathbf{Q}) \right]$$

Tới đây ta sẽ tìm ma trận  $\boldsymbol{\Sigma}$  để cực đại hóa log-hàm hợp lý:

$$\log L([\boldsymbol{\beta}], \boldsymbol{\Sigma}, [\mathbf{Y}]) = -mn \log(2\pi) + n \log \det (\boldsymbol{\Sigma}^{-1}) - \frac{1}{2} \text{tr} (\boldsymbol{\Sigma}^{-1} \mathbf{Q})$$

Do  $\mathbf{Q}$  là ma trận đối xứng xác định dương nên tồn tại ma trận nghịch đảo của nó và ma trận căn bậc hai  $\mathbf{Q}^{1/2}$ .

Đặt  $\mathbf{A} = \mathbf{Q}^{1/2} \boldsymbol{\Sigma}^{-1} \mathbf{Q}^{1/2}$ , khi đó  $\boldsymbol{\Sigma}^{-1} = \mathbf{Q}^{-1/2} \mathbf{A} \mathbf{Q}^{-1/2}$ . Ta viết lại log-hàm hợp lý thành:

$$\begin{aligned} \log L([\boldsymbol{\beta}], \boldsymbol{\Sigma}, [\mathbf{Y}]) &= -mn \log 2\pi + n \log \det (\mathbf{Q}^{-1/2} \mathbf{A} \mathbf{Q}^{-1/2}) - \text{tr} (\mathbf{Q}^{-1/2} \mathbf{A} \mathbf{Q}^{-1/2} \mathbf{Q}) \\ &= -mn \log 2\pi + n \log \det (\mathbf{Q}^{-1}) + n \log \det \mathbf{A} - \text{tr} (\mathbf{Q}^{-1/2} \mathbf{A} \mathbf{Q}^{-1/2}) \\ &= -mn \log 2\pi - n \log \det \mathbf{Q} + n \log \det \mathbf{A} - \text{tr} \mathbf{A} \end{aligned} \tag{2.7.3}$$

Gọi  $\lambda_i$  ( $i = \overline{1, m}$ ) là các trị riêng của ma trận  $\mathbf{A}$ . Ta có các kết quả đã có trong đại số tuyến tính như sau:

$$\det \mathbf{A} = \prod_i \lambda_i \text{ và } \operatorname{tr} \mathbf{A} = \sum_i \lambda_i$$

Thay các kết quả này vào (2.7.3), ta được:

$$\log L([\boldsymbol{\beta}], \boldsymbol{\Sigma}, [\mathbf{Y}]) = -mn \log 2\pi - n \log \det \mathbf{Q} + \sum_{i=1}^m (-\lambda_i + n \log \lambda_i)$$

Như vậy log-hàm hợp lý đạt cực đại khi và chỉ khi các giá trị  $-\lambda_i + n \log \lambda_i$  đạt cực đại, tương đương với  $\lambda_i = n$  với mỗi  $i = \overline{1, m}$ . Mặt khác, do  $\mathbf{A}$  là ma trận đối xứng nên ta có thể viết  $\mathbf{A}$  dưới dạng chéo hóa:  $\mathbf{A} = \mathbf{P} \boldsymbol{\Lambda} \mathbf{P}^\top$  trong đó  $\boldsymbol{\Lambda} = \operatorname{diag} \{\lambda_1, \lambda_2, \dots, \lambda_m\}$  và  $\mathbf{P}$  là ma trận trực giao. Do các trị riêng của  $\mathbf{A}$  đều bằng  $n$  nên:

$$\mathbf{A} = \mathbf{P} (n\mathbf{I}) \mathbf{P}^\top = n\mathbf{P}\mathbf{P}^\top = n\mathbf{I}$$

Từ đây suy ra ước lượng hợp lý cực đại của  $\boldsymbol{\Sigma}$  là:

$$\begin{aligned} \hat{\boldsymbol{\Sigma}} &= \mathbf{Q}^{1/2} \mathbf{A}^{-1} \mathbf{Q}^{1/2} = \mathbf{Q}^{1/2} \left( \frac{1}{n} \mathbf{I} \right) \mathbf{Q}^{1/2} = \frac{1}{n} \mathbf{Q} = \\ &= \frac{1}{n} \left( [\mathbf{Y}] - \mathbf{Z} [\hat{\boldsymbol{\beta}}] \right)^\top \left( [\mathbf{Y}] - \mathbf{Z} [\hat{\boldsymbol{\beta}}] \right) \end{aligned}$$

### Hệ quả

Giá trị lớn nhất của hàm hợp lý cực đại đạt tại  $[\hat{\boldsymbol{\beta}}]$  và  $\hat{\boldsymbol{\Sigma}}$  là:

$$\begin{aligned} L([\boldsymbol{\beta}], \boldsymbol{\Sigma}, [\mathbf{Y}]) &= \frac{1}{\sqrt{(2\pi)^{mn} (\det \boldsymbol{\Sigma})^n}} \exp \left[ -\frac{1}{2} \operatorname{tr} (\boldsymbol{\Sigma}^{-1} \mathbf{Q}) \right] \\ &= \frac{1}{\sqrt{(2\pi)^{mn} (\det \boldsymbol{\Sigma})^n}} \exp \left\{ -\frac{1}{2} \operatorname{tr} \left[ n \left( [\boldsymbol{\varepsilon}]^\top [\boldsymbol{\varepsilon}] \right)^{-1} \left( [\boldsymbol{\varepsilon}]^\top [\boldsymbol{\varepsilon}] \right) \right] \right\} \\ &= \frac{1}{\sqrt{(2\pi)^{mn} (\det \boldsymbol{\Sigma})^n}} \exp \left[ -\frac{1}{2} \operatorname{tr} (n\mathbf{I}) \right] \\ &= (\det \boldsymbol{\Sigma})^{-\frac{n}{2}} (2\pi e)^{-\frac{mn}{2}} \end{aligned}$$

Với ước lượng như trên thì  $n\hat{\boldsymbol{\Sigma}}$  sẽ tuân theo phân phối  $W_{p, n-k-1}(\boldsymbol{\Sigma})$ .

### 2.7.3 Các tính chất quan trọng

Ở phần này, ta sẽ bàn về các tính chất của các tham số ước lượng, ví dụ như xét xem liệu các ước lượng đó có là ước lượng hợp lý cực đại với các mẫu quan sát được không, liệu chúng là ước lượng chệch hay không chệch.

#### Tính chất 1

$[\hat{\beta}]$  là ước lượng không chệch của  $\beta$

#### Chứng minh

Để chứng minh tính chất này ta cần chỉ ra  $E([\hat{\beta}]) = \beta$ . Thật vậy, ta có:

$$\begin{aligned} E([\hat{\beta}]) &= E[(Z^T Z)^{-1} Z^T [Y]] \\ &= E[(Z^T Z)^{-1} Z^T (Z[\beta] + [\epsilon])] \\ &= E[(Z^T Z)^{-1} Z^T Z[\beta]] + E[(Z^T Z)^{-1} Z^T [\epsilon]] \\ &= [\beta] + (Z^T Z)^{-1} Z^T E([\epsilon]) = [\beta] \quad (E([\epsilon]) = 0) \end{aligned}$$

Như vậy,  $[\hat{\beta}]$  là một ước lượng không chệch của  $\beta$

#### Tính chất 2

$[\hat{\beta}]$  là ước lượng hợp lý cực đại của  $[\beta]$  (Khi nhiều  $[\epsilon]$  có phân phối chuẩn)

#### Chứng minh

Khi  $[\epsilon]$  có phân phối chuẩn thì hàm hợp lý cho  $n$  quan sát sẽ có dạng như công thức (2.7.2):

$$\begin{aligned} L([\beta], \Sigma, [Y]) &= \prod_{i=1}^n f(\epsilon_i) \\ &= \frac{1}{\sqrt{(2\pi)^{mn} (\det \Sigma)^n}} \exp \left[ -\frac{1}{2} \sum_{i=1}^n (Y_i - Z\beta_i) \Sigma^{-1} (Y_i - Z\beta_i)^T \right] \end{aligned}$$

Đặt:

$$\mathbf{S}_i = (\mathbf{Y}_i - \mathbf{Z}\boldsymbol{\beta}_i) \boldsymbol{\Sigma}^{-1} (\mathbf{Y}_i - \mathbf{Z}\boldsymbol{\beta}_i)^\top$$

$$\mathbf{S} = \sum_{i=1}^n (\mathbf{Y}_i - \mathbf{Z}\boldsymbol{\beta}_i) \boldsymbol{\Sigma}^{-1} (\mathbf{Y}_i - \mathbf{Z}\boldsymbol{\beta}_i)^\top = \sum_{i=1}^n \mathbf{S}_i$$

Ta sẽ tìm giá trị  $[\hat{\boldsymbol{\beta}}]$  để cực đại hóa hàm hợp lý trên. Do đại lượng  $1/\sqrt{(2\pi)^{mn}(\det\boldsymbol{\Sigma})^n}$  không phụ thuộc vào  $[\boldsymbol{\beta}]$  nên  $L$  đạt cực đại khi và chỉ khi giá trị  $\mathbf{S}$  đạt cực tiểu. Mặt khác, bởi vì  $\mathbf{S}$  là tổng của dạng toàn phương xác định không âm  $\mathbf{S}_i$  nên  $\mathbf{S}$  đạt cực tiểu khi và chỉ khi các giá trị  $\mathbf{S}_i$  đạt cực tiểu. Ta có:

$$\frac{\partial \mathbf{S}_i}{\partial [\boldsymbol{\beta}]^\top} = \left[ \boldsymbol{\Sigma}^{-1} + (\boldsymbol{\Sigma}^{-1})^\top \right] \left( \mathbf{Y}_i^\top - [\boldsymbol{\beta}]^\top \mathbf{Z}_i^\top \right) (-\mathbf{Z}_i) = -2\boldsymbol{\Sigma}^{-1} \left( \mathbf{Y}_i^\top \mathbf{Z}_i - [\boldsymbol{\beta}]^\top \mathbf{Z}_i^\top \mathbf{Z}_i \right)$$

Do ma trận  $\boldsymbol{\Sigma}^{-1}$  là ma trận đối xứng xác định dương nên  $\partial \mathbf{S}_i / \partial [\boldsymbol{\beta}]^\top = 0$  khi và chỉ khi  $\mathbf{Y}_i^\top \mathbf{Z}_i = [\boldsymbol{\beta}]^\top (\mathbf{Z}_i^\top \mathbf{Z}_i)$ . Lấy tổng với  $i$  từ 1 đến  $n$ , ta được:

$$\sum_{i=1}^n \mathbf{Y}_i^\top \mathbf{Z}_i = \sum_{i=1}^n [\boldsymbol{\beta}]^\top (\mathbf{Z}_i^\top \mathbf{Z}_i) \text{ hay } [\mathbf{Y}]^\top \mathbf{Z} = [\boldsymbol{\beta}]^\top (\mathbf{Z}^\top \mathbf{Z})$$

Như vậy ước lượng hợp lý cực đại của  $[\boldsymbol{\beta}]$  chính là nghiệm của phương trình  $\partial \mathbf{S}_i / \partial [\boldsymbol{\beta}]^\top = 0$ , và nghiệm đó chính là  $[\boldsymbol{\beta}] = (\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{Z}^\top [\mathbf{Y}]$

### Tính chất 3

$$E([\hat{\boldsymbol{\varepsilon}}]) = 0 \quad \text{và} \quad \text{Cov}(\boldsymbol{\beta}_{(i)}, \boldsymbol{\beta}_{(j)}) = \boldsymbol{\sigma}_{ij} (\mathbf{Z}^\top \mathbf{Z})^{-1}$$

### Chứng minh

Để thấy  $E([\hat{\boldsymbol{\varepsilon}}]) = 0$  vì với mọi  $j = \overline{1, m}$ , ta có:

$$E([\hat{\boldsymbol{\varepsilon}}]_{(j)}) = E\left[\mathbf{Y}_j - \mathbf{Z} [\hat{\boldsymbol{\beta}}]_{(j)}\right] = E\left[\mathbf{Z} \left(\boldsymbol{\beta}_{(j)} - [\hat{\boldsymbol{\beta}}]_{(j)}\right) + \boldsymbol{\varepsilon}_{(j)}\right] = 0$$

Mặt khác, với phép đặt  $\mathbf{C} = (\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{Z}^\top$ , ta có:

$$\begin{aligned} \text{Cov} \left( \left[ \hat{\beta} \right]_{(i)}, \left[ \hat{\beta} \right]_{(j)} \right) &= \text{Cov} (\mathbf{C} \mathbf{Y}_{(i)}, \mathbf{C} \mathbf{Y}_{(j)}) \\ &= E \left[ \mathbf{C} \mathbf{Y}_{(i)} - E(\mathbf{C} \mathbf{Y}_{(i)}) \right] \left[ \mathbf{C} \mathbf{Y}_{(j)} - E(\mathbf{C} \mathbf{Y}_{(j)}) \right]^\top \\ &= \mathbf{C} \left[ E \left( \mathbf{Y}_{(i)} - \mathbf{Z} \beta_{(i)} \right) \left( \mathbf{Y}_{(j)} - \mathbf{Z} \beta_{(j)} \right)^\top \right] \mathbf{C}^\top \\ &= \mathbf{C} E \left[ \boldsymbol{\varepsilon}_{(i)} \boldsymbol{\varepsilon}_{(j)}^\top \right] \mathbf{C}^\top = \mathbf{C} \text{Cov} \left[ \boldsymbol{\varepsilon}_{(i)}, \boldsymbol{\varepsilon}_{(j)} \right] \mathbf{C}^\top \\ &= (\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{Z}^\top (\sigma_{ij} \mathbf{I}) \mathbf{Z} (\mathbf{Z}^\top \mathbf{Z})^{-1} \\ &= \sigma_{ij} (\mathbf{Z}^\top \mathbf{Z})^{-1} \end{aligned}$$

#### Tính chất 4

$\left[ \hat{\beta} \right]$  có phân phối chuẩn

#### Chứng minh

Với giả thiết  $\boldsymbol{\varepsilon}_{(i)} \sim N_n(0, \sigma_{ii} \mathbf{I})$  ta được  $\mathbf{Y}_{(i)} \sim N_n(\mathbf{Z} \beta, \sigma_{ii} \mathbf{I})$ .

Do đó  $\left[ \hat{\beta} \right]_{(i)} = (\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{Z}^\top \mathbf{Y}_{(i)} \sim N_{k+1} \left[ \beta_{(i)}, \sigma_{ii} (\mathbf{Z}^\top \mathbf{Z})^{-1} \right]$ .

$\Rightarrow \left[ \hat{\beta} \right]$  có phân phối chuẩn.

#### Tính chất 5

$\hat{\Sigma}$  là ước lượng chệch của  $\Sigma$

#### Chứng minh

Trước hết ta chứng minh  $E \left[ \left[ \hat{\varepsilon} \right]_{(i)}^\top \left[ \hat{\varepsilon} \right]_{(j)} \right] = \sigma_{ij} (n - k - 1)$ , với  $\forall i, j = \overline{1, m}$

Thật vậy, với các ma trận đối xứng lũy đẳng  $\mathbf{H} = \mathbf{Z} (\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{Z}^\top$  và  $\mathbf{I} - \mathbf{H}$ ,

ta có biến đổi:

$$\begin{aligned}
 E \left[ [\hat{\boldsymbol{\varepsilon}}]_{(j)}^\top [\hat{\boldsymbol{\varepsilon}}]_{(k)} \right] &= E \left( \mathbf{Y}_{(j)} - \hat{\mathbf{Y}}_{(j)} \right)^\top \left( \mathbf{Y}_{(j)} - \hat{\mathbf{Y}}_{(j)} \right) \\
 &= E \left[ \mathbf{Y}_{(j)} - \mathbf{H} \mathbf{Y}_{(j)} \right]^\top \left[ \mathbf{Y}_{(k)} - \mathbf{H} \mathbf{Y}_{(k)} \right] \\
 &= E \left[ \mathbf{Y}_{(j)}^\top (\mathbf{I} - \mathbf{H}) \mathbf{Y}_{(k)} \right] \\
 &= E \left( \mathbf{Y}_{(j)} - \mathbf{Z} \boldsymbol{\beta}_{(j)} \right)^\top (\mathbf{I} - \mathbf{H}) \left( \mathbf{Y}_{(k)} - \mathbf{Z} \boldsymbol{\beta}_{(k)} \right) \\
 &= E \left[ \boldsymbol{\varepsilon}_{(j)}^\top (\mathbf{I} - \mathbf{H}) \boldsymbol{\varepsilon}_{(k)} \right] \\
 &= E \left\{ \text{tr} \left[ (\mathbf{I} - \mathbf{H}) \boldsymbol{\varepsilon}_{(k)} \boldsymbol{\varepsilon}_{(j)}^\top \right] \right\} \\
 &= \text{tr} \left[ (\mathbf{I} - \mathbf{H}) E \left( \boldsymbol{\varepsilon}_{(k)} \boldsymbol{\varepsilon}_{(j)}^\top \right) \right] \\
 &= \sigma_{jk} \text{tr} (\mathbf{I} - \mathbf{H}) \\
 &= \sigma_{jk} (n - r - 1)
 \end{aligned}$$

Như vậy,  $E \left( \hat{\boldsymbol{\Sigma}} \right) = (n - k - 1) \boldsymbol{\Sigma} / n$  và do đó  $\hat{\boldsymbol{\Sigma}}$  ước lượng chệch của  $\boldsymbol{\Sigma}$ .

### Hệ quả

Ước lượng không chệch của  $\boldsymbol{\Sigma}$  là:

$$\hat{\boldsymbol{\Sigma}}^* = \frac{n}{n - k - 1} \hat{\boldsymbol{\Sigma}} = \frac{n}{n - k - 1} [\hat{\boldsymbol{\varepsilon}}]^\top [\hat{\boldsymbol{\varepsilon}}]$$

## 2.7.4 Đưa ra dự đoán từ mô hình hồi quy tuyến tính đa bội

Xét mô hình hồi quy tuyến tính đa bội  $\mathbf{Y} = \mathbf{Z}\boldsymbol{\beta} + [\boldsymbol{\varepsilon}]$  với  $\text{rank } \mathbf{Z} = k + 1 \leq n - m$  và nhiễu  $[\boldsymbol{\varepsilon}]$  có phân phối chuẩn, với các tham số đã được ước lượng và tính chỉnh. Khi đó, ta có thể tiến hành sử dụng mô hình trong việc dự đoán với các dữ liệu sẵn có. Vấn đề được đặt ra là ta phải dự đoán trung bình của các biến phải hồi dựa trên một quan sát  $\mathbf{Z}_0$  mà ta vừa thu thập được. Suy luận về trung bình của các biến phản hồi có thể được đưa ra dựa vào các phân phối mà ta đã kết luận được từ việc ước lượng các tham số hồi quy.

Trước hết ta có:

$$\left[\hat{\beta}\right]^{\top} \mathbf{z}_0 \sim N_m \left[ \beta^{\top} \mathbf{z}_0, \mathbf{z}_0^{\top} (\mathbf{Z}^{\top} \mathbf{Z})^{-1} \mathbf{z}_0 \Sigma \right] \text{ và } n\hat{\Sigma} \sim W_{n-k-1}(\Sigma)$$

Giá trị cần tìm của hàm hồi quy là  $\beta^{\top} \mathbf{z}_0$ , dựa vào kiến thức về thống kê  $T^2$  ở mục 5 ta có thể viết:

$$T^2 = \left( \frac{\left[\hat{\beta}\right]^{\top} \mathbf{z}_0 - \beta^{\top} \mathbf{z}_0}{\sqrt{\mathbf{z}_0^{\top} (\mathbf{Z}^{\top} \mathbf{Z})^{-1} \mathbf{z}_0}} \right)^{\top} \left( \frac{n}{n-k-1} \hat{\Sigma} \right)^{-1} \left( \frac{\left[\hat{\beta}\right]^{\top} \mathbf{z}_0 - \beta^{\top} \mathbf{z}_0}{\sqrt{\mathbf{z}_0^{\top} (\mathbf{Z}^{\top} \mathbf{Z})^{-1} \mathbf{z}_0}} \right)$$

và miền ellipsoid với độ tin cậy  $100(1-\alpha)\%$  của  $\left[\hat{\beta}\right]^{\top} \mathbf{z}_0$  được cho bởi bất đẳng thức:

$$T^2 = \left( \frac{\left[\hat{\beta}\right]^{\top} \mathbf{z}_0 - \beta^{\top} \mathbf{z}_0}{\sqrt{\mathbf{z}_0^{\top} (\mathbf{Z}^{\top} \mathbf{Z})^{-1} \mathbf{z}_0}} \right)^{\top} \left( \frac{n}{n-k-1} \hat{\Sigma} \right)^{-1} \left( \frac{\left[\hat{\beta}\right]^{\top} \mathbf{z}_0 - \beta^{\top} \mathbf{z}_0}{\sqrt{\mathbf{z}_0^{\top} (\mathbf{Z}^{\top} \mathbf{Z})^{-1} \mathbf{z}_0}} \right) \\ \leq \mathbf{z}_0 (\mathbf{Z}^{\top} \mathbf{Z})^{-1} \mathbf{z}_0 \left[ \frac{m(n-k-1)}{n-k-m} F_{m,n-k-m}(\alpha) \right]$$

mà ở đó  $F_{m,n-k-m}(\alpha)$  là phân vị trên mức ý nghĩa  $100\alpha\%$  của phân phối Fisher với các bậc tự do là  $m$  và  $n-k-m$ . Từ đây ta có khoảng tin cậy đồng thời với độ tin cậy  $100(1-\alpha)\%$  của  $E(\mathbf{Y}_i | \mathbf{Z} = \mathbf{z}_0) = \mathbf{z}_0^{\top} \beta_{(i)}$  là:

$$\mathbf{z}_0 \left[\hat{\beta}\right]_{(i)} \pm \sqrt{\frac{m(n-k-1)}{n-k-m} F_{m,n-k-m}(\alpha)} \sqrt{\mathbf{z}_0^{\top} (\mathbf{Z}^{\top} \mathbf{Z})^{-1} \mathbf{z}_0 \left( \frac{n}{n-k-1} \hat{\Sigma}_{ii} \right)}$$

với  $\left[\hat{\beta}\right]_{(i)}$  là cột thứ  $i$  của ma trận  $\left[\hat{\beta}\right]$  và  $\hat{\Sigma}_{ii}$  là phần tử ở hàng thứ  $i$  trên đường chéo chính của ma trận  $\hat{\Sigma}$ .

Một vấn đề khác là việc đưa ra dự đoán về các giá trị của  $\mathbf{Y}_0 = [\beta]^{\top} \mathbf{z}_0 + \varepsilon_0$ , trong đó  $\varepsilon_0$  độc lập với các vector trong ma trận  $[\varepsilon]$ .

Ta lại có:

$$\mathbf{Y}_0 - \left[\hat{\beta}\right]^{\top} \mathbf{z}_0 \sim N_m \left( 0, \left[ 1 + \mathbf{z}_0^{\top} (\mathbf{Z}^{\top} \mathbf{Z})^{-1} \mathbf{z}_0 \right] \Sigma \right)$$

Khi đó miền ellipsoid dự đoán với độ tin cậy  $100(1-\alpha)\%$  là:

$$\left( \frac{\left[\hat{\beta}\right]^{\top} \mathbf{z}_0 - \beta^{\top} \mathbf{z}_0}{\sqrt{\mathbf{z}_0^{\top} (\mathbf{Z}^{\top} \mathbf{Z})^{-1} \mathbf{z}_0}} \right)^{\top} \left( \frac{n}{n-k-1} \hat{\Sigma} \right)^{-1} \left( \frac{\left[\hat{\beta}\right]^{\top} \mathbf{z}_0 - \beta^{\top} \mathbf{z}_0}{\sqrt{\mathbf{z}_0^{\top} (\mathbf{Z}^{\top} \mathbf{Z})^{-1} \mathbf{z}_0}} \right) \\ \leq \left( 1 + \mathbf{z}_0^{\top} (\mathbf{Z}^{\top} \mathbf{Z})^{-1} \mathbf{z}_0 \right) \left[ \frac{m(n-k-1)}{n-k-m} F_{m,n-k-m}(\alpha) \right]$$



Cuối cùng, ta có khoảng dự đoán đồng thời với độ tin cậy  $100(1 - \alpha)\%$  là:

$$\mathbf{z}_0 \left[ \hat{\boldsymbol{\beta}} \right]_{(i)} \pm \sqrt{\frac{m(n-k-1)}{n-k-m} F_{m,n-k-m}(\alpha)} \sqrt{\left(1 + \mathbf{z}_0^\top (\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{z}_0\right) \left(\frac{n}{n-k-1} \hat{\Sigma}_{ii}\right)}$$

### Nhận xét

So sánh hai công thức cho khoảng tin cậy, ta thấy rằng khoảng tin cậy cho giá trị thật của các biến phản hồi rộng hơn khoảng tin cậy của kỳ vọng.

### Ví dụ.

Quay trở lại ví dụ 2 trong phần 2.5.2, ta bổ sung thêm biến phản hồi thứ hai là  $\mathbf{Y}_2$ , chỉ dung lượng của đĩa với các quan sát tương ứng với các biến dự đoán  $\mathbf{z}_1, \mathbf{z}_2$  là:

$$\mathbf{Y}_2 = \begin{bmatrix} 301.8 & 396.1 & 328.2 & 307.4 & 362.4 & 369.5 & 229.1 \end{bmatrix}^\top$$

Ta tiến hành xác định miền ellipse tin cậy với mức ý nghĩa 5% cho  $\mathbf{Y}_0 = \begin{bmatrix} \mathbf{Y}_{01} & \mathbf{Y}_{02} \end{bmatrix}$  tương ứng với quan sát vừa thu được là  $\mathbf{Z}_0^\top = \begin{bmatrix} 1 & 130 & 7.5 \end{bmatrix}$ . Tính toán cho ta mô hình:

$$\hat{\mathbf{Y}}_2 = 14.14 + 2.25\mathbf{z}_1 + 5.67\mathbf{z}_2$$

Như vậy,  $\left[ \hat{\boldsymbol{\beta}}_{(2)} \right] = \begin{bmatrix} 14.14 & 2.25 & 5.67 \end{bmatrix}^\top$

Từ ví dụ 2 trong phần 2.5.2, ta có:

$$\left[ \hat{\boldsymbol{\beta}}_{(1)} \right] = \begin{bmatrix} 8.42 & 1.08 & 42 \end{bmatrix}^\top, \mathbf{z}_0^\top \boldsymbol{\beta}_{(1)} = 151.97, \mathbf{z}_0^\top (\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{z}_0 = 0.34725$$

Lại có:

$$\mathbf{z}_0^\top \boldsymbol{\beta}_{(2)} = 14.14 + 2.2511302 + 5.6717.52 = 349.17$$

và:

$$\begin{aligned} n\boldsymbol{\Sigma} &= \begin{bmatrix} \left( \mathbf{Y}_{(1)} - \mathbf{Z} \left[ \hat{\boldsymbol{\beta}} \right]_{(1)} \right)^\top \left( \mathbf{Y}_{(1)} - \mathbf{Z} \left[ \hat{\boldsymbol{\beta}} \right]_{(1)} \right) & \left( \mathbf{Y}_{(1)} - \mathbf{Z} \left[ \hat{\boldsymbol{\beta}} \right]_{(1)} \right)^\top \left( \mathbf{Y}_{(2)} - \mathbf{Z} \left[ \hat{\boldsymbol{\beta}} \right]_{(2)} \right) \\ \left( \mathbf{Y}_{(2)} - \mathbf{Z} \left[ \hat{\boldsymbol{\beta}} \right]_{(2)} \right)^\top \left( \mathbf{Y}_{(1)} - \mathbf{Z} \left[ \hat{\boldsymbol{\beta}} \right]_{(1)} \right) & \left( \mathbf{Y}_{(2)} - \mathbf{Z} \left[ \hat{\boldsymbol{\beta}} \right]_{(2)} \right)^\top \left( \mathbf{Y}_{(2)} - \mathbf{Z} \left[ \hat{\boldsymbol{\beta}} \right]_{(2)} \right) \end{bmatrix} \\ &= \begin{bmatrix} 5.80 & 5.30 \\ 5.30 & 13.13 \end{bmatrix} \end{aligned}$$

Bởi vì:

$$[\beta]^\top \mathbf{z}_0 = \begin{bmatrix} \hat{\beta}_{(1)}^\top \mathbf{z}_0 \\ \hat{\beta}_{(2)}^\top \mathbf{z}_0 \end{bmatrix} = \begin{bmatrix} 151.97 \\ 349.17 \end{bmatrix}$$

Với  $n = 7, r = 2, m = 2$ , miền ellipse tin cậy với mức ý nghĩa 5% cho  $[\hat{\beta}]^\top \mathbf{z}_0$  là tập các điểm trên mặt phẳng thỏa mãn:

$$\begin{aligned} \frac{4}{7} \begin{bmatrix} \mathbf{z}_0^\top \beta_{(1)} - 151.97 \\ \mathbf{z}_0^\top \beta_{(1)} - 349.17 \end{bmatrix}^\top \begin{bmatrix} 5.80 & 5.30 \\ 5.30 & 13.13 \end{bmatrix}^{-1} \begin{bmatrix} \mathbf{z}_0^\top \beta_{(1)} - 151.97 \\ \mathbf{z}_0^\top \beta_{(1)} - 349.17 \end{bmatrix} \\ \leq (0.347252) \left[ \frac{2(4)}{3} F_{2,3}(0.05) \right] \end{aligned}$$

trong đó,  $F_{2,3}(0.05) = 9.55$ . Ta xác định được tâm của ellipse là  $(151.97, 349.17)$ . Còn độ dài trục lớn và trục bé có thể được xác định dựa vào giá trị riêng và vector riêng của  $n\hat{\Sigma}$ .

# CHƯƠNG 3. ỨNG DỤNG HỒI QUY TUYẾN TÍNH TRONG DỰ BÁO GIÁ NHÀ ĐẤT

## 3.1 Mô tả bài toán

### 3.1.1 Đặt vấn đề

Trong nghiên cứu này, em tập trung vào việc giải quyết vấn đề đánh giá giá trị của các căn hộ bất động sản. Những người mới bước vào lĩnh vực này thường khó có thể đánh giá ngay được giá trị thực sự của một căn hộ chỉ qua những thuộc tính bên ngoài của nó. Vì vậy, em đề xuất xây dựng một thuật toán nhỏ nhằm dự báo giá trị của các căn hộ trong khu vực dựa trên các thông số như diện tích, khu đô thị, số phòng ngủ, ... và sử dụng dữ liệu từ những giao dịch bán căn hộ tương tự đã diễn ra trước đó.

Để xây dựng thuật toán, em thu thập thông tin về những giao dịch bán căn hộ trong một khu vực nhất định và trong khoảng thời gian xác định. Mỗi giao dịch sẽ được ghi nhận với những chi tiết như số phòng ngủ, diện tích, khu đô thị và giá bán cuối cùng. Nhờ có dữ liệu này, em sử dụng thuật toán học có giám sát để xây dựng mô hình và dự đoán giá trị của các căn hộ khác mà khách hàng quan tâm.

Nhưng nếu bạn không biết giá của các căn hộ đó thì sao? Thì với học máy, ta vẫn hoàn toàn có thể dự báo giá nhà được. Đó là học không giám sát.

Đồ án này nhằm xây dựng mô hình dự báo giá nhà dựa trên thuật toán hồi quy tuyến tính trong học có giám sát sẽ được tạo ra thông qua việc xác định các thuộc tính quan trọng từ tin bất động sản được đăng trên mạng. Kết quả từ mô hình này sẽ giúp cung cấp một ước lượng giá trị cụ thể cho mỗi căn nhà được nghiên cứu.

Tóm lại, nghiên cứu này nhằm phát triển một mô hình dự báo giá nhà dựa

trên thông tin thu thập từ tin bất động sản, và áp dụng các thuật toán hồi quy tuyến tính trong học có giám sát. Những kết quả dự đoán từ nghiên cứu này có thể cung cấp thông tin hữu ích cho các đại lý bất động sản và người mới bước vào lĩnh vực này để đánh giá giá trị của các căn hộ và hỗ trợ quyết định đầu tư một cách hiệu quả.

### 3.1.2 Bài toán

Trong dữ liệu của bài toán dự báo giá nhà, ta quan tâm đến giá nhà, diện tích, số phòng ngủ, ... Ví dụ  $\mathbf{Y}$  là giá nhà hiện nay, khi đó  $\mathbf{Y}$  phụ thuộc vào các yếu tố:

- $\mathbf{Z}_1$  là thu nhập trung bình của khu vực.
- $\mathbf{Z}_2$  là tuổi của ngôi nhà.
- $\mathbf{Z}_3$  là số lượng phòng.
- $\mathbf{Z}_4$  là số lượng phòng ngủ.
- $\mathbf{Z}_5$  là dân số khu vực.
- ...

Khi đó, ta có mô hình hồi quy tuyến tính của giá nhà như sau:

$$\mathbf{Y} = \beta_0 + \beta_1 \mathbf{Z}_1 + \dots + \beta_k \mathbf{Z}_k + \epsilon$$

## 3.2 Xây dựng bộ dữ liệu

### 3.2.1 Các bước tiến hành phân tích hồi quy

Để xây dựng một mô hình hồi quy tuyến tính hoàn chỉnh, ta làm theo các bước sau:

**Bước 1:** Tiền xử lý dữ liệu: chuẩn hóa tập mẫu  $z^* = \frac{z - \mu}{s}$

**Bước 2:** Xác định các biến quan trọng

- Ước lượng các hệ số hồi quy:  $\hat{\beta} = (\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{Z}^\top \mathbf{Y}$

- Sử dụng tiêu chuẩn  $F$ , kiểm tra mối liên hệ giữa  $\mathbf{Z}$  và  $\mathbf{Y}$  hay giả thiết:  $\beta_1 = \dots = \beta_k = 0$
- Xác định hệ số  $R$  của từng biến  $\mathbf{Z}_i$
- Lựa chọn các biến quan trọng, loại bỏ biến không cần thiết

**Bước 3:** Khảo sát phần dư

- Sử dụng tiêu chuẩn Student, kiểm tra các sai số  $\varepsilon$ .
- Xác định các outlier.
- Xác định các giá trị Leverage.
- Loại bỏ các outlier dựa vào các giá trị Leverage vừa tìm được.

**Bước 4:** Xây dựng mô hình

- Ước lượng lại hệ số hồi quy và khoảng tin cậy.
- Xác định hệ số  $R$ .
- Ước lượng hàm hồi quy tuyến tính.

### 3.3 Mô tả bộ dữ liệu

Trong đồ án II của em, em tập trung vào việc tìm hiểu mô hình hồi quy tuyến tính, sử dụng thuật toán học máy có giám sát để dự báo giá nhà đất. Mức tìm hiểu dừng lại ở giới thiệu chứ không đi sâu vào phân tích dữ liệu. Cho nên, bộ dữ liệu mà em xây dựng sẽ có quy mô rất nhỏ. Vì quy mô dữ liệu nhỏ nên, ta không cần bước chuẩn hóa dữ liệu và loại bỏ các biến ít quan trọng. Điều này đồng nghĩa với việc ta không cần phải khảo sát phần dư.

### Mô tả bộ dữ liệu

- Bộ dữ liệu gồm có 6 thuộc tính bao gồm: thu nhập trung bình của khu vực, tuổi của ngôi nhà, số lượng phòng, số lượng phòng ngủ, dân số khu vực và giá bán của từng ngôi nhà.
- Dữ liệu về giá bán của ngôi nhà đóng vai trò làm biến mục tiêu. Những dữ liệu còn lại đóng vai trò biến giải thích.
- Bộ dữ liệu được khảo sát ở 100 ngôi nhà khác nhau tại Hà Nội, có kích cỡ 1.06 MB.
- File dữ liệu mà em dùng để phân tích hồi quy: House-Price-HaNoi

Dưới đây là bảng dữ liệu mô tả 25 bản ghi đầu tiên trong bộ dữ liệu:

| Avg. Area Income<br>(Z <sub>1</sub> ) | Age<br>(Z <sub>2</sub> ) | Rooms<br>(Z <sub>3</sub> ) | Bedrooms<br>(Z <sub>4</sub> ) | Area Population<br>(Z <sub>5</sub> ) | Price<br>(Y) |
|---------------------------------------|--------------------------|----------------------------|-------------------------------|--------------------------------------|--------------|
| 79545.45857                           | 5.68                     | 7.01                       | 3.09                          | 23086.8005                           | 1059033.558  |
| 79248.64245                           | 6                        | 6.73                       | 2.09                          | 40173.07217                          | 1505890.915  |
| 61287.06718                           | 5.87                     | 8.51                       | 4.13                          | 36882.1594                           | 1058987.988  |
| 63345.24005                           | 7.19                     | 5.59                       | 2.26                          | 34310.24283                          | 1260616.807  |
| 59982.19723                           | 5.04                     | 7.84                       | 3.23                          | 26354.10947                          | 630943.4893  |
| 80175.75416                           | 4.99                     | 6.1                        | 3.04                          | 26748.42842                          | 1068138.074  |
| 64698.46343                           | 6.03                     | 8.15                       | 2.41                          | 60828.24909                          | 1502055.817  |
| 78394.33928                           | 6.99                     | 6.62                       | 1.42                          | 36516.35897                          | 1573936.564  |
| 59927.66081                           | 5.36                     | 6.39                       | 1.3                           | 29387.396                            | 798869.5328  |
| 81885.92718                           | 4.42                     | 8.17                       | 5.1                           | 40149.96575                          | 1545154.813  |

| Avg. Area Income<br>( $Z_1$ ) | Age<br>( $Z_2$ ) | Rooms<br>( $Z_3$ ) | Bedrooms<br>( $Z_4$ ) | Area Population<br>( $Z_5$ ) | Price<br>( $Y$ ) |
|-------------------------------|------------------|--------------------|-----------------------|------------------------------|------------------|
| 80527.47208                   | 8.09             | 5.04               | 3.1                   | 47224.35984                  | 1707045.722      |
| 50593.6955                    | 4.5              | 7.47               | 3.49                  | 34343.99189                  | 663732.3969      |
| 39033.80924                   | 7.67             | 7.25               | 2.1                   | 39220.36147                  | 1042814.098      |
| 73163.66344                   | 6.92             | 5.99               | 1.27                  | 32326.12314                  | 1291331.518      |
| 69391.38018                   | 5.34             | 8.41               | 3.37                  | 35521.29403                  | 1402818.21       |
| 73091.86675                   | 5.44             | 8.52               | 3.01                  | 23929.52405                  | 1306674.66       |
| 79706.96306                   | 5.07             | 8.22               | 2.12                  | 39717.81358                  | 1556786.6        |
| 61929.07702                   | 4.79             | 5.1                | 3.3                   | 24595.9015                   | 528485.2467      |
| 63508.1943                    | 5.95             | 7.19               | 4.12                  | 35719.65305                  | 1019425.937      |
| 62085.2764                    | 5.74             | 7.09               | 4.49                  | 44922.1067                   | 1030591.429      |
| 74869.96089                   | 5.93             | 5.76               | 4.86                  | 56435.9468                   | 1546049.065      |
| 43578.22298                   | 6.53             | 5.87               | 1.52                  | 54669.98497                  | 966195.8754      |
| 64000.23045                   | 6.25             | 5.34               | 2.44                  | 42480.07184                  | 1066329.83       |
| 51704.77701                   | 7.54             | 5.19               | 4.21                  | 41613.37366                  | 843607.4939      |
| 67764.9732                    | 7.26             | 8.18               | 4.8                   | 53360.11622                  | 1606869.264      |

Bảng 3.1 Bảng dữ liệu của 25 ngôi nhà đầu tiên

**Bài toán (P)**

Giá bán của 1000 căn hộ đầu tiên ở Hà Nội, được thẩm định dựa vào thu nhập trung bình của khu vực đó, tuổi của ngôi nhà, số lượng phòng, số lượng phòng ngủ, dân số khu vực và cuối cùng là giá bán của từng ngôi nhà.

## 3.4 Cài đặt thuật toán

### 3.4.1 Chương trình

```
1 import pandas as pd
2 import numpy as np
3 import statsmodels.api as sm
4 import matplotlib.pyplot as plt
5 from scipy import stats
6
7 # Load the dataset from the CSV file
8 data = pd.read_csv('DuLieuYKhoa.csv')
9
10 # Separate the target variable (Y) and the explanatory variables (X)
11 X = data.drop('Price', axis=1)
12 Y = data['Price']
13
14 # Step 1: Print the input data
15 print("Input Data:")
16 print(X)
17
18 # Step 2: Identify important variables
19 # Step 2.1: Using F criterion, check the relationship between X and Y
20 X_with_const = sm.add_constant(X)
21 model = sm.OLS(Y, X_with_const).fit()
22 f_p_value = model.f_pvalue
23 print("\nF-statistic p-value:", f_p_value)
24
25 # Step 2.2: Print out the regression coefficients
26 coefficients = pd.Series(model.params[1:], X.columns)
27 print("\nRegression Coefficients:")
28 print(coefficients)
29
30 # Step 2.3: Determine the coefficient R of each variable X (explanatory variable)
31 r_squared = model.rsquared
32 print("\nR-squared:", r_squared)
33
34 # Step 3: Survey of residuals
35 # Step 3.1: Using Student's criterion, check for epsilon errors
36 residuals = model.resid
37 t_stat, p_value = stats.ttest_1samp(residuals, 0)
38 print("\nStudent's t-test p-value:", p_value)
```



```

39
40 # Step 3.2: Identifying Outliers (using absolute z-scores > 3 as a threshold)
41 outliers = np.abs(stats.zscore(residuals)) > 3
42 print("\nOutliers identified:")
43 print(data[outliers])
44
45 # Step 3.3: Determining Leverage values
46 leverage = model.get_influence().hat_matrix_diag
47 print("\nLeverage values:")
48 print(leverage)
49
50 # Step 3.4: Eliminate outliers based on the newly found Leverage values
51 cleaned_data = data[~outliers]
52
53 # Step 4: Model building with cleaned data
54 X_cleaned = cleaned_data.drop('Price', axis=1)
55 Y_cleaned = cleaned_data['Price']
56
57 # Re-estimate the regression coefficients and confidence intervals
58 X_cleaned_with_const = sm.add_constant(X_cleaned)
59 model_cleaned = sm.OLS(Y_cleaned, X_cleaned_with_const).fit()
60
61 # Step 4.1: Print out the regression coefficients for the cleaned model
62 coefficients_cleaned = pd.Series(model_cleaned.params[1:], X_cleaned.columns)
63 print("\nRegression Coefficients (Cleaned Model):")
64 print(coefficients_cleaned)
65
66 # Step 4.2: Determination of R coefficient for the cleaned model
67 r_squared_cleaned = model_cleaned.rsquared
68 print("\nR-squared (Cleaned Model):", r_squared_cleaned)
69
70 # Step 4.3: Estimating the linear regression function for the cleaned model
71 def regression_function(x):
72     x_with_const = sm.add_constant(x)
73     return model_cleaned.predict(x_with_const)
74
75 # Step 5: Print out the predicted Y values for the cleaned model
76 predicted_Y_cleaned = regression_function(X_cleaned)
77 print("\nPredicted Y (Cleaned Model):")
78 print(predicted_Y_cleaned)
79
80 # Step 6: Print out the actual Y values for the cleaned model
81 print("\nActual Y (Cleaned Model):")

```

```
82 print(Y_cleaned.values)
83
84 # Step 7: Print out the error value of the cleaned model (mean squared error)
85 error_cleaned = np.mean((predicted_Y_cleaned - Y_cleaned) ** 2)
86 print("\nMean Squared Error (Cleaned Model):", error_cleaned)
87
88 # Step 8: Graph comparing predicted values and actual values for the cleaned
      model
89 plt.scatter(Y_cleaned, predicted_Y_cleaned)
90 plt.xlabel("Giá trị Y thực tế")
91 plt.ylabel("Giá trị Y dự đoán")
92 plt.title("So sánh giá trị dự đoán và giá trị thực tế")
93 plt.show()
```

### 3.4.2 Kết quả

- Dữ liệu vào

```
Input Data:
      Avg. Area Income    Age  Rooms  Bedrooms  Area Population
0      79545.45857    5.68   7.01     3.09     23086.80050
1      79248.64245    6.00   6.73     2.09     40173.07217
2      61287.06718    5.87   8.51     4.13     36882.15940
3      63345.24005    7.19   5.59     2.26     34310.24283
4      59982.19723    5.04   7.84     3.23     26354.10947
..      ...      ...      ...      ...      ...
995     65698.35901    5.83   5.87     4.30     42943.61345
996     75411.99691    5.20   5.49     3.62     24043.15068
997     81677.82078    6.92   6.94     2.16     48817.24623
998     53356.81750    5.70   6.40     5.00     40020.82910
999     54223.66930    4.46   5.47     2.03     58231.02792

[1000 rows x 5 columns]
```

Hình 3.1 Dữ liệu đầu vào.

- Hệ số hồi quy

```
Regression Coefficients:
Avg. Area Income      21.411404
Age                   151417.659281
Rooms                 107411.692174
Bedrooms              -30195.818531
Area Population       13.911822
dtype: float64
```

Hình 3.2 Hệ số hồi quy.

- Hệ số  $R$

R-squared: 0.9654261104853933

Hình 3.3 Hệ số  $R$ .

- Outliers

Outliers identified:  
Empty DataFrame

Hình 3.4 Các điểm dữ liệu bất thường.

- Giá trị  $Y$  dự đoán

```
Predicted Y (Cleaned Model):
0      1.211616e+06
1      1.491536e+06
2      1.171080e+06
3      1.122063e+06
4      8.262101e+05
...
995    1.055101e+06
996    8.844671e+05
997    1.823551e+06
998    7.662966e+05
999    8.402249e+05
Length: 1000, dtype: float64
```

Hình 3.5 Giá trị  $Y$  dự đoán.

- Giá trị Y thực tế

```
Actual Y (Cleaned Model):
0      1.059034e+06
1      1.505891e+06
2      1.058988e+06
3      1.260617e+06
4      6.309435e+05
...
995    9.594905e+05
996    8.930305e+05
997    1.962033e+06
998    7.566989e+05
999    8.808498e+05
Name: Price, Length: 1000, dtype: float64
```


Hình 3.6 Giá trị Y thực tế.

- Giá trị sai số của mô hình

```
Mean Squared Error (Cleaned Model): 5093453730.805487
```

Hình 3.7 Giá trị sai số của mô hình.

- So sánh giá trị dự đoán và giá trị thực tế



Hình 3.8 So sánh giá trị dự đoán và giá trị thực tế.

Sau đây, em sẽ áp dụng lý thuyết về mô hình hồi quy tuyến tính để từ tập dữ liệu này, xây dựng một hàm sử dụng cho việc định giá một bất động sản (giá nhà) bất kì trong tương lai. Chúng ta chuyển sang phần tiếp theo, đó là kiểm nghiệm thuật toán và áp dụng.

### 3.5 Kiểm nghiệm thuật toán và áp dụng

Ta tiến hành tìm mô hình hồi quy của bài toán (P) bằng hồi quy tuyến tính.

Giả sử các thuộc tính này tuân theo mô hình tuyến tính cổ điển, khi đó:

$$Y = \beta_0 + \beta_1 Z_1 + \beta_2 Z_2 + \beta_3 Z_3 + \beta_4 Z_4 + \beta_5 Z_5 + \varepsilon$$

Từ bảng dữ liệu ta có:

$$\mathbf{Z} = \begin{bmatrix} 1 & 79545.45857 & 5.68 & 7.01 & 3.09 & 23086.8005 \\ 1 & 79248.64245 & 6 & 6.73 & 2.09 & 40173.07217 \\ 1 & 61287.06718 & 5.87 & 8.51 & 4.13 & 36882.1594 \\ 1 & 63345.24005 & 7.19 & 5.59 & 2.26 & 34310.24283 \\ 1 & 59982.19723 & 5.04 & 7.84 & 3.23 & 26354.10947 \\ 1 & 80175.75416 & 4.99 & 6.1 & 3.04 & 26748.42842 \\ 1 & 64698.46343 & 6.03 & 8.15 & 2.41 & 60828.24909 \\ 1 & 78394.33928 & 6.99 & 6.62 & 1.42 & 36516.35897 \\ 1 & 59927.66081 & 5.36 & 6.39 & 1.3 & 29387.396 \\ & & & \dots\dots\dots & & \\ 1 & 42308.44668 & 4.67 & 7.38 & 4.58 & 58814.38534 \\ 1 & 76503.13468 & 5.6 & 6.06 & 2.47 & 24916.09247 \\ 1 & 49564.74924 & 5.53 & 8.05 & 1.69 & 60008.35154 \\ 1 & 54378.2455 & 5.33 & 7.24 & 3.41 & 27744.7482 \\ 1 & 65698.35901 & 5.83 & 5.87 & 4.3 & 42943.61345 \\ 1 & 75411.99691 & 5.2 & 5.49 & 3.62 & 24043.15068 \\ 1 & 81677.82078 & 6.92 & 6.94 & 2.16 & 48817.24623 \\ 1 & 53356.8175 & 5.7 & 6.4 & 5 & 40020.8291 \\ 1 & 54223.6693 & 4.46 & 5.47 & 2.03 & 58231.02792 \end{bmatrix} \quad \text{và } \mathbf{Y} = \begin{bmatrix} 1059033.558 \\ 1505890.915 \\ 1058987.988 \\ 1260616.807 \\ 630943.4893 \\ 1068138.074 \\ 1502055.817 \\ 1573936.564 \\ 798869.5328 \\ \dots \\ 777791.7134 \\ 979883.9464 \\ 1206375.023 \\ 678969.8975 \\ 959490.47 \\ 893030.4572 \\ 1962032.627 \\ 756698.9085 \\ 880849.7545 \end{bmatrix}$$

Cặp giả thuyết:

$$\mathbf{H}_0 : \beta_1 = \beta_2 = \dots = \beta_k = 0 \text{ và } \mathbf{H}_1 : \exists \beta_j \neq 0 \text{ với } j = \overline{1, k} \text{ với mức ý nghĩa } 1\%.$$

Ta tính được:

$$\mathbf{Z}^T \mathbf{Z} = \begin{bmatrix} 1000 & 60634430.63 & 6238.57 & 6783.9 & 3211.09 & 41759375.43 \\ 60634430.63 & 3828075461295.65 & 378893162.95 & 412052199.34 & 194986005.56 & 2531769718411.39 \\ 6238.57 & 378893162.95 & 40036.8481 & 42325.1677 & 20055.219 & 261492759.6 \\ 6783.9 & 412052199.34 & 42325.1677 & 47041.8284 & 21817.1256 & 283607608.4 \\ 3211.09 & 194986005.56 & 20055.219 & 21817.1256 & 11500.1593 & 133675424.4 \\ 41759375.43 & 2531769718411.39 & 261492759.60 & 283607608.40 & 133675424.37 & 1859707976051.43 \end{bmatrix}$$

$$(\mathbf{Z}^T \mathbf{Z})^{-1} = \begin{bmatrix} 11651542858 & -34612.34403 & -505308216.5 & -621198491.6 & -245654178.1 & -31070.29906 \\ -34612.34403 & 0.663837982 & -369.720462 & -460.6696046 & -136.3026689 & 0.005513722 \\ -505308216.5 & -369.720462 & 90431713.27 & 264114.3452 & -1908838.52 & -768.7097791 \\ -621198491.6 & -460.6696046 & 264114.3452 & 98487761.54 & -2761787.075 & -282.0814152 \\ -245654178.1 & -136.3026689 & -1908838.52 & -2761787.075 & 84361407.26 & 327.3720328 \\ -31070.29906 & 0.005513722 & -768.7097791 & -282.0814152 & 327.3720328 & 0.871517308 \end{bmatrix} \times 10^{-11}$$

$$\hat{\beta} = (\mathbf{Z}^T \mathbf{Z})^{-1} \mathbf{Z}^T \mathbf{Y} = \begin{bmatrix} -2332446.827 \\ 21.41140418 \\ 151417.6593 \\ 107411.6922 \\ -30195.81853 \\ 13.91182153 \end{bmatrix}$$

Từ đây, ta được phương trình hồi quy tuyến tính mẫu là:

$$\hat{\mathbf{Y}} = -2332446.827 + 21.41140418\mathbf{Z}_1 + 151417.6593\mathbf{Z}_2 + 107411.6922\mathbf{Z}_3 - 30195.81853\mathbf{Z}_4 + 13.91182153\mathbf{Z}_5$$



$$\hat{\mathbf{Y}} = \mathbf{Z} (\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{Z}^\top \mathbf{Y} = \begin{bmatrix} 1211615.773 \\ 1491535.881 \\ 1171079.789 \\ 1122063.466 \\ 826210.0851 \\ 1075338.167 \\ 1614751.723 \\ 1580691.904 \\ 818225.5517 \\ \dots \\ 753173.5659 \\ 1076491.018 \\ 1214602.374 \\ 699596.7859 \\ 1055100.745 \\ 884467.0958 \\ 1823551.202 \\ 766296.5858 \\ 840224.9458 \end{bmatrix} \quad \hat{\boldsymbol{\varepsilon}} = \mathbf{Y} - \mathbf{Z}\hat{\boldsymbol{\beta}} = \begin{bmatrix} -152582.2153 \\ 14355.03387 \\ -112091.8008 \\ 138553.3416 \\ -195266.5956 \\ -7200.093139 \\ -112695.906 \\ -6755.340223 \\ -19356.01867 \\ \dots \\ 24618.14756 \\ -96607.07098 \\ -8227.350815 \\ -20626.88826 \\ -95610.27515 \\ 8563.361601 \\ 138481.4254 \\ -9597.677113 \\ 40624.80887 \end{bmatrix}$$

Ta tính các hệ số:

1.  $\bar{y} = \sum_{k=1}^n \frac{y_k}{n} = 1123108.807$
2.  $\sum_{k=1}^n (y_k - \bar{y})^2 = 147320819332566.4$
3.  $s^2 = \frac{1}{n - k - 1} \sum_{j=1}^n \hat{\varepsilon}_j^2 = \frac{5093453731529.69}{994} = 5124198925.08017$

Từ đó ta tính được:

1. Tổng bình phương các phần dư:

$$\sum_{k=1}^n \hat{\epsilon}_k^2 = \sum_{k=1}^n y_k^2 - \mathbf{Y}^T \mathbf{Z} \hat{\beta} = 5093453731529.692$$

2. Bình phương hệ số xác định:

$$R^2 = 1 - \frac{\sum_{k=1}^n \hat{\epsilon}_k^2}{\sum_{k=1}^n (y_k - \bar{y})^2} = 1 - 0.0346 = 0.9654$$

$$3. \text{ F-scored: } F = \frac{(n - k - 1) R^2}{k (1 - R^2)} = \frac{(1000 - 5 - 1) \times 0.9654}{5 (1 - 0.9654)} = 5546.865$$

Ta có:  $F_{5,994}(0.01) = 3.036 \Rightarrow F > F_{5,994}(0.01)$

$\Rightarrow$  Với mức ý nghĩa 1%, ta được  $F > F_{5,994}(0.01)$ . Do đó, ta bác bỏ giả thuyết  $\mathbf{H}_0$ , tức là bài toán có sự phụ thuộc vào các biến độc lập.

4. Từ giá trị của  $s^2$ , ta tính lần lượt các giá trị sau:

$$\begin{aligned} \left[ s^2 (\mathbf{Z}^T \mathbf{Z})^{-1} \right]_{11} &= 5124198925.08017 \times 0.116515429 \\ \left[ s^2 (\mathbf{Z}^T \mathbf{Z})^{-1} \right]_{22} &= 5124198925.08017 \times 0.00000000000664 \\ \left[ s^2 (\mathbf{Z}^T \mathbf{Z})^{-1} \right]_{33} &= 5124198925.08017 \times 0.000904317 \\ \left[ s^2 (\mathbf{Z}^T \mathbf{Z})^{-1} \right]_{44} &= 5124198925.08017 \times 0.000984878 \\ \left[ s^2 (\mathbf{Z}^T \mathbf{Z})^{-1} \right]_{55} &= 5124198925.08017 \times 0.000843614 \\ \left[ s^2 (\mathbf{Z}^T \mathbf{Z})^{-1} \right]_{66} &= 5124198925.08017 \times 0.00000000000872 \end{aligned}$$

Và với  $t_{994}(0.005) = 2.581$ , ta có khoảng tin cậy đồng thời mức 99% của các hệ số hồi quy là:

$$\begin{aligned}\widehat{\beta}_0 \pm t_{994}(0.005) \sqrt{\left[s^2 (\mathbf{Z}^\top \mathbf{Z})^{-1}\right]_{11}} &= -2332446.827 \pm 63065.626 \\ \widehat{\beta}_1 \pm t_{994}(0.005) \sqrt{\left[s^2 (\mathbf{Z}^\top \mathbf{Z})^{-1}\right]_{22}} &= 21.41140418 \pm 0.476 \\ \widehat{\beta}_2 \pm t_{994}(0.005) \sqrt{\left[s^2 (\mathbf{Z}^\top \mathbf{Z})^{-1}\right]_{33}} &= 151417.6593 \pm 5555.989 \\ \widehat{\beta}_3 \pm t_{994}(0.005) \sqrt{\left[s^2 (\mathbf{Z}^\top \mathbf{Z})^{-1}\right]_{44}} &= 107411.6922 \pm 5798.187 \\ \widehat{\beta}_4 \pm t_{994}(0.005) \sqrt{\left[s^2 (\mathbf{Z}^\top \mathbf{Z})^{-1}\right]_{55}} &= -30195.81853 \pm 5366.274 \\ \widehat{\beta}_5 \pm t_{994}(0.005) \sqrt{\left[s^2 (\mathbf{Z}^\top \mathbf{Z})^{-1}\right]_{66}} &= 13.91182153 \pm 0.546\end{aligned}$$

5. Tiếp theo, ta sẽ kiểm định giả thuyết  $\mathbf{H}_0 : \widehat{\beta}_{(2)} = \begin{bmatrix} \beta_2 & \beta_3 & \beta_4 \end{bmatrix}^\top = 0$

$$\text{với ma trận } \mathbf{C} = \begin{bmatrix} \mathbf{0}_{2 \times 4} & \vdots & \mathbf{I}_{2 \times 2} \end{bmatrix} = \begin{bmatrix} 0 & 0 & 0 & 0 & 1 & 0 \\ 0 & 0 & 0 & 0 & 0 & 1 \end{bmatrix}$$

Với giả thiết trên ta có  $n = 1000, k = 5, q = 3$ .

Ta tính các giá trị sau:

$$\mathbf{C}\widehat{\beta} = \begin{bmatrix} -30195.81853 \\ 13.91182153 \end{bmatrix} \quad \mathbf{C}(\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{C}^\top = \begin{bmatrix} 8.43614 & 0.00000000327 \\ 0.00000000327 & 0.00000000000872 \end{bmatrix}$$

$$\text{Từ đó, ta có: } \frac{(\mathbf{C}\widehat{\beta})^\top [\mathbf{C}(\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{C}^\top]^{-1} \mathbf{C}\widehat{\beta}}{s^2} = 4331.40145443$$

Với độ tin cậy 99% ta có:  $(k - q) F_{k-q, n-k-1}(\alpha) = 2.F_{2,994}(0.01) = 9.253$

Vì  $9.253 < 4331.40145443$  nên ta bác bỏ giả thuyết  $\mathbf{H}_0$  với mức ý nghĩa 1%. Hay nói cách khác, với xác suất sai lầm là 1%, thì giá của ngôi nhà sẽ phụ thuộc tuyến tính vào ít nhất 1 trong 3 yếu tố là tuổi ngôi nhà, số phòng và số phòng ngủ.

6. Cuối cùng, ta sẽ tiến hành ước lượng hàm hồi quy tuyến tính tại một vector  $\mathbf{z}_0$ .

$$\text{Cho } \mathbf{z}_0 = \begin{bmatrix} 1 & 79264.75623 & 5.06 & 8.19 & 2.79 & 34034.84964 \end{bmatrix}^\top$$

Ta có:

$$\mathbf{z}_0^\top \hat{\boldsymbol{\beta}} = 1399838.441, s^2 = 5124198925.08017, \mathbf{z}_0^\top (\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{z}_0 = 0.00706008$$

Do đó, khoảng tin cậy đồng thời mức 99% của hàm hồi quy tuyến tính tại  $\mathbf{z}_0$  là:

$$\mathbf{z}_0^\top \hat{\boldsymbol{\beta}} \pm t_{994}(0.005) \sqrt{s^2 \mathbf{z}_0^\top (\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{z}_0} = 1399838.441 \pm 15524.078$$

và khoảng dự đoán mức 99% của quan sát mới  $\mathbf{Y}_0$  tại  $\mathbf{z}_0$  là:

$$\mathbf{Y}_0 = \mathbf{z}_0^\top \hat{\boldsymbol{\beta}} \pm t_{n-k-1} \left( \frac{\alpha}{2} \right) \sqrt{s^2 \left( 1 + \mathbf{z}_0^\top (\mathbf{Z}^\top \mathbf{Z})^{-1} \mathbf{z}_0 \right)} = 1399838.441 \pm 185408.092$$

Như vậy,  $\mathbf{Y}_0 \in (1214430.349, 1585246.533)$

Đối chiếu với kết quả ta tổng hợp được trong file dữ liệu, ta thấy thực tế  $\mathbf{Y}_0 = 1529666.047$  nằm trong khoảng giá trị trên.

| Avg. Area Income | Age  | Rooms | Bedrooms | Area Population | Price       |
|------------------|------|-------|----------|-----------------|-------------|
| 179264.75623     | 5.06 | 8.19  | 2.79     | 34034.84964     | 1529666.047 |

Hình 3.9 Thống số bản ghi trong file dữ liệu.

*Qua đó, ta có thể kết luận phần nào tính đúng đắn của thuật toán trong việc xây dựng mô hình hồi quy tuyến tính để dự đoán giá nhà. Tuy nhiên phân tích cho thấy thuật toán xây dựng mô hình hồi quy tuyến tính để dự đoán giá nhà cần được cải tiến. Mô hình hiện tại chưa chuẩn hóa dữ liệu, dẫn đến tính ổn định không cao và ước lượng chưa chính xác. Để cải thiện, cần thực hiện chuẩn hóa dữ liệu và lựa chọn biến quan trọng một cách cẩn thận. Điều này sẽ giúp đạt được mô hình chính xác và tin cậy hơn trong dự báo giá nhà.*

### 3.6 Đánh giá thuật toán

Hồi quy tuyến tính là một thuật toán đơn giản và dễ hiểu, được sử dụng phổ biến để mô hình hóa mối quan hệ giữa một biến độc lập đầu vào và biến phụ thuộc đầu ra thông qua mô hình tuyến tính. Ngoài ra, trong trường hợp tổng quát hơn, chúng ta còn có hồi quy tuyến tính đa biến, nơi một mô hình được xây

dựng để mô tả mối quan hệ giữa nhiều biến độc lập đầu vào và biến phụ thuộc đầu ra. Trong cả hai trường hợp, mô hình vẫn duy trì tính tuyến tính, trong đó đầu ra được biểu diễn bằng sự kết hợp tuyến tính của các biến đầu vào.

Việc đánh giá thuật toán này có thể dựa vào những ưu điểm và nhược điểm của mô hình.

- **Ưu điểm**

1. Hồi quy tuyến tính nhanh chóng và hữu ích khi mối quan hệ giữa biến độc lập và biến phụ thuộc không quá phức tạp và khi dữ liệu không lớn.
2. Thuật toán đơn giản và dễ hiểu.
3. Phân tích hồi quy cung cấp thông tin về các mối quan hệ đáng kể giữa biến độc lập và biến phụ thuộc, cho thấy tác động của nhiều biến độc lập lên biến phụ thuộc. Điều này làm cho mô hình hồi quy hữu ích trong việc dự báo doanh thu, giá bất động sản, và các lĩnh vực tương tự mà các doanh nghiệp cần thiết phải sử dụng mô hình dự báo.

- **Nhược điểm**

1. Trong trường hợp dữ liệu lớn và phức tạp, mô hình hồi quy tuyến tính không hoạt động tốt bằng các mô hình khác.
2. "Nhảy cảm với nhiễu"(outlier) là một nhược điểm lớn của thuật toán. Điểm nhiễu có thể làm thay đổi đường thẳng tuyến tính tìm được theo hồi quy tuyến tính, ảnh hưởng xấu đến kết quả dự đoán. Trước khi thực hiện hồi quy, cần loại bỏ các nhiễu này để đảm bảo tính chính xác của mô hình.
3. Hồi quy tuyến tính không thể biểu diễn các mô hình phức tạp. Mặc dù có thể áp dụng một số biến thể để xác định mối quan hệ không tuyến tính giữa biến độc lập và biến phụ thuộc, nhưng mô hình này vẫn đơn giản hơn rất nhiều so với các mô hình thực tế. Để dễ so sánh, ta đặt ra câu hỏi: "Làm thế nào để xác định được các hàm  $\sin x$ ,  $x^3$ ,  $\log(x)$ , ...?"

## CHƯƠNG 4. TỔNG KẾT

Phân tích hồi quy tuyến tính là một kỹ thuật thống kê dùng để xác định phương trình phù hợp nhất cho tập hợp kết quả quan sát của biến phụ thuộc và biến độc lập. Qua đó, nó cung cấp kết quả ước lượng tốt nhất về mối quan hệ giữa các biến số. Bằng cách sử dụng phương trình ước lượng này, chúng ta có thể dự báo giá trị của biến phụ thuộc dựa trên giá trị đã biết của biến độc lập.

Trong đề án này, em đã tìm hiểu về các nội dung sau:

1. Mô hình hồi quy tuyến tính cổ điển và đa biến.
2. Ước lượng khoảng tin cậy cho các hệ số hồi quy.
3. Xây dựng thuật toán hồi quy tuyến tính.
4. Xử lý dữ liệu khi gặp điểm ngoại lệ (outlier).
5. Kiểm tra các khía cạnh của mô hình hồi quy.
6. Xây dựng mô hình hồi quy tuyến tính đa bội.
7. Ứng dụng hồi quy tuyến tính để dự đoán giá nhà đất.
8. Đánh giá hiệu quả của thuật toán.

Em xin kính gửi đề án II đã hoàn thành sau quá trình học tập và làm việc dưới sự hướng dẫn tận tình của thầy Lê Đình Nam. Trong đề án này, em đã trình bày đầy đủ kiến thức về hồi quy tuyến tính trong học máy và áp dụng nó để xây dựng mô hình dự báo giá nhà đất.

Tuy nhiên, em nhận thức rằng sẽ luôn có những khuyết điểm trong quá trình nghiên cứu và biểu diễn. Vì vậy, em rất mong nhận được những góp ý, đánh giá từ thầy để hoàn thiện hơn trong tương lai.

Cuối cùng, em xin chân thành cảm ơn thầy Lê Đình Nam - giảng viên đã dành thời gian, tâm huyết hướng dẫn và cung cấp thông tin liên tục để giúp em nắm vững và hiểu sâu hơn về môn học. Em rất biết ơn thầy và xin gửi lời tri ân sâu sắc ạ!

## Tài liệu tham khảo

- [1] Wiley-series-in-probability-and-statistics-Sanford-Weisberg-Applied-linear-regression, A JOHN WILEY & SONS, INC., PUBLICATION
- [2] Lê Xuân Lý, Slide bài giảng Phân tích số liệu, Đại học Bách khoa Hà Nội
- [3] Tống Đình Quỳ, Giáo trình Xác suất thống kê, Đại học Bách khoa Hà Nội
- [4] N. J. le Roux, Sugnet Gardner. "Analysing Your Multivariate Data as a Pictorial: A Case for Applying Biplot Methodology", International Statistical Review, 73 (2005).
- [5] Richard Johnson, Dean Wichern. "Applied Multivariate Statistical Analysis", Pearson New International Edition, 7 (2014).
- [6] Machine Learning cơ bản.  
<https://machinelearningcoban.com/2016/12/28/linearregression>
- [7] Gareth James, Daniela Witten, Trevor Hastie Robert, Tibshirani. "Introduction to statistical learning", (2014).
- [8] Kenney, Yuchun Lee, Benjamin Van Roy, Christopher D. Reed, Richard P. Lippmann. "Solving Data Mining Problems Through Pattern Recognition", Upper Saddle River, NJ: Prentice-Hall, (1997).